

STATISTICA

(1)

MODELLO STATISTICO

$X_1 \dots X_n$ campione casuale v.a. iid

Immagino che la legge della variabile

$f(x_i)$ dipenda da $\theta \in \mathbb{R}^k$ θ incognito

($f(x_i)$ è la funzione densità con $f_{x_i}(t)$ f.d.p. quindi
- ci mettiamo in un sotto spazio, quindi c'è basta fare
inferenze su un insieme finito)

$X_1 \dots X_n \quad X_i \sim \text{Bin}(p) \quad \theta = p \in [0,1]$

$X_1 \dots X_n \quad X_i \sim N(\mu, \sigma^2) \quad \theta = (\theta_1, \theta_2) = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+$

COS'E UN MODELLO STATISTICO IN QUESTO AMBITO PARAMETRICO?

È LA TRIPLETTA

$(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \{\rho_\theta, \theta \in \Theta \subset \mathbb{R}^k\})$

o'algebra dei
σ-insiemi

per ogni scelta dei
possibili valori dei
parametri ho lo
spazio dove vive il mio
modello

Io sperimentazione ha a disposizione
la realizzazione del vettore

$x_1 \dots x_n$ dati \rightarrow con questi dati vogliamo dare info su θ .

Il modello statistico deve utilizzare la realizzazione casuale x
dare informazione sul modello statistico.

Def STATISTICA

$Y = T(X_1 \dots X_n)$ FUNZIONE DELLE SOLE V.A. È UNA STATISTICA

es campione gaussiano

$X_1 \dots X_n \sim N(\mu, \sigma^2)$

\bar{X}_n È UNA STATISTICA

$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ NON È UNA STATISTICA perché dipende anche
da μ e σ che sono parametri incogniti

Come faccio a conoscere i parametri incogniti? Usando la statistica

$T(X_1 \dots X_n) = \frac{1}{n} \sum x_i$ STATISTICA MEDIA CAMPIONARIA

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2$ STATISTICA VARIANZA CAMPIONARIA

$\sqrt{S^2} = S$

$X_{(1)} = \min(X_1 \dots X_n)$ STATISTICA: minimo

$X_{(n)} = \max(X_1 \dots X_n)$ STATISTICA: massimo

(come si calcolano min e max conoscendo una v.a?)

$T(X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}$

ma potremmo in realtà anche avere delle statistiche bidimensionali.

$(T_1, T_2) : \Omega \rightarrow \mathbb{R}^2$

- Il campione stesso è una statistica, ma mentre le altre statistiche "summarize" i dati, riproducono una sintesi, il campione stesso non lo fa.
Dobbiamo scegliere la statistica in modo da riuscire a definire il parametro θ .

PRINCIPIO DI SUFFICIENZA

DATO UN CAMPIONE CASUALE $X_1, \dots, X_n \rightarrow$
LA CUI LEGGE $\mathcal{L}(X_i)$ DIPENDE DA θ

LA STATISTICA $T(\vec{X})$ È SUFFICIENTE PER θ

QUANDO OGNI INFERENZA SU θ DIPENDE DA \vec{X}
SOLO TRAMITE $T(\vec{X})$.

OSSIA SE HO DUE REALIZZAZIONI DEL CAMPIONE \vec{x}, \vec{y} DIVERSE
 $T(\vec{x}) = T(\vec{y})$ L'INFERENZA CHE FARÒ SU θ È LA STESSA

SE $T(\vec{x})$ È SUFFICIENTE

SE HO DUE CAMPIONI DIVERSI MA LA MEDIA ARITMETICA È LA STESSA
E LA STATISTICA È SUFFICIENTE ALLORA LA MEDIA È UGUALE
LA + BONITA STATISTICA SUFFICIENTE È IL CAMPIONE INTERO

Def STATISTICA SUFFICIENTE

$T(\vec{X})$ È STATISTICA SUFFICIENTE PER θ

SE LA DISTRIBUZIONE CONDIZIONATA A $T(\vec{X}) = t$
NON DIPENDE DA θ QUALUNQUE SIAT.

LA LEGGE DI (X_1, \dots, X_n) CONDIZIONATA A $T(\vec{X}) = t$

ESEMPIO

X_1, X_2 iid $Be(p)$

prendiamo $T(\vec{X}) = X_1 + X_2$

La legge compiuta del campione dipende solo da p .

$T(\vec{X}) = t \quad t = 0, 1, 2$

$P(X_1, X_2 | t=0)$

diventa

$$P(X_1=0, X_2=0 | t=0) = \frac{1}{4}$$

$$P(X_1=1, X_2=1 | t=2) = \frac{1}{4}$$

$$P(X_1=1, X_2=0 | t=1) = \frac{P(X_1=1, X_2=0, T=1)}{P(T=1)} = \frac{P(1-p)}{\binom{2}{1} p(1-p)} = \frac{1}{2}$$

idem per

$$P(X_1=0, X_2=1 | t=1) = \frac{1}{2}$$

$\wedge T \sim Bi(2, p)$

X_k è somma di 2 Bernoulli

ma se la somma della somma è degenera agli estremi,
vali $\frac{1}{2}$ per $t=1$. (3)

Ma non dipende da $p \Rightarrow$ La legge è sufficente

Ho tutte le info necessarie x parlare di p

Ma mettendo a calcolo la legge condizionata potrebbe essere un bel particolo
quindi di fatto come controllo se la statistica è sufficiente?

TEOREMA di FATTORIZZAZIONE

SIA $f(\vec{x}, \theta)$ LA DENSITÀ CONGIUNTA (discreta o continua)
DEL CAMPIONE \vec{x} .

UNA STATISTICA $T(\vec{x})$ È SUFFICIENTE PER θ

\exists DUE FUNZIONI $g(t, \theta)$
 $t \in$ \uparrow
 $h(\vec{x})$

$\forall \vec{x}, \theta$ LA DENSITÀ CONGIUNTA
 $f(\vec{x}, \theta) = g(T(\vec{x}), \theta) \cdot h(\vec{x})$

Interessante è che è un \Leftrightarrow
la densità $f(\vec{x}, \theta)$: $\mathbb{R}^n \rightarrow \mathbb{R}$
- altrimenti la f non dipende da θ , è equivalente a scrivere $f_\theta(\vec{x})$,
la densità, quindi la probabilità quindi la media dipende da θ
 $E\theta(\vec{x})$ (potrebbe essere che come notazione si trovi $f(\vec{x}|\theta)$,
Approccio Bayesiano che vede θ come v.a.)
di più nel CASO DISCRETO.

• SIA $T(\vec{x})$ STATISTICA SUFFICIENTE

dove mostriamo che posso fattorizzare la legge congiunta.

$$f(\vec{x}, \theta) = P_\theta(\vec{X} = \vec{x}) = P_\theta(\vec{X} = \vec{x} | T(\vec{x}) = T(\vec{x}))$$

TEO BAYES

Poiché la statistica
è sufficiente, non dipende
da θ .

$$h(\vec{x})$$

$$g(T(\vec{x}), \theta)$$

dipende
da θ ma
tramite $T(\vec{x})$.

$T(\vec{x})$
è la libbra di T .

• SAPENDO CHE VALE LA

FATTORIZZAZIONE DOBBIAMO

DIMOSTRARE CHE $T(\vec{x})$ È SUFFICIENTE

Assumiamo che valga la fattorizzazione

$$f(\vec{x}, \theta) = h(\vec{x}) g(T(\vec{x}), \theta)$$

Chiamiamo

$$A_{T(\vec{x})} = \{\vec{y} : T(\vec{y}) = T(\vec{x})\}$$

$$\text{Calcolo la legge di } \vec{X} | T = \frac{f(\vec{x}, \theta)}{q(T(\vec{x}), \theta)}$$

\leftarrow $p(X=\vec{x}, T=t)$
non è nulla solo
and $T=T(\vec{x})$

$$= \frac{h(\vec{x}) g(T(\vec{x}), \theta)}{q(T(\vec{x}), \theta)} =$$

\leftarrow marginale
legge di T

$$\begin{aligned}
 &= \frac{g(T(\vec{x}), \theta) h(x)}{\sum_{y \in A_T(x)} f(y, \theta)} = \frac{g(T(\vec{x}), \theta) h(x)}{\sum_{y \in A_T(x)} g(T(y), \theta) h(y)} \\
 &= \frac{g(T(\vec{x}), \theta) h(\vec{x})}{g(T(\vec{x}), \theta) \sum_{y \in A_T(\vec{x})} h(y)}
 \end{aligned}$$

ma sommando su questo insieme ho che $g(T(y), \theta)$ sono tutti = $g(T(x), \theta)$

Ma $h(\vec{x})$ e $h(\vec{y})$ non dipendono da θ

\Rightarrow la legge del campione condizionata a T non dipende da θ e quindi è sufficente.

es

$T(\vec{x})$ sono facce

$$\vec{x} = (x_1, x_2)$$

$$x_i = 1 \dots 6$$

$$P(T(\vec{x}) = 4) = P(\vec{x} = (1, 3)) + P(\vec{x} = (2, 2)) + \dots$$

\nwarrow QST è la f.

Esempi

1) $x_1 \dots x_n \sim U[0, \theta]$

È uniforme, quindi $f(x, \theta) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x)$

la congiunta è

$$f(\vec{x}, \theta) = \prod_{i=1}^n f(x_i, \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{1}_{[0, \theta]}(x_i)$$

ma vorrei scrivere come statistica...

Un prodotto di funzioni indicatorie è una f.-indicatrice

$$\prod_{i=1}^n \mathbb{1}_{[0, \theta]}(x_i) = \begin{cases} 1 & 0 \leq x_i \leq \theta \quad \forall i \\ 0 & \text{altrimenti} \end{cases}$$

$$\mathbb{1}_{[0, +\infty)}(x_{(n)}) \cdot \mathbb{1}_{[-\infty, \theta]}(x_{(n)}) \circ \mathbb{1}_{[0, \theta]}(\max(x_i))$$

$$= \frac{1}{\theta^n} \mathbb{1}_{[0, \theta]}(\max(x_i))$$

\Rightarrow la densità congiunta è la fattorizzazione di \max e θ è funzione di θ

\downarrow
 $x_{(n)}$, il max, è statistica suff. ciante.

$$2) \boxed{X_1, \dots, X_n \sim P(\lambda)} \quad f = \frac{e^{-\lambda} \lambda^x}{x!}$$

la legge congiunta

$$f(\vec{x}, \lambda) = \frac{e^{-\lambda^n} \prod_{i=1}^n \lambda^{x_i}}{\prod x_i!} \prod_{i=1}^n \mathbb{1}_{[N]}(x_i) =$$

$$= \left(\frac{1}{\prod x_i!} e^{-\lambda^n} \lambda^{\sum x_i} \right) \prod \mathbb{1}_{[N]}(x_i)$$

$$T(\vec{x}) = \sum x_i \text{ è sufficiente.}$$

$$3) \boxed{X_1, \dots, X_n \sim N(\mu, \sigma^2)} \quad \vec{\theta} (= (\mu, \sigma^2))$$

densità congiunta

$$f(\vec{x}, \vec{\theta}) = \frac{1}{\sqrt{(2\pi\sigma^2)^n}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} = \checkmark$$

$$= \frac{1}{\sqrt{(2\pi\sigma^2)^n}} \exp \left\{ -\frac{1}{2\sigma^2} \left[\sum x_i^2 - 2\mu \sum x_i + \mu^2 \right] \right\}$$

$$T(\vec{x}) = (\sum x_i^2, \sum x_i) \text{ È SUFFICIENTE}$$

*

$$= \frac{1}{\sqrt{2\pi\sigma^2}^n} \exp \left\{ -\frac{1}{2\sigma^2} \left[\sum (x_i - \bar{x}_n)^2 + n(\bar{x}_n - \mu)^2 + 2(\bar{x}_n - \mu) \sum (x_i - \bar{x}_n) \right] \right\}$$

$$= \frac{1}{\sqrt{2\pi\sigma^2}^n} \exp \left\{ -\frac{1}{2\sigma^2} \left[(n-1)s^2 + n(\bar{x}_n - \mu)^2 \right] \right\}$$

Per il criterio di fattorizzazione

$$T(\vec{x}) = (s^2, \bar{x}_n) \text{ È SUFFICIENTE}$$

CASPIA MA ALLORA DI STATISTICHE E DI STATISTICHE SUFFICIENTI
ce ne sono tante!

È perché vale questo risultato:

$T(\vec{x})$ sufficiente e n funzione bionivoca



$T^*(\vec{x}) = n(T(\vec{x}))$ È sufficiente

$\times \times \quad T(\vec{x}) = h(\vec{x}) g(T(\vec{x}), \theta) \quad$ ma n bionivoca $\Rightarrow T(\vec{x}) = h^{-1}(T^*(\vec{x}))$

$$h^{-1}(T^*) = h(\vec{x}) g(h^{-1}(T^*(\vec{x})), \theta) = h(\vec{x}) g^*(T^*(\vec{x}), \theta)$$

Quindi se falso posso provare la sufficienza della mia o dell'altra coppia e poi trovarlo n'altro strada che sono suff entrambe

Def GENERALE di DENSITÀ PER UNA FAMIGLIA ESPONENZIALE

X HA LEGGE CHE APPARTIENE ALLA FAMIGLIA ESPONENZIALE se

$$f(x, \theta) = h(x) c(\theta) \exp \left[\sum_{j=1}^k w_j(\theta) t_j(x) \right]$$

Se presa una legge, posso scriverla così allora la variabile appartiene alla famiglia esponenziale.

SE VALE QUESTO

$$\vec{T}(\vec{x}) = \left(\sum_{i=1}^n t_1(x_i), \dots, \sum_{i=1}^n t_k(x_i) \right) \text{ È sufficiente}$$

Se congruità sarà un prodotto di $h(x)$, un prodotto di c , poi

$$f(\vec{x}, \theta) = \dots \exp \left[\sum_{i=1}^n \left(\sum_{j=1}^k w_j(\theta) \cdot t_j(x_i) \right) \right]$$

Scambio le sommatorie e ho le mie statistiche.

ESEMPI

1) $X \sim \text{Be}(p)$

$$\exp(x \ln p) + \exp((1-x) \ln(1-p))$$

$$\begin{aligned} f(x, p) &= p^x (1-p)^{1-x} \mathbb{1}_{\{0,1\}}(x) \\ &= \underbrace{\mathbb{1}_{\{0,1\}}(x)}_{h(x)} \underbrace{(1-p)}_{c(p)} \exp \left\{ x \log \frac{p}{1-p} \right\} \\ &\quad \underbrace{t_1(x)}_{w_1(p)} \end{aligned}$$

$$T(x) = \sum_{i=1}^n t_1(x_i) = \sum x_i \quad \text{la somma è una statistica sufficiente.}$$

$$\log \frac{p}{1-p} = \log(\text{ODDS})$$

ODDS = 1 quando l'esperimento è bilanciato

$$\text{ODDS} = \frac{\text{prob successo}}{\text{prob insuccesso}}$$

2) $X \sim P(\lambda)$

$$f(x, \lambda) = \frac{e^{-\lambda} \lambda^x}{x!} \quad \mathbb{1}_N(x) = \frac{\mathbb{1}_N(x)}{x!} e^{-\lambda} \exp(x \log \lambda)$$

$$T(\vec{x}) = \sum x_i \quad \text{è una statistica sufficiente}$$

3) $X \sim N(\mu, \sigma^2)$

$$f_X(x, \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (x_i - \mu)^2 \right\}$$
$$= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} [x_i^2 - 2\mu x_i + \mu^2] \right\}$$

isoliamo qll che dipende solo dal parametro

$$= \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{\mu^2}{2\sigma^2}}}_{c(\theta)} \exp \left[-\sum x_i^2 \frac{1}{2\sigma^2} + \frac{\mu}{\sigma^2} \sum x_i \right]$$
$$\sum x_i \quad \sum x_i^2 \quad \underbrace{\frac{1}{2\sigma^2}}_{w_1(\theta)} \quad \underbrace{\frac{\mu}{\sigma^2}}_{w_2(\theta)} \quad \sum x_i \quad \underbrace{\rightarrow t_1(x_i)}_{w_1(\theta)} \quad \underbrace{\rightarrow t_2(x_i)}_{w_2(\theta)}$$

$\sum x_i$ e $\sum x_i^2$ sono suff.

4) $X \sim U[0, \theta]$

$$f(x, \theta) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x)$$

non ri usano mai a scrivere come exp.

Le leggi il cui supporto dipende da θ non stanno nella famiglia esponenziale.

Le statistiche sufficienti ci raccontano bene il nostro parametro θ .

Ma magari ce ne sono di migliori

Def STATISTICA SUFFICIENTE E MINIMALE

UNA STATISTICA SUFFICIENTE $T(\vec{x})$ È DETTA STATISTICA SUFFICIENTE MINIMALE SE PER OGNI ALTRA STATISTICA SUFFICIENTE $T'(x)$

$T(x)$ È FUNZIONE DI $T'(x)$

Quindi se $T'(\vec{x}) = T'(\vec{y}) \Rightarrow T(\vec{x}) = T(\vec{y})$

-Tutto il campione è statistica suff. ma non minimale.

Ma non è una definizione applicabile!

TEOREMA di LEMANN - SCHEFFE'

(5)

SIA $f(\vec{x}, \theta)$ la legge congiunta del vettore \vec{x} .

SOPRINTIAMO CHE È UNA FUNZIONE $T(\vec{x})$

TC $\forall \vec{x}, \vec{y}$ coppia di vettori

IL RAPPORTO

$$\frac{f(\vec{x}, \theta)}{f(\vec{y}, \theta)}$$

È COSTANTE

in θ

$$f(\vec{y}, \theta)$$

$$\Leftrightarrow T(\vec{x}) = T(\vec{y})$$

$\Rightarrow T(\vec{x})$ È STATISTICA SUFFICIENTE MINIMALE PER θ .

dim

- Assumiamo di essere nel supporto della densità $f(\vec{x}, \theta) > 0 \quad \forall \vec{x}, \forall \theta$.

Sia $A_t = \{\vec{x} : T(\vec{x}) = t\}$

$\forall A_t$ scegliamo un elemento $\vec{x}_t \in A_t$.

Ovviamente \vec{x}_t e $\vec{x}_{T(\vec{x}_t)}$ sono nello stesso A_t .

sta nelle curve di livello di $T(x)$ nella stessa curva di livello

\Rightarrow per l'HP del teorema

$$\frac{f(\vec{x}, \theta)}{f(\vec{x}_{T(\vec{x}_t)}, \theta)}$$

è costante rispetto a θ .

Quindi posso dire

$$f(\vec{x}, \theta) = f(\vec{x}_{T(\vec{x}_t)}, \theta) \cdot \frac{f(\vec{x}, \theta)}{f(\vec{x}_{T(\vec{x}_t)}, \theta)}$$

Per teo di fatt

ho dimostrato

che la statistica è sufficiente.

x HP solo
funzione della \vec{x} ,
e cost in θ .

- SIA $T'(\vec{x})$ UN'ALTRA STATISTICA SUFFICIENTE. Allora $\exists h', g'$ tc $f(\vec{x}, \theta) = h'(\vec{x}) g(T'(\vec{x}), \theta)$.

Prendiamo

$$\vec{x}, \vec{y} \text{ TC } T'(\vec{x}) = T'(\vec{y})$$

$$\frac{f(\vec{x}, \theta)}{f(\vec{y}, \theta)} = \frac{g(T'(\vec{x}), \theta) h'(\vec{x})}{g(T'(\vec{y}), \theta) h'(\vec{y})} = \frac{h'(\vec{x})}{h'(\vec{y})}$$

si semplifica

$$\text{XK } T'(\vec{x}) = T'(\vec{y})$$

non dipende da θ

Allora x l'HP del teorema

$$T'(\vec{x}) = T'(\vec{y})$$

□

Allora $T(\vec{x})$ è funzione di $T'(\vec{x}) \Rightarrow T$ minima

(T' è funzione di T se $T'(\vec{x}) = T'(\vec{y})$)

$$T(\vec{x}) = T(\vec{y})$$

Sopponiamo che T sia sufficiente minima

n binivoca $\Rightarrow n(T(x))$ è suff. minima

- la suff. l'abbiamo vista

- per la minimialità:

sia W stat. suff. Allora $T(\vec{x})$ è funzione di W .

$\Rightarrow n(T(\vec{x}))$ è funzione di W

ESEMPIO

Consideriamo $X_1 \dots X_n \sim N(\mu, \sigma^2)$

Per applicare il teo dovo fare il quoziente e vedere se riesco a non farlo dipendere da θ .

$$\frac{f(\vec{x}, \vec{\theta})}{f(\vec{y}, \vec{\theta})} = \frac{\exp\left[-\frac{1}{2\sigma^2}((n-1)S_x^2 + n(\bar{X}_n - \mu)^2)\right]}{\exp\left[-\frac{1}{2\sigma^2}((n-1)S_y^2 + n(\bar{Y}_n - \mu)^2)\right]}$$

Se $S_x = S_y$ e $\bar{X}_n = \bar{Y}_n$

ma e' detto sono uguali e così la frazione non dipende da θ .
Ma e' l'unico modo possibile.

Quindi $\Leftrightarrow S_x = S_y$ e $\bar{X}_n = \bar{Y}_n$ $f(\vec{x}, \vec{\theta})$

e quindi (S^2, \bar{X}_n) non dipende da θ .

Posso dire (S^2, \bar{X}_n) è suff. minima e minima.

$(\sum x_i, \sum x_i^2)$ è suff. minima $\forall k$ è funz. binivoca.

Def ANCILLARITÀ

UNA STATISTICA $S(\vec{x})$ LA CUI LEGGE non DIPENDE DA $\vec{\theta}$
È DETTA ANCILLARE

Esempio

Si può dimostrare che prese

$$X_1 \dots X_n \sim U[\theta, \theta+1]$$

$$R = \text{Range} = X_{(n)} - X_{(1)} \sim \text{Beta}(n-1, 2)$$

- che sia una Beta è confrontante, $x_k \in U[\theta, \theta+1]$
Quindi il Range non dipende da θ , ma solo dal campione.

Quindi è una statistica di θ , ma ancillare.

Il massimo e il minimo da soli ci portano fuori di θ .

(sono tendenti a $\theta+1$ e θ)

ma la loro differenza invece non parla di θ .

Guardiamo

$$T(\vec{x}) = (X_{(1)}, X_{(n)})$$

$$f_X(x, \theta) = \mathbb{1}_{[\theta, \theta+1]}(x) \leftarrow \text{non sta nella fam. exp.}$$

$$f(\vec{x}, \vec{\theta}) = \prod_{i=1}^n \mathbb{1}_{[\theta, \theta+1]}(x_i) \leftarrow \theta \leq x_i \leq \theta+1$$

Quindi:

$$f(\vec{x}, \theta) = \mathbb{1}_{[x_{(1)}, x_{(n)}]}(\theta)$$

Quindi $\min x_i > \theta$

e $\max x_i \leq \theta+1$

Quindi $\vec{T}(\vec{x}) = (X_{(1)}, X_{(n)})$ è statistica sufficiente.

per 100 uniege

$$\frac{f(\vec{x}, \theta)}{f(\vec{y}, \theta)} = \frac{\mathbb{1}_{[x_{(n)-1}, x_{(1)}]}(\theta)}{\mathbb{1}_{[y_{(n)-1}, y_{(1)}]}(\theta)}$$

L'unico modo per bottare via θ è che max e min coincidano.

In tal caso avrei statistica sufficiente e minimale.

Verrebbe da pensare che due ancillari siano + (?!!)

7 condizioni per cui sufficienti minimali + ancillari.

IL TEOREMA DI SUFFICIENZA

SE Verificai il teo di Scheffé fosa minimalita che sufficiente

Def COMPLETEZZA

Consideriamo una famiglia di densità di probabilità $f(t, \theta)$ la famiglia di densità di $T(\vec{x})$ statistica $T(\vec{x})$ è completa se $f(t, \theta)$ è completa, cioè se

$$E_\theta[g(T)] = 0 \quad \forall \theta \Rightarrow P(g(T) = 0) = 1$$

Completezza: $\int g(t) f(t, \theta) dt = 0 \Leftrightarrow g=0$ ↑
la funzione deve essere la
fazione identicamente nulla
qualora la media della
funzione sia nulla.

ESEMPIO

1) $X_1, \dots, X_n \sim \text{Be}(p)$

$\sum X_i$ È SUFFICIENTE.

È completa?

$$T(\vec{x}) = \sum X_i \sim Bi(n, p)$$

Sia famiglia delle binomiali è completa?

Se una funzione a media nulla è 0

Sia g t.c. $E_p(g(T)) = 0 \quad \forall p \in [0, 1]$

$$\forall p \in (0, 1)$$

$$\sum_{k=0}^n g(k) \binom{n}{k} p^k (1-p)^{n-k} = 0$$

↓

$$(1-p)^n \sum_{k=0}^n g(k) \binom{n}{k} p^k (1-p)^{n-k} = 0$$

$$\text{Quindi sia } n = \frac{p}{1-p}$$

(11)

$\sum_{k=0}^n g(k) \binom{n}{k} \pi^k = 0 \quad \forall p$, quindi $\forall 0 < n < \infty$
 Sto dicendo che
 un polinomio è 0 sempre
 ciò accade \Leftrightarrow sono 0 tutti i suoi coeff

Quindi g deve essere 0 su tutti gli interi.

$$\mathbb{E}_p[g(T)] = 0 \quad \forall p$$

$$g(k) = 0 \quad \forall k = 0 \dots n$$

$$P(g(T) = 0) = 1$$

X_k il supporto di T sono solo gli interi.

$g(T)$ sono solo $g(0), g(1), \dots$


Quindi devo guardare le masse solo sugli interi.

$$2) X_1, \dots, X_n \sim U[0, \theta] \text{ iid}$$

dimostrare che $X_{(n)}$ è suff, min, compl.
 Mi manca solo completo.

Devo scrivere la densità del massimo.

$$f_{X_i}(t) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]} + \mathbb{1}_{(\theta, +\infty)} \quad \text{fdr del massimo?}$$



$$F_{X_{(n)}}(t) = P(X_{(n)} \leq t) = P\left(\bigcap_{i=1}^n X_i \leq t\right) = \prod_{i=1}^n F_{X_i}(t) = (F_X(t))^n$$

Per il massimo si usa la fdr, X_K è lei elevata alla n nel caso iid
 (Per il minimo si usa $1 - F_X(t)$)
 quindi

$$F_{X_{(n)}}(t) = \left(\frac{t}{\theta}\right)^n \mathbb{1}_{[0, \theta]} + \mathbb{1}_{(\theta, +\infty)}$$

($X_n \xrightarrow{p} \theta$ e la fdr di $X_{(n)}$ converge a q il di θ)

$$f_{X_{(n)}}(t) = \frac{n t^{n-1}}{\theta^n} \mathbb{1}_{[0, \theta]}$$

$$\mathbb{E}[g(T)] = \int g(T) \frac{n t^{n-1}}{\theta^n} dt = 0 \quad \forall \theta$$

Voglio ottenere qualcosa che dipende da θ .
 $\frac{d}{d\theta} \mathbb{E}[g(T)] = 0 \quad \hookrightarrow X_K \in [g(T)] = \text{cost.}$

$$\frac{d}{d\theta} \int g(T) \frac{n t^{n-1}}{\theta^n} dt = 0$$

$$\text{Quindi} \quad = \underbrace{\left(\frac{d}{d\theta} \theta^{-n} \right) \theta^n \mathbb{E}[g(\tau)]}_{=0} + \frac{1}{\theta^n} n \theta^{n-1} g(\theta) = 0 \quad \forall \theta$$

$$\text{Quindi} \quad \frac{d}{d\theta} g(\theta) = 0 \quad \forall \theta$$

$$\Downarrow \quad P[g(\tau) = 0] = 1 \quad \text{Quindi } X(n) \text{ è completa.}$$

L'idea è che voglio sfruttare che l'integrale sia nullo e uso la derivata.

Quindi il massimo è stato suff minima le completo.

TEOREMA di BAHADUR

UNA STATISTICA SUFFICIENTE E COMPLETA
È ANCHE SUFFICIENTE E MINIMA LE

sufficienza e
complettezza mi
regalano la
minimalità

TEOREMA di BASU

SE $T(\vec{x})$ È STATISTICA SUFFICIENTE MINIMA LE E COMPLETA
 $T(\vec{x})$ È IN DIPENDENTE DA OGNI STATISTICA ANCILLARE

dim $S(\vec{x})$ È ANCILLARE (\Rightarrow la sua legge non dipende da θ)

$P(S(\vec{x}) = s)$ non dipende da θ .

$P(S(\vec{x}) = s | T(x) = t)$ non dipende da θ \times $T(x)$ è suff.

Per dimostrarlo voglio mostrare

$$S(\vec{x}) \perp T(\vec{x}) \Leftrightarrow P(S(\vec{x}) = s) = P(S(\vec{x}) = s | T(\vec{x}) = t) \quad \forall t$$

(se la legge di S dipendesse da θ non potrei scriverlo)

Teorema delle probabilità totali

$$P(S(\vec{x}) = s) = \sum_t P(S(\vec{x}) = s | T(\vec{x}) = t) P(T(\vec{x}) = t)$$

$$P(S(\vec{x}) = s) = \underbrace{\sum_t P(S(\vec{x}) = s)}_{\text{se } P(S(\vec{x}) = s) + t} \cdot P(T(\vec{x}) = t)$$

$$\times \sum_t P(T(\vec{x}) = t) = 1.$$

$$\sum_t P(S(\vec{x}) = s | T(\vec{x}) = t) \cdot P(T(\vec{x}) = t) = \\ = \sum_t P(S(\vec{x}) = s) P(T(\vec{x}) = t)$$

$$\sum_t g(t) P(T(\vec{x}) = t) = 0$$

$$\mathbb{E}_g[g(T)] = 0$$

Ma T è completa $\Rightarrow P(S(\vec{x}) = s | T(x) = t) = P(S(x) = s)$

Quindi ho l'indipendenza di una stat minimale completa da una auxillare.

vt

Esempio

$$X_1, \dots, X_n \sim N(\mu, \sigma^2)$$

σ^2 noto

\bar{X}_n è suff minimaile completa per μ
 S^2 è auxillare per μ , X_K la sua legge è una χ^2 ,
 Quindi $\bar{X}_n + S^2$ non entra più nello spazio di S .

È PIÙ DIFFICILE DI MOSTRARE LI T D LA COMPLETEZZA?

TEOREMA

X_1, \dots, X_n iid nella famiglia esponenziale

$$(f(x, \theta) = h(x)g(\theta) \exp \left[\sum_{j=1}^k t_j(x) w_j(\theta) \right])$$

$$\Rightarrow \vec{T} = \left(\sum_{i=1}^n t_1(x_i), \dots, \sum_{i=1}^n t_k(x_i) \right)$$

È COMPLETA SE $\{w_1(\theta), \dots, w_k(\theta), \theta \in \mathbb{H}\}$
 contiene almeno un aperto di \mathbb{R}^k

$\Rightarrow T$ È SUFFICIENTE MINIMALE COMPLETA

Controllare questa richiesta è facile

ESEMPI

$$X_1, \dots, X_n \sim N(\mu, \sigma^2) \quad \sigma^2 \text{ noto}$$

$$f(x, \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2} \right] =$$

$$= \underbrace{\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{1}{2} \frac{x^2}{\sigma^2} \right]}_{\text{dipende solo da } x} \underbrace{\exp \left[-\frac{1}{2} \frac{\mu^2}{\sigma^2} \right]}_{\text{dipende solo da } \mu} \underbrace{\exp \left[\frac{\mu x}{\sigma^2} \right]}_{\text{dipende solo da } x}$$

dipende solo da x
 x è noto
 dipende solo da x

$$\begin{aligned} \nu &= 1 \\ t_1(x) &= x \\ w_1(\mu) &= \mu/\sigma^2 \end{aligned}$$

$$T(\bar{x}) = \sum_{i=1}^n x_i \text{ è sufficiente}$$

14

$W_1(\mu)$ mappa \mathbb{R} in \mathbb{R}

$$W_1(\mu) : \mathbb{R} \rightarrow \mathbb{R}$$

$$\uparrow \mu \in \mathbb{R}$$

Quindi $\text{Im}(W_1(\mu)) = \mathbb{R}$ contiene aperto di \mathbb{R}

Quindi $\sum x_i$ è completo

Quindi $\sum x_i$ è sufficiente minimale completa

Ma io avevo la media campionaria.

È ancora sufficiente minimale completa?

Sì, se X_K la legge di \bar{X}_n è ancora una Gaussiana,
fino solo n al denominatore nella $f(x, \mu)$

UNA TRASFORMAZIONE BIUNIVOCÀ DI UNA STATISTICA COMPLETA È
COMPLETA?

$$T \text{ completa } T^* = n(T)$$

$$\mathbb{E}[g(T^*)] = 0 = \mathbb{E}[g(n(T))] = 0$$

↓

$$P(g(n(T)) = 0) = 1 \Rightarrow P(g(T^*) = 0) = 1$$

$$\text{Quindi } \mathbb{E}[g(T^*)] = 0 \Rightarrow P[g(T^*) = 0] = 1$$

ESEMPIO

$$x_1 \dots x_n \sim P(\lambda)$$

trovare statistica sufficiente completa

$$f(x, \lambda) = \frac{1}{x!} \lambda^x e^{-\lambda} \exp\{x \log \lambda\}$$

So che $\sum x_i$ è sufficiente.

$$\log \lambda : \mathbb{R}^+ \rightarrow \mathbb{R}$$

Quindi contiene almeno un aperto di \mathbb{R}
 \Rightarrow È sufficiente, completa, minimale.

POTREBBE SUCCEDERE CHE PER ES. L'IMMAGINE SIA UNA CURVA, SIA VINCOLATA,

$$\text{se ho } \mathbb{R} \rightarrow \mathbb{R}^2$$

QUINDI HO CHE NON HO UN APERTO DI \mathbb{R}^2 .

es: $N(\mu, \mu^2)$ mappa in una parabola,
 che non contiene un aperto di \mathbb{R}^2

ESEMPIO

$$x_1 \dots x_n \sim \text{Be}(p)$$

$$f(x, p) = \prod_{i=1}^n (1-p)^{1-x_i} p^{x_i} \exp\left\{x_i \log \frac{p}{1-p}\right\}$$

$$\log \frac{p}{1-p} : [0, 1] \rightarrow (-\infty, +\infty)$$

\nwarrow contiene almeno
 un aperto di \mathbb{R} .

STIMARE I PARAMETRI

(15)

STIMA PONTUALE

- 1) METODI PER STIMARE I PARAMETRI (stimatori)
- 2) METODI PER CONFRONTARE GLI STIMATORI.

Def STIMATORE PONTUALE

UNO STIMATORE PONTUALE PER θ È UNA QUALENQUE FUNZIONE
 $W(x_1 \dots x_n) = W(\vec{x})$ DEL CAMPIONE

(è una qualunque statistica)

la statistica mi parla in generale ("tifoso")

lo stimatore pontuale mi parla bene
solo di qualcosa ("tifoso della squadra X")

$$W(\vec{x}) \in V.A : \Omega \rightarrow \mathbb{R}$$

STIMA

dati $(x_1 \dots x_n) = (x_1, \dots, x_n)(\omega)$

realizzazione del campione in ω

LA STIMA È

$$W(\vec{x})(\omega) = W(x_1 \dots x_n) \in \mathbb{R} \text{ è un numero}$$

Ho realizzato i dati campionando un modello.
la stima è la realizzazione dell'operatore usando quei dati

METODO DEI MOMENTI (Pearson)

$x_1 \dots x_n$ iid

$$m_1 = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\mu_1 = E[X]$$

$$m_2 = \frac{1}{n} \sum_{i=1}^n x_i^2$$

$$\mu_2 = E[X^2]$$

:

$$m_k = \frac{1}{n} \sum_{i=1}^n x_i^k$$

$$\vdots$$

$$\mu_k = E[X^k]$$

↑
MEDI 0
MOMENTI EMPIRICI

↑
MOMENTI TEORICI

(tipicamente μ_j è funzione di $\vec{\theta}$)

SI OTTENGONO GLI STIMATORI $\hat{\theta}$
RISOLVENDO LE EQUAZIONI

$$m_1 = \mu_1(\theta_1 \dots \theta_k)$$

:

$$m_k = \mu_k(\theta_1 \dots \theta_k)$$

quali teorici?

10

ESEMPIO

$$x_1 \dots x_n \sim N(\mu, \sigma^2) \quad \vec{\theta} = (\theta_1, \theta_2) = (\mu, \sigma^2)$$

$$M_1 = \frac{1}{n} \sum x_i = \bar{x}_n$$

$$M_2 = \frac{1}{n} \sum x_i^2$$

Dobbiamo risolvere le equazioni in θ_1 e θ_2 ,

$$M_1 = \mu_1 = \mu \Rightarrow \hat{\mu} = \hat{\theta}_1 = \bar{x}_n \leftarrow \begin{array}{l} \text{LO STIMATORE della MEDIA} \\ \text{È LA MEDIA CAMPIONARIA} \end{array}$$

$$M_2 = \sigma^2 + \mu^2 \Rightarrow \hat{\sigma}^2 = \hat{\theta}_2 = M_2 - \hat{\mu}^2$$

$$= \frac{1}{n} \sum x_i^2 - \bar{x}_n^2 = \frac{1}{n} \sum (x_i - \bar{x}_n)^2$$

IL NUMERO DI
UGUAGLIANZE OTTILI DEVE
EGUAGLIARE IL N° DI
PARAMETRI DA STIMARE

non è la varianza
campionaria!

Qst è lo stimatore proposto
da Pearson.

Ma l'ordine (il grado) potrebbe non coincidere
con l'ordine dello spazio dei parametri.

ESEMPIO

$$x_1 \dots x_n \sim U[-\theta, \theta] \quad \text{dobbiamo stimare } \theta.$$

$$M_1 = \frac{1}{n} \sum x_i = E[x] = 0 \leftarrow \begin{array}{l} \text{il momento primo non è più} \\ \text{funzione di } \theta \rightarrow \text{dobbiamo andare al} \\ \text{momento secondo} \end{array}$$

$$M_2 = \frac{1}{n} \sum x_i^2 = E[x^2] = \text{Var}[x] = \frac{1}{12} 4\theta^2 = \frac{\theta^2}{3}$$

lo stimatore proposto è

$$\hat{\theta} = \sqrt{\frac{3}{n} \sum x_i^2}$$


lo spazio dei
parametri è dato in \mathbb{R} ,

ma dobbiamo andare al 2^o momento per trovare lo stimatore,
e probabilmente è x qst che è brutto.

PERCHÉ PEARSON HA AVUTO QUESTA IDEA?

FUNZIONE DI RIPARTIZIONE EMPIRICA (DISCRETA)

$$F_n(x) = \frac{1}{n} \sum \mathbf{1}_{[x_i \leq x]}$$



ogni volta che
ho x_i ho
una funzione che mi
fa salire di $\frac{1}{n}$

Quindi assegna una probabilità $\frac{1}{n}$ a
ogni punto del salto
(È DISCRETA)

una distribuzione discreta così ha

$$\mathbb{E} = \frac{1}{n} \sum x_i \leftarrow \text{media che corrisponde alla fdR di } f_n(x)$$

\uparrow

$$\mathbb{E} \left[\frac{1}{n} \sum x_i \right]$$

E perché la media delle fdR empirica dovrebbe assomigliare alla media?

PERCHÉ VALE IL TEOREMA di GLIVENKO-CANTELLI

$$\sup_x |f_n(x) - F(x)| \xrightarrow{P} 0$$

[se si assomiglia le fdR si assomiglieranno tutte le altre cose]

Mi aspetto che il valore atteso dell'empirica sia vicino alla teorica μ .

E così vale per i momenti.

La fdR empirica va a schiacciarsi sulla fdR teorica.
E quindi così fanno la media e i momenti.

Se io ho v.a. discreto

X ha legge

x	p_i
x_1	$1/n$
\vdots	
x_n	$1/n$

$$\mathbb{E}[X] = \sum x_i p_i = \frac{1}{n} \sum x_i$$

FdR empirica:

x_1	\dots	x_n	$\frac{1}{n}$
	\vdots		

$$F_{(n)}(x) \text{ è aleatorio, } x_k \mathbb{P}_{\text{teorica}} [x_i \leq x]$$

Con questo metodo riusciamo a risolvere operazioni essenzialmente algebriche

VEROSIMIGLIANZA (LIKELIHOOD)

DENSITÀ CONGIUNTA di \vec{x} VISTA COME PARAMETRO

$$L(\theta, \vec{x}) = f(\vec{x}, \theta)$$

nel discreto:

$$P(\vec{x} = \vec{x}, \theta) \leftarrow f(\vec{x}, \theta)$$

$$L(\theta, \vec{x}) = P(\vec{x} = \vec{x}, \theta)$$

\uparrow sia realizzato \vec{x} , vogliamo vedere come al valore di θ cambia la probabilità.

Audro a cercare i θ che aumentano la probabilità di osservare quello che ho osservato.

SE OSSEROVANO UNA COSA IMMAGINO CHE SIA PROBABILE che FOSSE POSSIBILE.

Per X fissato guardalo come varia la probabilità di quell' X al variare di θ .

PRINCIPIO DI VERO SIMIGLIANZA

10

Se \vec{x}, \vec{y} osservazioni del campione sono t.c.

$L(\theta, \vec{x})$ è proporzionale (in funzione di θ)
alla $L(\theta, \vec{y})$


(cioè $\exists c(\vec{x}, \vec{y})$ t.c. $L(\theta, \vec{x}) = c(\vec{x}, \vec{y}) L(\theta, \vec{y}) \forall \theta$)

SI DICE CHE

\vec{x}, \vec{y} SONO IN ACCORDO CON IL PRINCIPIO DI VERO SIMIGLIANZA

PERCHÉ LE CONCLUSIONI CHE OTTIENIAMO CONOSCENDO \vec{x}

SONO LE STESE CHE OTTIENIAMO CONOSCENDO \vec{y}



se ho un fattore di scala
le info su quanto è
probabile x , al variare di θ
è uguale a quanto è probabile y

Competitor del metodo dei momenti?

METODO di MASSIMA VERO SIMIGLIANZA

Def MLE = Maximum Likelihood Estimator

$\hat{\theta}_{MLE}(\vec{x})$ È IL VALORE DEL PARAMETRO θ
IN CUI $L(\theta, \vec{x})$ RAGGIUNGE IL MASSIMO

$$\hat{\theta}_{MLE}(\vec{x}) = \underset{\theta \in \mathbb{H}}{\operatorname{Arg\,Sup}} L(\theta, \vec{x})$$

↑
non sempre riesco a trovare una soluzione
chiusa al problema
Altrettanto debbo andare a usare metodi numerici

Per definizione

$\hat{\theta}(\vec{x})$ ASSUME VALORI NEL RANGE DI AMMISSIBILITÀ,
cioè dove vive $\theta \in \mathbb{H}$

Io ho $L(\theta, \vec{x})$ e trovo un $\hat{\theta}(\vec{x})$ che realizza il massimo.
Se ho per es. $\frac{1}{n} \sum x_i$ ↑ stima.

avrei $\hat{\theta}(\vec{x}) (= \frac{1}{n} \sum x_i)$ ← stimatore

Potere essere che non riesco a trovare il massimo in
forma chiusa

Problema di
massimizzazione ↼ metodi numerici
che possono essere sensibili all'inizializzazione
= metodi instabili
oppure potrebbero non convergere

$$\frac{\partial}{\partial \theta} L(\theta, \vec{x}) = 0$$

$$\frac{\partial L}{\partial \theta_i} (\theta_i, \vec{x}) = 0 \quad \forall i=1 \dots k$$

$\theta = (\theta_1, \dots, \theta_k)$ -
candidato a essere punto di max

Ma io ho

$$L(\theta, \vec{x}) = \prod_{i=1}^n f(x_i, \theta)$$

\Rightarrow che casumo fare le derivate di un prodotto!

Posso e $\log L(\theta, \vec{x}) = l(\theta, \vec{x}) = \sum_{i=1}^n \log f(x_i, \theta)$

$$\hat{\theta}_{MLE} = \operatorname{Arg\,Sup} L(\theta, \vec{x}) = \operatorname{Arg\,Sup} l(\theta, \vec{x})$$

XK il log è funzione monotona

Ma ci sono casi in cui non posso fare il logaritmo!

ESEMPI

- 1) Supponiamo di avere un'urna da cui estraiamo con reimmissione 3 palline
p palline bianche
1-p palline nere
OTTENGO 2 palline bianche su 3.
 $P = 1/2$ o $P = 1/3$?

Come faccio a prendere questa decisione?

CALCOLIAMO LA PROBABILITÀ CHE SUCCEDA CIOÈ CHE È SUCCESSO.

$$P_{p=\frac{1}{2}} (\sum X_i = 2) \quad \sum X_i \sim Bi(3, \frac{1}{2})$$

$$= \binom{3}{2} \left(\frac{1}{2}\right)^2 \left(\frac{1}{2}\right)^1 = \frac{3}{2} \cdot \frac{1}{8} = \frac{3}{8} \quad \begin{matrix} \text{Probabilità di vedere} \\ 2 \text{ palline bianche con} \\ \text{reimmissione} \end{matrix}$$

$$P_{p=\frac{1}{3}} (\sum X_i = 2) \quad \sum X_i \sim Bi(3, \frac{1}{3})$$

$$= \binom{3}{2} \left(\frac{1}{3}\right)^2 \left(\frac{2}{3}\right)^1 = \frac{2}{9}$$

$\frac{3}{8} > \frac{2}{9} \Rightarrow$ le mie opinioni mi dicono di scommettere su $1/2$, XK quel parametro, tra quei due è più che mi rende + probabile quello ho osservato.

Ma se invece dico ok tu hai visto $\frac{2}{3}$, quanto dico che vale p?

\downarrow
 X_1, \dots, X_n iid $Be(p)$

- Con il metodo dei momenti Momenti - $\frac{1}{n} \sum X_i = \frac{2}{3}$
- con la vero somiglianza

$$L(p, x_i) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} \quad \prod_{i=0,1} (x_i) = p^y (1-p)^{n-y} \quad \prod_{i=1}^n \prod_{i=0,1} (x_i)$$

$$l(p, \vec{x}) \propto y \log p + (n-y) \log (1-p)$$

$$\frac{\partial l}{\partial p} = \frac{y}{p} - (n-y) \frac{1}{1-p}$$

per p quindi
trascurando ciò
che non dipende da p)

$$\frac{\partial \mathcal{L}}{\partial p} = \frac{-\theta - \theta p - \ln p + \ln \theta}{p(1-p)} = 0 \Leftrightarrow p = \frac{\theta}{n}$$

(10)

- se $y=0$ avrei avuto la derivata sempre decrescente
 $\hat{p}=0$
- $y=n$ avrei avuto la derivata sempre crescente
 $\hat{p}=1$

Per ogni $y < n$ ho $p = \frac{y}{n}$, $\hat{P}_{MLE} = \frac{\sum x_i}{n}$ ($y = \sum x_i$)
 Quindi di fatto \hat{p} è la media campionaria delle mie osservazioni

2) $x_1, \dots, x_n \sim U[0, \theta]$


$$\hat{\theta}_{MOM} = 2 \frac{\sum x_i}{n} \quad (\mu = \frac{\theta}{2})$$

$\hat{\theta}_{MLE} = ?$

$$L(\theta, \bar{x}) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{1}_{[0, \theta]}(x_i) = \frac{1}{\theta^n} \mathbb{1}_{[0, \theta]}(x_{(n)})$$

non a lo faccio con le derivate! \rightarrow Non posso togliere θ ne usare le logaritmitizzazioni!
 Allora trovando,

e' $\frac{1}{\theta^n}$ se $0 \leq x_{(n)} \leq \theta$




Quindi $\hat{\theta}_{MLE} = x_{(n)}$

$\hat{\theta}_{MLE} + \hat{\theta}_{MOM}$


So che il massimo è suff. minima complete
 \Rightarrow prendo $\hat{\theta}_{MLE}$

Se due campioni sono d'accordo con il principio di verosimiglianza trovo lo stesso $\hat{\theta}_{MLE}$, ed è anche x qst che devo qst al stimatore.

Se due punti sono in accordo con il PVS ho che le 2 curve sono proporzionali a una costante che non dipende da θ :



se avessi



$$l_1 = l_2 \mathbb{1}_{[y_{(n)}, +\infty]} (\theta)$$

la cost dipende da θ
 \Rightarrow non vale PVS

$$x \text{ e } y \text{ sono in accordo con i criteri di massima probabilità}$$

$$\hat{x}(n) = y(n)$$

Quindi $\hat{\theta}_{MLE}(\vec{x}) = \hat{\theta}_{MLE}(\vec{y})$

ma $\hat{\theta}_{MOM}(\vec{x}) \stackrel{?}{=} \hat{\theta}_{MOM}(\vec{y})$?

non necessariamente,

potrei avere $x = \{1, 5\}$ e $y = \{2, 5\}$
il massimo è ma la media aritmetica è ≠

3) $x_1, \dots, x_n \sim N(\mu, \sigma^2)$

$$L(\mu, \vec{x}) = \frac{1}{(\sqrt{2\pi\sigma^2})^n} \exp\left[-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right]$$

$$\ell(\mu, \vec{x}) \propto -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{2\sigma^2} \cdot 2 \sum_{i=1}^n (x_i - \mu) = 0 \Leftrightarrow \mu = \frac{\sum x_i}{n}$$

$$\text{Quindi } \hat{\mu}_{MLE} = \frac{\sum x_i}{n} = \bar{x}_n$$

(calcolare $(\mu, \sigma^2)_{MLE}$)

Pro e Contro di Mom e MLE

1) $x_1, \dots, x_n \sim \text{Bin}(k, p)$ $\Theta = \{k, p\}$

$$\mathbb{H} = \{N \times [0, 1]\}$$

METODO DEI MOMENTI

$$\begin{cases} \bar{x}_n = kp \\ \frac{1}{n} \sum x_i^2 = kp(1-p) + k^2 p^2 \end{cases}$$

$$\begin{cases} \hat{p} = \frac{\bar{x}_n}{k} \\ \frac{1}{n} \sum x_i^2 = kp \underbrace{\frac{\bar{x}_n}{kp}}_{p} - k \underbrace{\frac{\bar{x}_n^2}{kp^2}}_{p^2} + k^2 \underbrace{\frac{\bar{x}_n^2}{kp^2}}_{p^2} \end{cases}$$

$$\begin{cases} \hat{p} = \frac{\bar{x}_n}{k} \\ \bar{x}_n + \bar{x}_n^2 - \frac{1}{n} \sum x_i^2 = \frac{\bar{x}_n^2}{k} \end{cases}$$

$$\begin{cases} \hat{p} = \frac{\bar{x}_n}{k} \\ \hat{k} = \frac{\bar{x}_n^2}{\bar{x}_n - \frac{1}{n} \sum (x_i - \bar{x}_n)^2} \end{cases}$$

$\hat{\theta}$ deve dunque stare intero > 0 , $\forall k \in \mathbb{N}$.

Ma non è detto che ciò accada!

Il problema è il range di ammissibilità.
Le stime possono $\notin \mathbb{N}$.

Anche con il metodo di verosimiglianza potrei avere problemi $\forall k \in \mathbb{N}$ una discreta quindi non avrei idea

$$2) X \sim U[0, \theta]$$

$$Y \sim U[0, \theta] \quad \text{Pro Mom}$$

Non conosco il valore di X e Y ,

ma conosco $T = (X-Y)^2$, ho la distanza presa da 2 valori a caso presi da una uniforme

Calcolo la legge di $-Y \sim U[-\theta, 0]$

$$\text{di } X-Y \sim \Delta$$

$$\text{e poi di } (X-Y)^2$$

$$f_T(t) = \frac{\theta - \sqrt{t}}{\theta^2 \sqrt{t}} \mathbf{1}_{[0, \theta^2]}(t)$$

$$\mathbb{E}[T] = \frac{\theta^2}{6} \rightarrow \hat{\theta} = \sqrt{6 \frac{\sum t_i}{n}}$$

con le verosimiglianze

$$L(\theta, t) = \frac{1}{\theta^{2n}} \prod_{i=1}^n \frac{1}{\theta - \sqrt{t_i}} \prod_{c=1}^n (\theta - \sqrt{t_i}) \mathbf{1}_{[\max t_i, +\infty)}(\theta)$$

dove si guarda il massimo. $\forall c \quad 0 \leq t_i \leq \theta^2$

Guardo la logverosimiglianza

$$l(\theta, t) = -2n \log \theta + \sum_{i=1}^n \log (\theta - \sqrt{t_i})$$

$$\frac{\partial l}{\partial \theta} = -\frac{2n}{\theta} + \sum \frac{1}{(\theta - \sqrt{t_i})}$$

Ma non riesco a calcolare il punto di massimo in forme chiuse!

In Generale le stime le faremo con il metodo di Verosimiglianza.

PROPRIETÀ di INVARIANZA degli MLE

SE $\hat{\theta}$ È MLE PER θ

ALLORA OGNI FUNZIONE $T(\theta)$ L'MLE DI $T(\theta)$ È $T(\hat{\theta}_{MLE})$

\wedge T bivinocca o univocca

(dim sul quadro)

(H) voglio restringere

l'insieme dei possibili parametri (H) restruzione di (H)

$$\hat{\theta}_{MLE} = \underset{\theta \in H}{\operatorname{Arg\,Sup}} L(\theta, \bar{x})$$

$\hat{\theta}_{MLE}$ può essere univoca o f da $\hat{\theta}_{MLE}$

METODI per VALUTARE gli STIMATORI

> MSE Mean Square Error di uno stimatore T di θ

$$MSE_{\theta}(T) = E_{\theta}(T - \theta)^2$$

Agliongo e tolgo $E[T]$ funzione di perdita.

$$MSE_{\theta}(T) = E_{\theta}\left((T - E_{\theta}(T))^2\right) + E_{\theta}\left((E_{\theta}(T) - \theta)^2\right) + 2E_{\theta}\left[(T - E(T))(E(T) - \theta)\right]$$

$$= \text{Var}\theta + (E_{\theta}(T) - \theta)^2$$

Def DISTORSIONE o BIAS
 $E_{\theta}(T) - \theta$

fa 0 xK
 $E[T] - \theta$ è un
numero.
Mi resto
 $2(E(T) - \theta)E(T - E(T))$
 $= 0$

$$MSE_{\theta}(T) = \text{Var}_{\theta}(T) + \text{distorzione}^2$$

Se $E_\theta(T) = \theta$, ossia la distorsione è nulla,
 allora si dice che T è un operatore non distorto
 per θ : È UNO STIMATORE UN BIASED.

(24)

Bisogna cercare di minimizzare l'intero MSE, ma di solito
 si ha l'effetto

"BIAS-VARIANCE TRADE OFF", ossia cerco di
 minimizzare la varianza e mi aumenta la
 distorsione, minimizzo la distorsione e mi aumenta
 la variabilità.

Non sempre la soluzione giusta è andare caccia di stimatori
 non distorti

T_1 È PREFERIBILE a T_2 SE

$$MSE_\theta(T_1) \leq MSE_\theta(T_2) \quad \forall \theta$$

↑ e disegno aggiunta tra 2 funzioni di θ !

In alcuni casi non riusciremo a decidere XK può essere
 che per alcuni θ vada meglio uno, per altri è meglio l'altro

ESEMPI

① $X_1 \dots X_n \quad \theta = E[X_i] \quad \sigma^2 = \text{Var}[X_i] = 1$

$$T_1 = a \bar{X}_n$$

$$T_2 = \bar{X}_n$$


$$\bullet \quad MSE_\theta(T_1) = \text{Var}(a\bar{X}_n) + (E[a\bar{X}_n] - \theta)^2 =$$

$$= \frac{a^2}{n} + (a\theta - \theta)^2 =$$

$$\text{Var } \bar{X}_n = \frac{\text{Var}[X_i]}{n} \quad E[\bar{X}_n] = E[X_i] = \theta$$

$$= \frac{a^2}{n} + (a-1)^2 \theta^2$$

$$\bullet \quad MSE_\theta(T_2) = \text{Var}(\bar{X}_n) + 0 = \frac{1}{n}$$



Se $a^2 > 1$ ok
 vince T_2 .

Ma per $a^2 < 1$
 dipende da θ
 quale stimatore
 sia meglio.

L'andamento non è totale, nello spazio degli stimatori,
 XK x QST 2 stimatori non so scegliere.

Questo in realtà è un caso un po' particolare XK all'aumentare
 di n di fatto mi va quasi sempre meglio \bar{X}_n
 e di fatto per stimare la media si usa sempre la
 media campionaria

(2) $X_1, \dots, X_n \sim N(\mu, \sigma^2)$

$$L(\mu, \sigma^2, \bar{x}) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right)$$

$$l(\mu, \sigma^2, \bar{x}) = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2$$

tanto derivare uno rispetto σ^2

Problema di massimizzazione in 2 variabili.

\downarrow CERCO i punti in cui si annulla il gradiente

$$\begin{cases} \frac{\partial l}{\partial \mu} = 0 \rightarrow \frac{1}{\sigma^2} \sum (x_i - \mu) = 0 \\ \frac{\partial l}{\partial \sigma^2} = 0 \rightarrow -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2 = 0 \end{cases}$$

$$\Rightarrow \begin{cases} \hat{\mu} = \bar{x}_n \\ \hat{\sigma}^2 = \frac{\sum (x_i - \bar{x}_n)^2}{n} \end{cases}$$

← non ottengo la varianza campionaria!

Per avere un massimo
almeno una delle due derivate seconde deve essere < 0
e il determinante dell'Hessiano > 0 .

$$\frac{\partial^2 l}{\partial \mu^2} = -\frac{n}{\sigma^2} \quad \leftarrow \text{ok! Almeno una delle due derivate è } < 0!$$

$$\frac{\partial^2 l}{\partial \sigma^2} = \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum (x_i - \mu)^2$$

$$\frac{\partial^2 l}{\partial \mu \partial \sigma^2} = -\frac{1}{\sigma^4} \sum (x_i - \mu)$$

$$\det \begin{bmatrix} \frac{\partial^2 l}{\partial \mu^2} & \frac{\partial^2 l}{\partial \mu \partial \sigma^2} \\ \frac{\partial^2 l}{\partial \mu \partial \sigma^2} & \frac{\partial^2 l}{\partial \sigma^2} \end{bmatrix} = \begin{vmatrix} -\frac{n}{\sigma^2} & -\frac{1}{\sigma^4} \sum (x_i - \mu) \\ -\frac{1}{\sigma^4} \sum (x_i - \mu) & \frac{n}{2\sigma^4} - \frac{1}{\sigma^6} \sum (x_i - \mu)^2 \end{vmatrix}$$

$$= \frac{1}{\sigma^6} \left[-\frac{n^2}{2} + \frac{n}{\sigma^2} \sum (x_i - \mu)^2 - \frac{1}{\sigma^2} (\sum (x_i - \mu))^2 \right] =$$

$$\begin{cases} \mu = \bar{x} \\ \sigma^2 = S_0^2 = \frac{1}{n} \sum (x_i - \bar{x}_n)^2 \end{cases}$$

$$= \frac{1}{(S_0^2)^3} \left[-\frac{n}{2} + \frac{n^2}{S_0^2} \cdot S_0^2 - \frac{1}{S_0^2} (\sum (x_i - \bar{x}_n))^2 \right]$$

$$= \frac{n^2}{2(S_0^2)^3} > 0 \quad \begin{array}{l} \approx 0 \\ (\sum x_i - n\bar{x} = n\bar{x} - n\bar{x}) \end{array}$$

\Rightarrow Ho punto di max interno - non vado a vedersi @ bordo

$$(\hat{\mu}, \hat{\sigma}^2) = (\bar{x}_n, \frac{1}{n} \sum (x_i - \bar{x}_n)^2)$$

(26)

E la buona vecchia varianza campionaria?

$$S^2 = \frac{1}{n-1} \sum (x_i - \bar{x}_n)^2$$

VOGLIO CONFRONTARLI CON L'MSE.

$$\frac{(n-1)S^2}{\alpha^2} \sim \chi^2(n-1) - \text{Xk } S^2 \sim N$$

$$\bullet E[S^2] = \frac{\alpha^2}{n-1} \quad E[\chi^2(n-1)] = \frac{\alpha^2}{n-1} \cdot (n-1) \quad (\chi^2(\alpha) = r(\frac{\alpha}{2}, \frac{1}{2}), \\ \Rightarrow E \text{ non distorto!})$$

$$\text{Var}[S^2] = \frac{\alpha^4}{(n-1)^4} \text{Var}[\chi^2(n-1)] = \\ = \frac{\alpha^4}{(n-1)^4} \cdot 2(n-1) = \frac{2\alpha^4}{n-1}$$

$$\begin{aligned} \Gamma(\alpha, \beta) &= \\ E[\alpha, \beta] &= \frac{\alpha}{\beta} \\ \text{Var}[\alpha, \beta] &= \frac{\alpha}{\beta^2} \end{aligned}$$

$$\downarrow \\ \text{MSE}_{\alpha^2}[S^2] = \text{Var}[S^2] = \frac{2\alpha^4}{n-1}$$

$$\bullet \text{MSE}_{\alpha^2}[\hat{\sigma}_{MLE}^2] = \text{MSE}_{\alpha^2}\left[\frac{1}{n} \sum (x_i - \bar{x}_n)^2\right] = \\ = \text{MSE}_{\alpha^2}\left[\frac{n-1}{n} S^2\right] = \\ = \text{Var}_{\alpha^2}\left[\frac{n-1}{n} S^2\right] + \left[E_{\alpha^2}\left[\frac{n-1}{n} S^2\right] - \alpha^2\right]^2 = \\ = \frac{(n-1)^2}{n^2} \frac{\frac{2\alpha^4}{n-1}}{n-1} + \left[-\frac{\alpha^2}{n}\right]^2 \\ = \frac{2\alpha^4(n-1)}{n^2} + \frac{\alpha^4}{n^2} = \frac{(2n-1)}{n^2} \alpha^4$$

» Ora confronto i due MSE.

$$\frac{(2n-1)}{n^2} \alpha^4 ? \frac{2\alpha^4}{n-1} = \text{MSE}_{\alpha^2}[S^2]$$

$$(2n-1)(n-1) ? 2n^2$$

$$2n^2 - 3n + 1 < 2n^2 \quad (\text{tanto } n > 1)$$

$$\frac{2n-1}{n^2} \alpha^4 < \frac{2\alpha^4}{n-1} \quad \forall \alpha^2$$



$$\text{MSE}[\hat{\theta}_{MLE}^2] < \text{MSE}[S^2]$$

\uparrow È quello distorto.

Quindi qui è meglio uno stimatore distorto.
Perché? E perché di solito prendiamo S^2 ?
Dato che la funzione quadratica tratta allo stesso modo
sovrastima e sottostima.

$\hat{\sigma}^2_{MLE}$ sottostima la varianza.

Dato che la varianza è un parametro di precisione non
posso permettermi di sottostimarlo.

Quindi non va bene che sottostima e sovrasta le
stesse cose, non va bene sottostimare le somme

LA FAMIGLIA DEGLI STIMATORI È TROPPO GRANDE x Riuscire
A DEFINIRE L'OPTIMALITÀ LI DENTRO;
NON È PROPRIO CHE BOTTOVIA GLI STIMATORI DISTORTI ...

③ $X_1 \sim P(\lambda)$ con una variabile casuale stimata $e^{-2\lambda}$

$$W(x_1) = (-1)^{x_1}$$

$$E[W] = \sum_{k=0}^{+\infty} (-1)^k \frac{e^{-\lambda} \lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!} = e^{-2\lambda}$$

W stimatore non distorto di $e^{-2\lambda}$

Qualunque sia λ , io devo stimare $e^{-2\lambda}$, che è > 0 .
con la stessa probabilità con cui una Poisson

assume un valore disponi lo ~~sotto~~stimato $e^{-2\lambda}$ con $q(1s) < 0$.

(Preferisco centrare con la stessa probabilità l'albero a destra
quello a sx e in media entrare nel box o sfiorare con
la fiancata i 2 alberi?)

UMVUE = Uniform Minimum Variance
Unbiased Estimator

Def | T^* È UMVUE PER Θ SE
 $E_\Theta[T^*] = \Theta$ e $\forall T$ STIMATORE
 NON DISTORTO DI $E(T) = \Theta$
 $\text{Var}[T^*] \leq \text{Var}[T] \quad \forall \Theta$

Cerco lo stimatore non distorto che
batte in termini di varianza gli altri
stimatori non distorti.

(28)

Non sempre è facile confrontare le varianze!

Esempio:

$$\lambda = E[X_i] = \text{Var}[X_i]$$

\bar{X}_n è distorto per λ

S^2 è uno stimatore distorto per λ .

Arriveremo a dire che è meglio \bar{X}_n , che è un uno stimatore a varianza minima.

$$X_i \quad E[X_i] = \mu \quad \text{Var}[X_i] = \sigma^2$$

$$E\left[\frac{1}{n} \sum X_i\right] = \frac{1}{n} \sum E[X_i] = \frac{n\mu}{n} = \mu$$

$$E[S^2] = \sigma^2$$

$$E\left[\frac{1}{n-1} \sum (X_i - \bar{X}_n)^2\right] = \frac{1}{n-1} E\left[\sum X_i^2 + n\bar{X}_n^2 - 2n\bar{X}_n^2\right]$$

$$= \frac{1}{n-1} \left[nE[X_i^2] - nE[\bar{X}_n^2] \right] =$$

$$= \frac{1}{n-1} \left[n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \right] =$$

$$= \frac{1}{n-1} \left[(n-1)\sigma^2 + n\mu^2 - n\mu^2 \right] =$$

$$= \sigma^2$$

Quindi per una v.a. qualsiasi
 S^2 è stimatore non distorto.

Audiamo alle

nuova di criteri x stimare l'OM VUE!

DISUGUAGLIANZA di CRAMER-RAO

$$x_1 \dots x_n \sim f(\vec{x}, \theta)$$

$T = T(\vec{x})$ stimatore di θ

ASSUMIAMO che

1) IL SUPPORTO DI $f(\vec{x}, \theta)$ NON DIPENDA DA θ (es: famiglia exp)

$$2) 0 = \frac{d}{d\theta} \int_{\mathbb{R}^n} f(\vec{x}, \theta) dx = \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} f(\vec{x}, \theta) d\vec{x}$$

$$3) \frac{d}{d\theta} E_\theta[T] = \frac{d}{d\theta} \int_{\mathbb{R}^n} T(\vec{x}) f(\vec{x}, \theta) dx = \int_{\mathbb{R}^n} T(\vec{x}) \frac{\partial}{\partial \theta} f(\vec{x}, \theta) dx$$

4) $E[T^2] < +\infty \quad \forall \theta$ (stimatore di varianza finita.)

SE

$$0 < E_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) \right)^2 \right] < +\infty$$

$$\Rightarrow \text{Var}_\theta[T] \geq \frac{[d/d\theta E_\theta[T]]^2}{E_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) \right)^2 \right]}$$

informazione
di Fisher
 $I_n(\theta)$

LIMITE INFERIORE di
CRAMER-RAO

Se lo stimatore è non distorto

$$E_\theta[T] = \theta \Rightarrow \frac{d}{d\theta} E_\theta[T] = 1$$

Perché può essere utile x la stima dell'UMVUE?
Perché mi dà un limite x la varianza.

Con queste RISONDIAMO A SE x P(λ) è meglio prendere le medie
o la varianza campionaria?

Il limite di Cramer-Rao dipende dalle log-vereosimiglianze.

$$X_1, \dots, X_n \sim P(\lambda)$$

$$\begin{aligned} \frac{\partial}{\partial \lambda} \log f(\vec{x}, \lambda) &= \frac{\partial}{\partial \lambda} \log \left[\prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \right] = \frac{\partial}{\partial \lambda} \sum \log \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \\ &= \sum \frac{\partial}{\partial \lambda} (-\lambda + x_i \log \lambda) = \sum (-1 + \frac{x_i}{\lambda}) \end{aligned}$$

$$\begin{aligned} I_n(\lambda) &= E_\lambda \left[\left(\frac{\partial}{\partial \lambda} \log f(\vec{x}, \lambda) \right)^2 \right] = E_\lambda \left[\left(-n + \sum x_i \right)^2 \right] = \\ &= \frac{1}{\lambda^2} E_\lambda \left[\left(-n\lambda + \sum x_i \right)^2 \right] \end{aligned}$$

Somma di Poisson $\Rightarrow n P(n\lambda)$

Windl dato che in questo caso $\mathbb{E}[\sum x_i] = n\lambda$

(30)

$$= \frac{1}{n^2} \text{Var}_\lambda(\sum x_i) = \frac{1}{n^2} n \lambda = \frac{\lambda}{n}$$

(in genere cerco di ricondursi a una varianza)

Io avevo \bar{x}_n, S^2 non distorzi

$$\text{Var}[\bar{x}_n] = \frac{\lambda}{n} = \frac{1}{n \lambda}$$

\Rightarrow È L'UMVUE!

Quindi in questo caso la media campionaria raggiunge il limite di CRAMER - RAO

dim

- DISUGUAGLIANZA di CAUCHY-SCHWARTZ.

$$x, y \quad |\text{Cov}(x, y)|^2 \leq \text{Var}(x) \cdot \text{Var}(y)$$

- il prodotto scalare tra 2 vettori è controllato dalla norma -

dim

$a \in \mathbb{R}$

$$0 \leq \text{Var}[ax + y] = a^2 \text{Var}[x] + 2a \text{Cov}(x, y) + \text{Var}[y]$$

una parabola è sempre ≥ 0

$\Delta \stackrel{\uparrow}{\leq} 0$ discriminante

$$\text{Cov}^2(x, y) - \text{Var}(x) \text{Var}(y) \leq 0$$

$$\text{Cov}^2(x, y) \leq \text{Var}(x) \text{Var}(y)$$



- VOGLIAMO DIMOSTRARE CHE CRAMER - RAO È UNA PARTECULARE DISG DI C-S.

$$X = T(\vec{x})$$

$$Y = \frac{\partial}{\partial \theta} \log f(\vec{x}, \theta)$$

OSSERVAZIONE

Hp

$$\frac{\partial}{\partial \theta} \mathbb{E}_\theta[T(\vec{x})] = \frac{\partial}{\partial \theta} \int_{\mathbb{R}^n} T(\vec{x}) f(\vec{x}, \theta) d\vec{x} \stackrel{\downarrow}{=} \int_{\mathbb{R}^n} T(\vec{x}) \frac{\partial}{\partial \theta} f(\vec{x}, \theta) d\vec{x}$$

$$= \int_{\mathbb{R}^n} T(\vec{x}) \frac{\frac{\partial}{\partial \theta} f(\vec{x}, \theta)}{f(\vec{x}, \theta)} f(\vec{x}, \theta) d\vec{x} =$$

$$= \int_{\mathbb{R}^n} T(\vec{x}) \frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) f(\vec{x}, \theta) d\vec{x} = \mathbb{E}\left[T(\vec{x}) \frac{\partial}{\partial \theta} \log f(\vec{x}, \theta)\right]$$

OSSERVAZIONE.1

La Applichiamo sostituendo $T(x) = 1$.

$$0 = \frac{d}{d\theta} \int_{\mathbb{R}^n} f(\vec{x}, \theta) dx = \underset{\text{HP}}{\uparrow} \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} f(\vec{x}, \theta) d\vec{x} = \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) \cdot f(\vec{x}, \theta) dx$$

$$= \mathbb{E}_{\theta} \left[\frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) \right]$$

che è la mia y

$\Rightarrow Y$ HA VALORE MEDIO nullo.

Allora abbiamo scoperto $\mathbb{E}[Y] = 0$

$$\downarrow$$

$$\text{Cov}(T(x), y) \stackrel{*}{=} E[T(\vec{x})y] = \underset{\text{o.s.}}{\uparrow} \frac{d}{d\theta} \mathbb{E}_{\theta}[T(\vec{x})]$$

forse vedevo
nuove
y?

$$\text{Var}[Y] = \mathbb{E}[Y^2]$$

(, ols c-s.)

$$\text{Var}[T(x)] \geq |\text{Cov}(T(\vec{x}), y)|^2 \frac{1}{\text{Var}[y]}$$

SOSTITUISCO

$$\text{Var}[T(x)] \geq \frac{\left[\frac{d}{d\theta} \mathbb{E}_{\theta}[T(\vec{x})] \right]^2}{\mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) \right)^2 \right]}$$

$$\textcircled{*} \quad \text{Cov}(x, y) = E[xy] - E[x]E[y]$$

Quando la di sogaglianza di (-) diventa uguaglianza?

QUANDO $T(\vec{x})$ È LINEARMENTE DIPENDENTE

DA $\frac{\partial}{\partial \theta} \log f(\vec{x}, \theta)$

Se troviamo stimatore non distorto che
raggiunge il limite di CR
È L'UMVUE

A CACCIA dell'UMVUE

TEOREMA di RAO-BLOCKWELL

T STIMATORE NON DISTORTO DI θ E W
 W STATISTICA SUFFICIENTE PER θ

$\Rightarrow M = E[T|W]$ È STIMATORE NON DISTORTO per θ
 $\text{e } \text{Var}(M) \leq \text{Var}_{\theta}(T)$

dimm

1) che M È STIMATORE

$$E[T|W=w] = \int t(x_1 \dots x_n) f_{\theta}(x_1 \dots x_n | W=w) dx_1 \dots dx_n$$

Quindi ho
 funzione di w
 che non dipende
 da θ
 \Rightarrow È STIMATORE

dato che la statistica è
 sufficiente non dipende
 da θ .

2) $E[M] = E[E[T|W]] = E[T] = \theta$

regola
 della doppia
 media

XK T È STIMATORE
 NON DISTORTO DI θ .

Quello che non dipende da θ è la legge di $T|W$

$$\begin{aligned} 3) \text{Var}[T] &= \text{Var}[E[T|W]] + E[\text{Var}[T|W]] \\ &\stackrel{\substack{\text{decomp.} \\ \text{varianze}}}{=} \text{Var}[M] + E[\text{Var}[T|W]] \\ &\quad \Downarrow \quad \underbrace{\geq 0} \\ &\text{Var}[M] \leq \text{Var}[T] \end{aligned}$$



ESEMPIO

$$x_1, x_2 \sim N(\mu, 1)$$

$\bar{X}_n = \frac{1}{2} (x_1 + x_2)$ non distorto $E[\bar{X}] = \mu$ $Var[\bar{X}] = \frac{1}{2}$

Usa il teorema senza porci il problema delle sufficienze

$$M = E[\bar{X} | x_1]$$

$\Leftarrow x_1$ non è sufficiente per μ ,
perché condizionato mi resta x_2 , che dipende
da μ .

$$E[M] = \mu$$

$$Var[M] \leq Var[\bar{X}]$$

$$\begin{aligned} M &= E[\bar{X} | x_1] = \frac{1}{2} [E[x_1 | x_1] + E[x_2 | x_1]] = \\ &\quad \text{lineari} \\ &= \frac{1}{2} [x_1 + \mu] \end{aligned}$$

\Rightarrow non è una statistica né una
stima perché dipende da μ .

TEOREMA UNICITÀ

SIA $T(\vec{x})$ UNO STIMATORE UMVUE PER θ .

\Downarrow
 $T(\vec{x})$ È L'UNICO UMVUE

dim Supponiamo che $\exists T'$ un altro UMVUE per θ .

$T^* = \frac{1}{2} (T + T')$ è ancora uno stimatore ed è ancora non distorto per θ .

$$\begin{aligned} Var[T^*] &= \frac{1}{4} [Var[T] + Var[T'] + 2 Cov(T, T')] \\ &\leq \frac{1}{4} Var[T] + \frac{1}{4} Var[T'] + \frac{1}{2} \sqrt{Var[T] Var[T']} \end{aligned}$$

vale anche senza modulo (vedi quadro)

Dato che T e T' sono UMVUE $\Rightarrow Var[T] = Var[T']$

Quindi $Var[T^*] \leq Var[T]$

Ma dato che T è UMVUE e nella diseg. di C-S deve valere =

$T' = aT + b$ XK la disegualanza vale quando sono lin. dipendenti

Per non avere assordo mi serve qst, con $a, b \in \mathbb{R}$.

Pero ho T e T' con stessa media e varianza.

$$E[T'] = \theta = E[T].$$

$$\theta = a\theta + b \quad \Rightarrow \text{applico E a } T' = aT + b.$$

$$b = \theta(1-a) \quad \leftarrow 1^{\text{a}} \text{ VINCOLO}$$

$$\underbrace{\text{Cov}(T, T')}_{\text{Var}(T)} = \text{Cov}(T, aT + b) = a \text{Var}T$$

34

$$\Downarrow \quad \text{Var}(T) = a \text{Var}T \Rightarrow a = 1 \quad \leftarrow 2^{\text{^}} \text{ vincolo}$$

$$\Downarrow \quad b = 0$$

$$\text{Quindi } T' = T$$



TEOREMA di LEHMANN - SCHEFFÉ UMVUE

W STATISTICA SUFFICIENTE e COMPLETA.

U STIMATORE NON DISTORTO per θ
ALLORA

$M = \mathbb{E}[U|W]$ È L'UNICO UMVUE per θ

dico M È STIMATORE.

$$\mathbb{E}[M] = \mathbb{E}[U] = \theta$$

Supponiamo che M non sia l'UMVUE e quindi $\exists T'$ non distorto con $\text{Var}(T') < \text{Var}(M)$.

Potrei prendere $M' = \mathbb{E}[T'|W]$ stimatore non distorto e per Rao-Block...

$$\text{Var}(M') < \text{Var}(T') < \text{Var}(M)$$

Se così fosse

M e M' sono funzioni di W

Quindi

$M - M'$ è funzione di W

$$\Downarrow \quad M - M' = g(W)$$

$\mathbb{E}[M - M'] = 0$ xk sono tutti stimatori non distorti

\Downarrow
 W è completa $P(g(W) = 0) = 1$

$$\Downarrow \quad M - M' = 0 \quad \text{ac}$$

$$M = M' \quad \text{ac}$$

Ma se è così, $\text{Var}(M) < \text{Var}(M)$ ASSURDO!

Allora ho l'autogolotto che potesse essere uno stimatore con varianza più piccola

VARIANTE

T STIMATORE NON DISTORTO PER $T(\theta)$.

W STATISTICA SUFFICIENTE MINIMALE COMPLETA per θ

$$\downarrow \\ M = \mathbb{E}[T|W] \text{ È L'UNICO UMVUE PER } T(\theta)$$

ESEMPIO

$X_1 \dots X_n$ iidn $B_i(k, \theta)$ k NOTO.

$$\begin{aligned} \text{Voglio trovare l'UMVUE per } T(\theta) &= P_{\theta}(X_i=1) \\ &= k\theta(1-\theta)^{k-1} \end{aligned}$$

probabilità
di avere
esattam.
1 successo

Cosa so della binomiale?

$$f(x, \theta) = \binom{k}{x} \theta^x (1-\theta)^{k-x} \mathbb{1}_{\{0 \dots k\}}(x)$$

sta nella famiglia exp?

$$= \underbrace{\binom{k}{x} \mathbb{1}_{\{0 \dots k\}}(x)}_{\text{dipende solo da } x} \underbrace{(1-\theta)^k}_{\text{dipende solo da } \theta} \exp \left\{ x \ln \frac{\theta}{1-\theta} \right\}$$

Quindi si sono nella famiglie exp.

$$W_1(\theta) = \log \frac{\theta}{1-\theta}$$

$$t_n(x) = X$$

Quindi osserviamo che $W_1 : [0, 1] \rightarrow \mathbb{R}$

$$\Rightarrow T(X) = \sum_{i=1}^n X_i \text{ È sufficiente, completa, minimale.}$$

Ha media $k\theta$, quindi non è uno stimatore non distorto.

Quando dovo

stimare una probabilità
trovare un operatore non distorto si cercano

$$Y_i = \begin{cases} 1 & X_i = 1 \\ 0 & \text{altrimenti} \end{cases}$$

OSSIA $Y_i = \mathbb{1}_{\{X_i=1\}}$ le y_i sono funzioni delle

x_i \Rightarrow le y_i sono tra loro indipendenti hanno lo stesso dbge:

y_i i id.

$$Y_i \sim \text{Be}(T(\theta)) = \text{Be}(k\theta(1-\theta)^{k-1})$$

valgono 1
qund $X_i=1$

Se prendo

(36)

$$\bar{Y}_n = \frac{1}{n} \sum Y_i$$

$$\mathbb{E}[\bar{Y}_n] = \tau(\theta)$$

Quindi ho costruito uno stimatore
BASATO SUL TUTTO IL CAMPIONE X
che è NON DISTORTO per $\tau(\theta)$.

Quindi per il

teorema trovo l'UMVUE condizionando:

$$M = \mathbb{E}[\bar{Y}_n | \sum X_i] \text{ È UMVUE per } \tau(\theta)$$

$$\mathbb{E}[\bar{Y}_n | \sum X_i] = \frac{1}{n} \sum \mathbb{E}[Y_i | \sum X_i]$$

\uparrow
linearità della media

$$\hookrightarrow \mathbb{E}[Y_1 | \sum X_i = t] = 1 \cdot P(Y=1 | \sum X_i = t) + 0 \cdot P(Y=0 | \sum X_i = t) =$$
$$(t=0, \dots, nK)$$

$$\begin{aligned} & \stackrel{Y_1 \text{ value}}{\text{solo se } X_1=1} = \frac{P(X_1=1 \cap \sum X_i = t)}{P(\sum X_i = t)} = \\ & = \frac{P(X_1=1 \cap \sum_{i=2}^n X_i = t-1)}{P(\sum X_i = t)} \\ & = \frac{(K\theta(1-\theta)^{K-1}) \binom{(n-1)K}{t-1} \theta^{t-1} (1-\theta)^{(n-1)K-t-1}}{\binom{nK}{t} \theta^t (1-\theta)^{nK-t}} \end{aligned}$$

θ è sconosciuto!

Se non fosse

sconosciuto ci saremmo

obbligati all'assunzione X_K la

statistica è sufficiente e non dipende da θ .

$$\rightarrow = \frac{\binom{(n-1)K}{t-1}}{\binom{nK}{t}}$$

Quindi:

$$M = \mathbb{E}[\bar{Y}_n | \sum X_i] = K \cdot \frac{\binom{(n-1)K}{\sum X_i - 1}}{\binom{nK}{\sum X_i}}$$

\uparrow
v.a. funzione
delle statistiche
suff. min. complete

è IL MIO
UMVUE.

1. Quando in faccia il modello, la legge congiunta, e cerco statistiche sufficienze minimale e completa.
2. Ho uno stimatore per $T(\theta)$
Lo posso trovare con il metodo dei momenti o con la verosimiglianza.
Se $T(\theta)$ è una probabilità faccio cm qui
3. Condizione
Se trovo già qualcosa che è funzione di $T(\theta)$, sono appunto, altrimenti magheggiò

INFORMAZIONE di FISHER

$$\begin{aligned} I_n(\theta) &= \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(\vec{x}, \theta) \right)^2 \right] \\ &= n \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right)^2 \right] = n I_1(\theta) \end{aligned}$$

Se x_1, \dots, x_n iid
dim

$$\begin{aligned} I_n(\theta) &= \mathbb{E}_\theta \left[\left(\frac{\partial}{\partial \theta} \log \prod_{i=1}^n f(x_i, \theta) \right)^2 \right] = \\ &= \mathbb{E}_\theta \left[\left(\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(x_i, \theta) \right)^2 \right] = \end{aligned}$$

RICORDO CHE:

$$\begin{aligned} \mathbb{E} \left[\frac{\partial}{\partial \theta} \log f(x_i, \theta) \right] &= \int \frac{\partial}{\partial \theta} \log f(x_i, \theta) f(x_i, \theta) dx = \int \frac{\partial}{\partial \theta} f(x_i, \theta) dx \\ &= \frac{\partial}{\partial \theta} \int f(x_i, \theta) dx = 0 \end{aligned}$$

Quindi anche la somma dei logaritmi ha media nulla.
Ma allora quello che resta ha lì è la varianza.

la varianza delle $\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(x_i, \theta)$ = $\text{Var} \left(\sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(x_i, \theta) \right) =$

$\sum \text{Var} \text{ sei i } \rightarrow = n \text{ Var} \left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right) =$

media è 0 $\rightarrow = n \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right)^2 \right] = n I_1(\theta)$

Lemma Quando lavorano con le ipotesi valgono le np
di (Cover-Rao) (38)

SE IN AGGIUNTA ALLE IPOTESI PRECEDENTI SI HA CHE

$$\frac{d}{d\theta} \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} f(\vec{x}, \theta) d\vec{x} = \int_{\mathbb{R}^n} \frac{\partial^2}{\partial \theta^2} f(\vec{x}, \theta) d\vec{x}$$

$$I_n(\theta) = - \mathbb{E}_{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f(\vec{x}, \theta) \right]$$

dim

$$\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(\vec{x}, \theta) \right] = \int \frac{\partial^2}{\partial \theta^2} \log f(\vec{x}, \theta) f(\vec{x}, \theta) d\vec{x} =$$

$$= \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} \left(\frac{\partial}{\partial \theta} \log f(x, \theta) f(x, \theta) \right) d\vec{x} =$$

$$= \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} \left(\frac{\partial f}{\partial \theta} \frac{1}{f} \right) f(x, \theta) d\vec{x} =$$

$$= \int_{\mathbb{R}^n} \frac{\partial^2 f}{\partial \theta^2} \frac{1}{f(x, \theta)} f(x, \theta) d\vec{x} - \int_{\mathbb{R}^n} \frac{1}{f^2(x, \theta)} \left(\frac{\partial f(x, \theta)}{\partial \theta} \right)^2 f(x, \theta) d\vec{x}$$

Ho

$$= \frac{d}{d\theta} \int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} f(x, \theta) d\vec{x} - \int_{\mathbb{R}^n} \frac{1}{f^2(x, \theta)} \left(\frac{\partial f(x, \theta)}{\partial \theta} \right)^2 f(x, \theta) d\vec{x}$$

$$= \frac{d}{d\theta} \underbrace{\left(\mathbb{E} \left[\frac{\partial}{\partial \theta} \log f(x, \theta) \right] \right)}_{= 0} - \int_{\mathbb{R}^n} \frac{1}{f^2(x, \theta)} \left(\frac{\partial f(x, \theta)}{\partial \theta} \right)^2 f(x, \theta) d\vec{x}$$

↓

$$\mathbb{E} \left[\frac{\partial^2}{\partial \theta^2} \log f(x, \theta) \right] = - \int_{\mathbb{R}^n} \left(\frac{\partial f(x, \theta)}{\partial \theta} \frac{1}{f(x, \theta)} \right)^2 f(x, \theta) d\vec{x}$$

$$= - \int_{\mathbb{R}^n} \left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right)^2 f(x, \theta) d\vec{x}$$

$$= - I_n(\theta)$$

■

E COSA MI DICE?

Quando moltiplico per il campione di ampiezza 1, (tanto poi basta che moltiplico x_n)

$$I_1(\theta) = -\frac{1}{\theta} \left[\frac{\partial^2}{\partial \theta^2} \log f(x, \theta) \right]$$

La derivata 2^a mi parla della concavità.

Se ho verosimiglianze unidimensionali molto concave forniscono informazione di Fisher alta.

↓
limite di Crammer Rao basso ▷

Se invece ho verosimiglianza piatta in pratica non ho informazione di Fisher e il limite di CR è alto

LA VARIABILITÀ del MIO STIMATORE È DATA dalla CONCAVITÀ della LOG VERO SIMIGLIANZA

TEOREMA

x_1, \dots, x_n da $f(x, \theta)$ è famiglia esponenziale

$$f(x, \theta) = h(x) c(\theta) \exp [w(\theta) t(x)]$$

TALE CHE \exists

$$\frac{d}{d\theta} w(\theta) \neq 0 \text{ e continua}$$

$$\text{Sia } T(\vec{x}) = \frac{1}{n} \sum_{i=1}^n t(x_i) \quad \leftarrow \text{QUINDI SUFF MIN COMPLETO}$$

Le condizioni per la dis di CR valgono

$$\text{Var}(T(\vec{x})) = \frac{\left(\frac{d}{d\theta} E_\theta[T(\vec{x})] \right)^2}{I_n(\theta)}$$

↑ ossia raggiunge il limite di Crammer Rao

$\Rightarrow T(\vec{x})$ È L'UMVUE per $E[t(x)]$

(è l'umvue x la sua media,
quindi x la media di $t(x)$)

* OSSERVAZIONE

$$\begin{aligned}
 0 &= \frac{\partial}{\partial \theta} \int f(x, \theta) dx = \frac{\partial}{\partial \theta} \int h(x) c(\theta) \exp \{ w(\theta) t(x) \} dx = \\
 &= \int h(x) c'(\theta) \exp \{ w(\theta) t(x) \} + \int h(x) c(\theta) \exp \{ w(\theta) t(x) \} w'(\theta) t(x) \\
 &\quad \text{moltiplico e divido per } c(\theta) \\
 &= \frac{c'(\theta)}{c(\theta)} \underbrace{\int h(x) c(\theta) \exp \{ w(\theta) t(x) \} dx}_1 + w'(\theta) \int t(x) f(x, \theta) dx \\
 &= \frac{\partial}{\partial \theta} \log c(\theta) + w'(\theta) \mathbb{E}_{\theta}(t(x)) = 0 \\
 &\quad \downarrow \\
 &\boxed{\mathbb{E}_{\theta}(t(x)) = -\frac{1}{w'(\theta)} \frac{\partial}{\partial \theta} \log c(\theta)}
 \end{aligned}$$

dim

$$\begin{aligned}
 I_n(\theta) &= n I(\theta) \\
 I(\theta) &= \mathbb{E}_{\theta} \left[\left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right)^2 \right] - \\
 &= \mathbb{E}_{\theta} \left[\left(\frac{\partial}{\partial \theta} (\log h(x) + \log c(\theta) + w(\theta) t(x)) \right)^2 \right] - \\
 &= \mathbb{E}_{\theta} \left[\left(\underbrace{\frac{\partial}{\partial \theta} \log c(\theta)}_{\text{pseudo l'oss}} + w'(\theta) t(x) \right)^2 \right]
 \end{aligned}$$

$$\begin{aligned}
 I(\theta) &= \mathbb{E}_{\theta} \left[(-w'(\theta) \mathbb{E}_{\theta}(t(x)) + w'(\theta) t(x))^2 \right] \\
 &= (w'(\theta))^2 \mathbb{E}_{\theta} [(t(x) - \mathbb{E}_{\theta}(t(x)))^2] \\
 &= (w'(\theta))^2 \text{Var} T(x)
 \end{aligned}$$

Quindi a destra del limite di CR ho
 $n(w'(\theta))^2 \text{Var} T(x)$

Ona studio il numeratore:

$$\frac{d}{d\theta} \mathbb{E}[t(x)] = \frac{d}{d\theta} \int t(x) h(x) c(\theta) \exp\{w(\theta) + t(x)\} dx = \\ = \int t(x) h(x) \frac{c'(\theta)}{c(\theta)} c(\theta) \exp\{w(\theta) + t(x)\} dx$$

tutto
 $T = \frac{1}{n} \sum t$
Quindi la
media è lo
stesso

$$\int t^2(x) h(x) c(\theta) \exp\{w(\theta) + t(x)\} w'(\theta) dx$$

$$\frac{d}{d\theta} \mathbb{E}_\theta[t(x)]$$

$$= w'(\theta) [\mathbb{E}[t^2(x)] - \mathbb{E}[t(x)]^2] \\ = w'(\theta) \text{Var}[t(x)]$$

Quindi ho ottenuto

$$\frac{d}{d\theta} \log c(\theta) \mathbb{E}[t(x)] \\ \times \text{oss. e} \\ w'(\theta) \mathbb{E}[t(x)]$$

- $\frac{d}{d\theta} \mathbb{E}_\theta[t(x)] = w'(\theta) \text{Var}(t(x))$

- $I_n(\theta) = n \text{Var}(t(x)) w'(\theta)^2$

$$\Rightarrow \text{limite CR} = \frac{w'(\theta)^2 \text{Var}^2(t(x))}{n \text{Var}(t(x)) w'(\theta)^2} = \frac{\text{Var}(t(x))}{n}$$

Il mio stimatore

$$T(x) = \frac{1}{n} \sum t(x_i)$$

$$\text{Var}(T(x)) = \frac{\text{Var}(t(x))}{n} = \text{limite CR}$$

Quindi il

nostro stimatore è l'omologo della media.

ESEMPIO

$x_1, \dots, x_n \sim P(\lambda)$

$$f(x, \lambda) = \underbrace{\frac{1}{N} (x)}_{h(x)} \underbrace{\frac{1}{x!}}_{c(\lambda)} \underbrace{e^{-\lambda}}_{w(\lambda)} \underbrace{\exp(\log(\lambda))}_{t(x)}$$

il teo mi dice che

$$\frac{1}{n} \sum x_i \text{ è l'UMVUE per } E[x] = \lambda$$

$$\text{Verifichiamo } E[t_i] = -\frac{1}{N(\theta)} \frac{d}{d\theta} \log f(\theta) : -\frac{d}{d\theta} (\log e^{-\lambda}) = \lambda$$

OSSERVAZIONE

Supponiamo di avere uno stimatore $T(x)$ che raggiunge il limite di CR.

- Se $|\text{Cov}(x, y)|^2 \leq \text{Var}(x) \text{Var}(y)$
vale $\ell' \Leftrightarrow y = ax + b$.

La diseguaglianza di CR è sostanzialmente la diseguaglianza di CS applicata a

$$T(x) \in \frac{\partial}{\partial \theta} \log f(\bar{x}, \theta)$$

$T(\bar{x})$ raggiunge il limite di CR

$$\Updownarrow$$

$$T(\bar{x}) = \frac{\partial}{\partial \theta} \log f(\bar{x}, \theta) = a(\theta)T(x) + b(\theta)$$

$$\Updownarrow$$

$f(\bar{x}, \theta)$ appartiene alla famiglia esponenziale

TEOREMA

W è l'UMVUE per $T(\theta)$

$$\Updownarrow$$

$$E[W] = T(\theta)$$

e

$$\text{Cov}(W, U) = 0$$

$\forall U$ statistica con $E_U(U) = 0$

Ossia l'umvue è

uno stimatore non distorto

scaricato da qualsiasi stimatore non distorto di zero!

dim

• $\Rightarrow W \in \text{UMVUE PER } T(\theta) \text{ e } U \in \#_{\theta} [U] = 0$

$$W' = W + aU$$

$E[W'] = E[W] \rightarrow W' \text{ è ancora uno stimatore per } T(\theta).$

$$\text{Var}[W'] = \text{Var}[W] + a^2 \text{Var}[U] + 2a \text{Cov}(W, U)$$

Se $\text{Cov}(W, U) \neq 0$ posso trovare $a \in \mathbb{R}$

$$a^2 \text{Var}[U] + 2a \text{Cov}(W, U) < 0$$

$$\left[a \in \left[0, -\frac{\text{Cov}(W, U)}{\text{Var}[U]} \right] \right]$$

Allora sono uno a
un assorolto: ottieni

(o il simmetrico se la cov è > 0)

$$\text{Var}[W'] < \text{Var}[W]$$

Quindi perché non valga l'assorolto deve
essere $\text{Cov}(W, U) = 0$

• \Leftarrow Se W non fosse l'UMVUE

\Downarrow

$\exists W'$ uno stimatore per $T(\theta)$
con $\text{Var}(W') < \text{Var}[W]$

Ma $W' = W + (W' - W)$

$E[W'] = E[W] \quad \times \text{k sono entrambi uno}$
 distorti

Di conseguenza

$$E[W' - W] = 0$$

Ma

$$\text{Var}[W'] = \text{Var}[W] + \text{Var}[W' - W] + 2 \underbrace{\text{Cov}(W, W' - W)}_{\text{è } 0 \text{ per Hp.}}$$

$$\geq \text{Var}[W]$$

contraddizione

□

APPROCCIO BAYESIANO: ESEMPIO

(44)

IL PARAMETRO θ DIVENTA AVEATORIO CON LEGGE $\Pi(\theta)$
chiiamata LEGGE A PRIORI.

Dopo il campionamento ho

$$f(\vec{x}|\theta) \xrightarrow{\text{teo Bayes}} \Pi(\theta|\vec{x}) \quad \begin{array}{l} \text{DISTRIBUZIONE} \\ \text{A} \\ \text{POSTERIORI} \end{array}$$

↓

nell'approssimazione Bayesiana la si usa
per costruire stime

$$\Pi(\theta|\vec{x}) = \frac{f(\vec{x}|\theta) \Pi(\theta)}{m(\vec{x})} =$$

$$= \frac{f(\vec{x}|\theta) \Pi(\theta)}{\int f(\vec{x}|\theta) \Pi(\theta) d\theta}$$

↑ marginalizzazione di x .

Tipicamente

$E[\Pi(\theta|\vec{x})]$ stima θ

Guardiamo un caso concreto

Modello Beta - Binomiale

$x_1, \dots, x_n | p \sim \text{Be}(p)$

$y = \sum_{i=1}^n x_i \sim \text{Bi}(n, p)$ sempre condizionalmente a p

$\Pi(p) \sim \text{Beta}(\alpha, \beta) \leftarrow$ sto prendendo a caso da una Beta, che ha supporto tra 0 e 1.

Quindi

$f(y|p) \sim \text{Bi}(n, p)$

congiunta: $f(y, p) = \underbrace{f(y|p) p^y (1-p)^{n-y}}_{f(y|p)} \underbrace{\left[\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} \right]}_{\Pi(p)}$

$$= \binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha+y-1} (1-p)^{n-y+\beta-1}$$

Una devo trovare la funzione.

$$f(y) = \binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \int_0^1 p^{\alpha+y-1} (1-p)^{n-y+\beta-1} dp$$

ha la formula della densità di una Beta.

$$= \binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(y+\alpha)\Gamma(n-y+\beta)}{\Gamma(n+\alpha+\beta)} \int_0^1 \text{cost.} \dots dp$$

Possiamo calcolare la distribuzione a posteriori di p :

$$f(p|y) = \frac{f(y, p)}{f(y)} = \frac{\Gamma(n+\alpha+\beta)}{\Gamma(\alpha+y)\Gamma(n-y+\beta)} p^{y+\alpha-1} (1-p)^{n-y+\beta-1}$$

$\sim \text{Beta}(\alpha+y, n-y+\beta)$

E' un caso favorevole, punto da una beta, il coniugato è Binomiale, la distribuzione a posteriori è ancora una Beta con nuovi parametri (parametri aggiornati).

Uno stimatore di p può essere la media della legge di p .

$$\mathbb{E}[p] = \frac{\alpha}{\alpha+\beta} \quad \alpha \text{ regola la massa in 1}$$

$$\mathbb{E}[p|y] = \frac{\alpha+y}{n+\alpha+\beta} \leftarrow \begin{array}{l} \text{media della legge a} \\ \text{posteriori} \end{array}$$

-stimatore bayesiano

$$\mathbb{E}[p|y] = \frac{\alpha+y}{n+\alpha+\beta} = \frac{n}{\alpha+\beta+n} \left(\frac{y}{n} \right) + \frac{\alpha+\beta}{\alpha+\beta+n} \frac{\alpha}{\alpha+\beta}$$

↑
stimatore
frequentista,
 $\frac{y}{n}$

↑
stimatore a priori

di fatto sto pensando un info tutto fornita

dai dati e quelle che sepevo a priori.

Più inciso e più ho importanza
quello che mi dicono i dati.

TEST d'IPOTESI

(46)

DEF X_1, \dots, X_n iid $f(x, \theta)$


È un processo decisionale per decidere a favore o contro l'ipotesi statistica: affermazione sui parametri del campione

In un problema di verifica delle ipotesi chiavi nella

H_0 IPOTESI NULLA
 H_1 IPOTESI ALTERNATIVA.

Dovrò scegliere tra H_0 e H_1 , che in genere riportiscono lo spazio dei parametri

$$\begin{cases} H_0 & \theta \in H_0 \\ H_1 & \theta \in H_1 \end{cases}$$



Cosa metto in H_0 e cosa in H_1 ?

In H_0 metto quello che è vero fino a prova contraria,

in H_1 metto quello che voglio avere le prove x poterlo affermare.

In H_0 metto la cosa conservativa

Il test d'ipotesi è un tribunale

Def UN TEST D'IPOTESI È UNA REGOLA CHE SPECIFICA
 a) PER QUALI VALORI DEL CAMPIONE SI ACCETTA H_0 (H_0 VERA)
 b) PER QUALI VALORI DEL CAMPIONE SI RIFIUTA H_0 (H_0 FALSA)

(47)

LA REGIONE CRITICA: quella x cui RIFIUTO

→ REGIONE di ACCETTAZIONE

Si parla in generale di "accetto H_0 " o "rifiuto H_0 ", xK magari ho anche H_2 .

RC, RA SONO COSTRUITE TRAMITE UNA STATISTICA $T(\vec{x})$
 CHIAMATA STATISTICA TEST

METODI per COSTRUIRE i TEST

* TEST del RAPPORTO di VERO SIMIGLIANZA (LIKELIHOOD RATIO TEST) (LRT)

Def LA STATISTICA SUOI SI BASA IL LRT per

$$\begin{cases} H_0 : \theta \in \mathbb{H}_0 \\ H_1 : \theta \in \mathbb{H}_1 \end{cases}$$

campione di massima
 verosimiglianza
 esplorato solo in
 un range

$$\lambda(\vec{x}) = \frac{\sup_{\theta \in \mathbb{H}_0} L(\theta, \vec{x})}{\sup_{\theta \in \mathbb{H}} L(\theta, \vec{x})} = \frac{L(\hat{\theta}_{MLE}^0, \vec{x})}{L(\hat{\theta}_{MLE}, \vec{x})}$$

xK il \uparrow sopra viene raggiunto
 in $\hat{\theta}_{MLE}$

REGIONE CRITICA:

$$\{ \lambda(\vec{x}) \leq c \}$$

$$0 \leq c \leq 1$$

($\lambda(\vec{x})$ è sicuramente < 1)

Se la quantità λ è piccola
 significa che la massima verosimiglianza cresce
 molto di più se non sto in \mathbb{H}_0 , quindi è +
 probabile che θ sia in \mathbb{H}_0^c

ESEMPIO

(48)

$$X_1 \dots X_n \sim N(\mu, 1)$$

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta \neq \theta_0 \end{cases} \quad \begin{array}{l} \theta \text{ è il parametro incosnito,} \\ \theta_0 \text{ è noto.} \end{array}$$

$$\lambda(\vec{x}) = \frac{L(\theta_0, \vec{x})}{L(\hat{\theta}_{MLE}, \vec{x})} \quad \leftarrow \begin{array}{l} \text{Non ha senso fare il Sup} \\ \text{se ho solo 1 punto!} \end{array}$$

- La regione critica dovrebbe dipendere dal campione e da θ_0 , NON DA θ , ma non posso prendere una decisione basata su θ che non conosco.

$$\begin{aligned} &= \frac{\frac{1}{(2\pi)^{n/2}} \exp\left\{-\frac{1}{2} \sum (x_i - \theta_0)^2\right\}}{\frac{1}{(2\pi)^{n/2}} \exp\left\{-\frac{1}{2} \sum (x_i - \bar{x}_n)^2\right\}} = \\ &= \exp\left\{\frac{1}{2} \left(-\sum (x_i - \theta_0)^2 + \sum (x_i - \bar{x}_n)^2\right)\right\} \end{aligned}$$

OSS

$$\sum_{\pm \bar{x}_n} (x_i - \theta_0)^2 = \sum (x_i - \bar{x}_n)^2 + \sum (\bar{x}_n - \theta_0)^2 + 2 \underbrace{\sum (x_i - \bar{x}_n)(\bar{x}_n - \theta_0)}_{=0}$$

$$= \exp\left\{\frac{1}{2} \left(-\sum (x_i - \bar{x}_n)^2 - n(\bar{x}_n - \theta_0)^2 + \sum (x_i - \bar{x}_n)^2\right)\right\}$$

$$\lambda(\vec{x}) = \exp\left\{-\frac{n}{2} (\bar{x}_n - \theta_0)^2\right\} \quad \text{OK è una statistica} \quad \text{OK dipende da } \bar{x}_n \text{ e } \theta.$$


COSTRUIAMO LA REGIONE CRITICA

$$0 \leq c \leq 1$$

$$\begin{aligned} RC &= \left\{ \lambda(x) \leq c \right\} = \left\{ \exp\left\{-\frac{n}{2} (\bar{x}_n - \theta_0)^2\right\} \leq c \right\} \\ &= \left\{ |\bar{x}_n - \theta_0|^2 \geq \sqrt{\frac{-2 \log c}{n}} \right\} = \left\{ |\bar{x}_n - \theta_0| \geq K \right\} \quad K \in \mathbb{R} \end{aligned}$$

più la soglia c è vicina a 1
e più rifiuto sempre.

~~È ragionevole la mia RC?~~
~~La decisita è qualcosa~~
~~Devo decidere se θ è + grande o~~
~~+ piccolo che.~~
Finché vedo \bar{x}_n



Voglio sapere come è fatta la Regione Critica.


È ragionevole la forma della RC?

Rifuto H_0 Quando la media del campionario è distante dalla mia θ_0 .

I would no di osservare una cosa probabile rispetto al fatto di avere osservato un miracolo.

Quando colui sono x_1, \dots, x_n da $N(\theta, \sigma^2)$

SE È VERA H_0 \bar{x}_n sotto H_0



mi dice di rifutare quando sono in modo lontano da H_0 .

Perche - se sono qui x è molto + probabile che il campione sia generato da quest

Quella orancia mi genera il campione pallino arancio con probabilità molto maggiore.

Quando vorremo dare un valore k guarderemo la deviazione standard.

H_0 ottenuto una REGIONE bilatera, x_k

H_0 era $\theta = \theta_0$

$H_1 \neq$

la forma della nc dipende molto da cosa metto in H_0 e H_1 .

ESEMPIO

80

x_1, \dots, x_n iid


$$f(x_i, \theta) = \exp(-|x_i - \theta|) \mathbb{1}_{[\theta, +\infty)}(x_i); \quad \theta \in \mathbb{R}$$

esponenziale traslata

Voglio costruire LR+

Come è fatta la verosimiglianza?

$$\begin{aligned} L(\theta, \vec{x}) &= \exp\left(-\sum x_i + n\theta\right) \prod_{i=1}^n \mathbb{1}_{[\theta, +\infty)}(x_i) \\ &= \exp\left(-\sum x_i + n\theta\right) \mathbb{1}_{(-\infty, x_{(1)})}(\theta) \end{aligned}$$




$$\hat{\theta}_{MLE} = x_{(1)}$$

$$\begin{cases} H_0: \theta \leq \theta_0 \\ H_1: \theta > \theta_0 \end{cases}$$

$$\lambda(\vec{x}) = \frac{\sup_{\theta \leq \theta_0} L(\theta, \vec{x})}{\exp\left\{-\sum x_i + n x_{(1)}\right\}} =$$

Se il minimo delle mie osservazioni cade prima di θ_0 , il sup ristretto è ancora il minimo, altrimenti è θ_0




$$= \begin{cases} \frac{L(x_{(1)}, \theta)}{L(x_{(1)}, \theta_0)} & x_{(1)} \leq \theta_0 \\ \frac{L(\theta_0, \theta)}{L(x_{(1)}, \theta_0)} & x_{(1)} > \theta_0 \end{cases}$$

Quindi

$$\lambda(\vec{x}) = \begin{cases} 1 & x_{(1)} \leq \theta_0 \\ \exp\{-n(x_{(1)} - \theta_0)\} & x_{(1)} > \theta_0 \end{cases}$$

La statistica test qui è il minimo:



§1

Se il minimo è $\leq \theta_0$ accetto sempre
Rifiuto se

$$RC = \{ \lambda(x) \leq c \} = \{ e^{-n(x_{(1)} - \theta_0)} \leq c \}$$


È una RC?

Una partizione che
posso campionare $\rightarrow \{ x_{(1)} > \theta_0 - \log c \cdot \frac{1}{n} \}$
Se ho i dati ec? si.

È ragionevole come RC?

la densità è

Devo decidere se
 θ è + grande o
+ piccolo di θ_0



se osservo minimo qui ACCETTO, x_K SE RIFIUTASSI POSSERI AVERE DENSITÀ TIPO

Perché vedo minimi
se trovo minimi $> \theta_0$ di una certa soglia mi
immagino che i dati
siano dati da qualcosa che ha θ più grande,
 x_K genera quei dati con alta probabilità.

Quindi la forma della mia RC è ragionevole.

TEOREMA

Sia $T(\vec{x})$ UNA STATISTICA SOFFICIENTE per θ
e $\lambda(\vec{x}) \in \lambda^*(t)$ le statistiche LRT su \vec{x} e T
RISPECTIVAMENTE.

$$\lambda^*(T(\vec{x})) = \lambda(\vec{x})$$

dim:

$$\begin{aligned} \lambda(\vec{x}) &= \left\{ \frac{\sup_{\theta \in \Theta_0} L(\theta, \vec{x})}{\sup_{\theta \in \Theta} L(\theta, \vec{x})} \right\} = \frac{\sup_{\theta \in \Theta} f(\vec{x}, \theta)}{\sup_{\theta \in \Theta} f(\vec{x}, \theta)} = \\ \text{essendo } T \text{ suff. vale} \\ \text{teo fatti.} \downarrow &= \frac{\sup_{\theta \in \Theta_0} g(T(\vec{x}), \theta) / A(\vec{x})}{\sup_{\theta \in \Theta} g(T(\vec{x}), \theta) / A(\vec{x})} \quad \text{il sop dipende da } \theta \\ &= \frac{\sup_{\theta \in \Theta_0} g(T(\vec{x}), \theta)}{\sup_{\theta \in \Theta} g(T(\vec{x}), \theta)} = \lambda^*(T(\vec{x})) \end{aligned}$$

il sop dipende da θ
quindi quest'ultima
fornita dal sop è
semplicemente

Se sono uguali le due statistiche test saranno
uguali le due regioni critiche.



$$\begin{cases} H_0: \theta \in \Theta_0 \\ H_1: \theta \in \Theta_1 \end{cases}$$

ABBIAMO UNA STATISTICA TEST
e QUINDI ABBIAMO UNA RC.

$$RC = \{ \vec{x} \mid t_c \text{ rifiuto } H_0 \}$$

		DECISIONE	
		ACCETTO H_0	RIFIUTO H_0
VERO	\neq	OK	ERRORE 1 ^a TIPO
	$=$	ERRORE 2 ^a TIPO	OK

Non è possibile
avere sia errore
1^a tipo che 2^a tipo
a 0.

ES: $X_1, \dots, X_n \sim \text{Be}(p)$ (53)
 voglio fare un test del tipo
 La moneta è equilibrata? Bo!

$$H_0: p = p_0 = \frac{1}{2}$$

$$H_1: p \neq p_0$$

 se ho una scatola che contiene tante palline bianche quanto nere
 potrei, aprendo la scatola, conoscere il vero p .
 Ma in generale, come nella moneta, il parametro è davvero incognito!

$P_\theta(\bar{X} \in R_C) = \text{PROBABILITÀ di commettere un errore di PRIMO TIPO, SE } \theta \in H_0.$

$P_\theta(\bar{X} \in R_C^c) = \text{PROBABILITÀ di commettere un errore di SECONDO TIPO SE } \theta \in H_0^c$
 \uparrow
 $= 1 - P_\theta(\bar{X} \in R_C)$

Quindi

$$P_\theta(\bar{X} \in R_C) = \begin{cases} \text{probabilità di errore di 1^ tipo } \theta \in H_0 \\ 1 - \text{probabilità di errore di 2^ tipo } \theta \in H_0^c \end{cases}$$

Def

si dice FUNZIONE POTENZA di UN TEST D'IPOTESI

$$H_0: \theta \in H_0 \quad vs \quad H_1: \theta \in H_0^c,$$

di ragione critica R_C

$$\beta(\theta) = P_\theta(\bar{X} \in R_C)$$

↑
 mappa lo spazio dei parametri in $[0,1]$

A seconda di dove sia θ mi dà l'errore di
 1^ tipo 0 1 - errore 2^ tipo

Mi piacerebbe valersi 0 in $\theta \in H_0$
 1 in $\theta \in H_0^c$

But it's pretty difficult to find it!

Per confrontare i vari test
 confronteremo β .

(54) $\text{vogliamo calcolare la prob di essere piu o meno vicini a } \theta_0$ $1^{\text{a}} \text{ tipo} = 0$
 $2^{\text{a}} \text{ tipo} = 0$

OSSERVAZIONE

$$X \sim B_i(5, \theta)$$

(cioe un'unica osservazione)

$$H_0: \theta \leq \frac{1}{2} \quad \text{vs} \quad H_1: \theta > \frac{1}{2}$$

test 1

voglio capire se la p e' > 0 < rispetto alla soglia sopra.

Rifiuto H_0 se osservo solo successi: $X=5$

test 2

Rifiuto H_0 se $X > 3$

Come sono questi due test in termini di potenza?

$$\beta_1(\theta) = P_{\theta}(X=5) = \theta^5$$

$$\beta_2(\theta) = P_{\theta}(X > 3) = \left(\frac{5}{3}\right) \theta^3 (1-\theta)^2 + 5\theta^4 (1-\theta) + \theta^5 > \beta_1(\theta)$$



$$\text{test 1: P(errore 1^{\text{a}} \text{ tipo})} \leq \beta_1\left(\frac{1}{2}\right) = \left(\frac{1}{2}\right)^5 = 0,03125$$

P(errore 2^{\text{a}} \text{ tipo}) e' alta! potenza > 0,8 quindi $\theta > 0,96$
 $\uparrow 1 - P = \theta^5$

$$\text{test 2: P(errore 2^{\text{a}} \text{ tipo})} \leq \beta_2\left(\frac{1}{2}\right) = (10+5+1) \frac{1}{2^5} = \frac{1}{2} \quad (50\% \rightarrow \text{troppo alto!})$$

ESERCIZIO

$$x_1, \dots, x_n \sim N(\mu, \sigma^2) \quad H_0: \mu \leq \mu_0 \quad \text{vs} \quad H_1: \mu > \mu_0$$

LRT prova a fare x es... arriviamo a $\left\{ \frac{\bar{x}_n - \mu_0}{\sigma/\sqrt{n}} > c \right\}$ con c che e' una costante


$$\left\{ \bar{x}_n > \mu_0 + \frac{\sigma}{\sqrt{n}} c \right\}$$

$$\begin{aligned} \text{Calcolo ora } \beta(\mu) &= P_{\mu} \left(\frac{\bar{x}_n - \mu_0}{\sigma/\sqrt{n}} > c \right) \\ &= P_{\mu} \left(\frac{\bar{x}_n - \mu_0 + \mu - \mu}{\sigma/\sqrt{n}} > c \right) = \text{così ho standardizzato} \\ &= P_{\mu} \left(\frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}} > c + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} \right) \end{aligned}$$

$$\text{Quindi} \quad P_{\mu} \left(Z > c + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} \right) = 1 - \phi \left(c + \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} \right)$$

Graffichiamo la funzione potenza

(55)



$$\lim_{\mu \rightarrow +\infty} B(\mu) = 1$$

$$\lim_{\mu \rightarrow -\infty} B(\mu) = 0$$

funzione monotona crescente in μ .

- Voglio che $P_{\text{al RC}}$ per $\mu \leq \mu_0$ sia ≤ 0.1

$$B(\mu) \leq B(\mu_0) \quad \forall \mu \leq \mu_0 \quad (\text{dato di fatto})$$

Quindi basta scegliere che

$$1 - \phi(c) = 0.1 \quad \text{cioè } P_{\text{al RC}} = 0.1$$
$$\Rightarrow \phi(c) = 0.9 \rightarrow c = Z_{0.9} = 1,28$$

NB Posso modificare n (aumentandolo) in modo che la funzione

- voglio che $B(\mu) > 0.8 \quad \forall \mu \geq \mu_0 + \sigma$ (probabilità di commettere errore di 2^a tipo: 20%).

Quanto vale B in $\mu_0 + \sigma$?

$$B(\mu_0 + \sigma) = 1 - \phi(1.28 - \sqrt{n}) = 0.8$$

$$1.28 - \sqrt{n} = Z_{0.2} = -0.84$$

$$\downarrow$$
$$n = 4.49 \Rightarrow n > 5$$

da $\mu_0 + c$ $B(\mu) > 0.8$

Cioè se faccio almeno 5 osservazioni posso avere probabilità di commettere errore 2^a tipo $\approx 20\%$.

(56) Def $\forall 0 \leq \alpha \leq 1$, un test con funzione potenza $\beta(\theta)$
è detto di DIMENSIONE α SE
 $\sup_{\theta \in H_0} \beta(\theta) = \alpha$

Def $\forall 0 \leq \alpha \leq 1$, un test con funzione potenza $\beta(\theta)$ è detto
di LIVELLO α SE
 $\sup_{\theta \in H_0} \beta(\theta) \leq \alpha$

OSS

Laodale la $\beta(\theta)$ è continua non ho problemi a determinare livello/dimensione
(colllassano)

In certi casi però non si riuscirà ad ottenere la dimensione α , comunque
quasi sempre noi poniamo di livello α .
 α lo cercheremo piccolo tendenzialmente.

Cosa succede se voglio fissare il livello/dimensione di un test?

ESEMPIO 1 (di PRIMA)

$$X_1, \dots, X_n \sim N(\mu, \sigma^2)$$

$$H_0: \mu \leq \mu_0 \quad vs \quad H_1: \mu > \mu_0$$

$$LRT: RC \left\{ \bar{X}_n > \mu_0 + \frac{\alpha}{\sqrt{n}} c \right\}$$

$$\beta(\mu) = 1 - \Phi \left(c + \frac{\mu_0 - \mu}{\sigma / \sqrt{n}} \right)$$

ora voglio calcolare α :

$$\sup_{\mu \leq \mu_0} \beta(\mu) = \beta(\mu_0) = 1 - \Phi(c)$$

Quindi dimensione: $\alpha = 1 - \Phi(c)$
(vogliò il livello del quantile) $\rightarrow \Phi(c) = 1 - \alpha$

$$c = z_{1-\alpha} \quad (\text{rifiuto se } \dots < \text{quantile di ordine } 1-\alpha)$$

ESEMPIO 2 (già fatto)

$$X_1, \dots, X_n \text{ iid} \quad f(x|\theta) = e^{-(x-\theta)} \mathbb{1}_{[\theta, +\infty)}(x)$$

(esp. traslato)

$$H_0: \theta \leq \theta_0$$

$$H_1: \theta > \theta_0$$

$$X_i \sim T_i + \theta$$

$\uparrow \varepsilon(\text{d})$

$$\text{LRT: } RC = \left\{ X_{(1)} > \theta_0 - \frac{\log c}{n} \right\} \quad (+c \text{ è piccolo + rifiuto quasi mai})$$

NB

- CON LRT (o altre tecniche) ho la forma della regione critica
- IMPONDENDO IL NIVELLO SI VINCOLA LA SOGLIA (c) della RC



$$\sup_{\theta \leq \theta_0} \beta(\theta) = \alpha$$

\uparrow vediamo se riusciamo

(α è tipicamente 1% o 5%.
ma in generale selgo 10)

OSS

$$P(X_{(1)} > t)$$

In generale $X_i \sim \varepsilon(d)$

$$\left[\prod_{i=1}^n P(X_i > t) = (1 - F_{X_i}(t))^n = (1 - 1 + e^{-dt})^n = e^{-nt} \right]$$

$$X_{(1)} \sim T_{(1)} + \theta \sim \varepsilon(na) + \theta \sim \varepsilon(n) + \theta$$

$$P(X_{(1)} > t) = e^{-n(t-\theta)}$$

Voglio calcolare

$$1) \beta(\theta) = P_\theta(X_{(1)} > \theta - \frac{\log c}{n}) \rightarrow \text{sostituisco a quella sopra}$$

e impongo che

$$t = \theta_0 - \frac{\log c}{n}$$

$$2) \sup_{\theta \leq \theta_0} \beta(\theta) = \alpha$$

$$\beta(\theta) \text{ cresce in } \theta \quad (\text{x ho } e^{\frac{n\theta - nt}{n}})$$

↑ positivo

Quindi

$$\sup_{\theta \leq \theta_0} \beta(\theta) = \beta(\theta_0) = e^{-n[\theta_0 - \frac{\log c}{n} - \theta_0]} = \alpha$$

↑ Per il fatto che la funzione $\beta(\theta)$ è crescente in θ

$$e^{\frac{\log c}{n}} = \alpha \rightarrow \underline{c = \alpha}$$

Quindi $\beta(\theta)$ è di dimensione α

$$\text{e } RC = \left\{ X_{(1)} > \theta_0 - \frac{\log \alpha}{n} \right\}$$

$$\beta(\theta) = e^{-n(\theta_0 - \theta - \frac{\log \alpha}{n})}$$


Agendo su n posso modificare $\beta(\theta)$ - vedi prima-

DEF UN TEST CON FONZIONE DI POTENZA $\beta(\theta)$ È NON DISTORTO
SE $\beta(\theta') > \beta(\theta'')$
 $\forall \theta' \in \Theta_0^c$ e $\theta'' \in \Theta_0$.

(provo

LRT

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu \neq \mu_0 \end{cases}$$



Verrebbe da dire che è monotona e sempre vero, ma per esempio non monotona

\Rightarrow cioè non è che le funzioni potenze sono sempre monotone!

ESERCIZIO 1

$$X_1, \dots, X_5 \sim \text{Bin}(p) \quad 0 \leq p \leq 1$$

$$\begin{cases} H_0: p = 1/2 \\ H_1: p \neq 1/2 \end{cases} \quad RC = \left\{ \left| \bar{X} - \frac{1}{2} \right| > c \right\}$$

OSS L'IPOTESI È UN PONTO QUINDI SI DICE IPOTESI SEMPLICE

- trovare c tc quel test abbia dimensione $\alpha = 0,1$
- " " livello $\alpha = 0,1$

Dato che H_0 è 1 punto non ho il sop, ma la prob in quel punto.

$$\begin{aligned} P_{1/2} \left(\left| \bar{X}_5 - \frac{1}{2} \right| > c \right) &= P_{1/2} \left(\left| \sum X_i - \frac{5}{2} \right| > sc \right) = \\ &= 1 - P_{1/2} \left(-sc \leq \sum X_i \leq sc \right) \end{aligned}$$

NB $\sum X_i \sim \text{Bin}(5, 1/2)$ $E[X_i] = \frac{5}{2}$

$\sum X_i - \frac{5}{2}$	P_k
-5/2	0,03125
-3/2	0,15625
-1/2	0,31250
1/2	0,31250
3/2	0,15625
5/2	0,03125

Quindi

$$\begin{aligned} P_{1/2} \left(\left| \bar{X}_5 - \frac{1}{2} \right| > c \right) &= \\ &= \begin{cases} 1 & sc < 1/2 \\ 1 - 2 \cdot 0,03125 & \frac{1}{2} < sc < 3/2 \\ 2 \cdot 0,03125 & 3/2 < sc < 5/2 \\ 0 & sc > 5/2 \end{cases} \end{aligned}$$

Ricco le dimensioni possibili sono: 1; 0,375; 0,0625; 0

(54)

Quindi non c'è c per cui ho dimensione α , ma posso trovare c tc la $\beta(\theta)$ ha livello α , basta scegliere

$Sc > 3/2$, così ho $0 + 0,625$ che è < 10%.

Il fatto che \exists dimensione $\in \mathbb{X}$ è discreto

ESERCIZIO 2

$$x_1 \sim P(\lambda)$$

$$\begin{cases} H_0: \lambda = 1 \\ H_1: \lambda = 2 \end{cases}$$

$$\beta(1) = P_{\lambda=1}(x > 3) = 0.019$$

RC $\{x > 3\}$ voglio un test di dimensione $\alpha = 5\%$.

Introduco allora ~~alla~~ dei test RANDO mizzati

$$\phi(x) = \begin{cases} 1 & x > 4 \\ \gamma & x = 3 \\ 0 & x \leq 2 \end{cases}$$

(funzione di γ con la quale voglio)

Allora decido il valore di γ tc

$$1 - P(x > 4) + \gamma P(x = 3) = 0.05 \quad \gamma = 0,506$$

Quindi posso costruire test che non sono trubonati con 2 possibilità, ma aggiungo un'ipotesi (qui γ) al fine di ottenere una

funzione potenzialmente di una certa dimensione α che voglio 10.

(60) Come massimizzare la potenza?

Def Sia \mathcal{C} una classe di test per verificare

$$H_0: \theta \in \mathcal{H}_0 \quad \text{vs} \quad H_1: \theta \in \mathcal{H}_0^c$$

un test ϵ è con funzione potenza $\beta(\theta)$ e detto

UMP (uniformly most powerful) uniformemente più potente

nella classe \mathcal{C} se

$$\beta(\theta) \geq \beta'(\theta) \quad \forall \theta \in \mathcal{H}_0^c$$

$\forall \beta'(\theta)$ funzione di un test ϵ' e

Conchiamo il test che performance meglio,

batte gli altri in termini di potenza quando $\theta \in \mathcal{H}_0^c$

Puoi di fatto fissare il livello, poi all'interno dei test di livello α cerchiamo l'UMP
 $\epsilon =$ test di livello α .

Per trovare l'UMP ci servono dei risultati.

LEMMA di NEYMAN - PEARSON

CNS x caratterizzare l'UMP,
tranne che x A misura nulla

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta = \theta_1 \quad (\text{IPOTESI SEMPLICA})$$

$f(\vec{x}, \theta_0)$ legge di \vec{x} sotto H_0

$f(\vec{x}, \theta_1)$ legge di \vec{x} sotto H_1

Se osiamo una RC tc

$$(1) \vec{x} \in RC \text{ se } f(\vec{x}, \theta_1) > K f(\vec{x}, \theta_0)$$

$$\vec{x} \in RC^c \text{ se } f(\vec{x}, \theta_1) \leq K f(\vec{x}, \theta_0)$$

- θ_1 reale + probabile
l'osservazione
rispetto a θ_0 .

$$(2) \alpha = P_{\theta_0}(\vec{x} \in RC) \quad K \geq 0$$



a) Qualunque test che soddisfi (1) e (2) è UMP
di livello α

b) Se \exists un test che soddisfa (1) e (2) con $K > 0$
allora ogni test UMP di livello α
ha anche dimensione α (vale la (2))

e soddisfa la (1) tranne che per un insieme
di misura nulla, cioè

$$P_{\theta_0}(\vec{x} \in A) = P_{\theta_1}(\vec{x} \in A) = 0$$

olim se vale la (2), dato che le ipotesi sono semplici, il test ha dimensione. (61)

Chiamiamo $\Phi(\vec{x})$ la funzione test:

$$\Phi(\vec{x}) = \begin{cases} 1 & \vec{x} \in R_C \\ 0 & \vec{x} \in R_C^c \end{cases}$$

- a) Sia $\Phi(\vec{x})$ la funzione test di un test che soddisfa (1) e (2)
Sia $\Phi'(\vec{x})$ la funzione test di un qualunque altro test di livello α
Siano $\beta(\theta_1)$ e $\beta'(\theta_1)$ le relative funzioni potenza.

$$(\Phi(\vec{x}) - \Phi'(\vec{x})) [f(\vec{x}, \theta_1) - K f(\vec{x}, \theta_0)] \geq 0 \quad \forall \vec{x} \in \mathbb{R}^n$$

- se $\vec{x} \in R_C$:

$$[1 - \Phi'(\vec{x})] \star \geq 0$$

$\xrightarrow{\substack{\vec{x} \in R_C \\ \text{non lo conosco}}} \quad \xleftarrow{\substack{\vec{x} \in R_C \\ \text{ma } \star \text{ nella } R_C \text{ è } > 0 \\ \vec{x} \in \text{costituita proprio da} \\ f(\vec{x}, \theta_1) > K f(\vec{x}, \theta_0)}}$

- se $\vec{x} \in R_C^c$:

$$[0 - \Phi'(\vec{x})] \star \geq 0 \quad \text{yo}$$

$\xleftarrow{\leq 0} \quad \xrightarrow{\geq 0}$

Quindi

$$0 \leq \int_{\mathbb{R}^n} (\Phi(\vec{x}) - \Phi'(\vec{x})) [f(\vec{x}, \theta_1) - K f(\vec{x}, \theta_0)] d\vec{x}$$

$$0 \leq \underbrace{\beta(\theta_1)}_{\in \int \Phi(\vec{x}) f(\vec{x}, \theta_1) d\vec{x}} - \underbrace{\beta'(\theta_1)}_{\in \int f(\vec{x}, \theta_1) d\vec{x}} - K [\beta(\theta_0) - \beta'(\theta_0)]$$

$$\text{ma dato che } \Phi \text{ candidato UMP soddisfa la (2),} \quad \beta(\theta_0) = \alpha \Rightarrow \beta(\theta_0) - \beta'(\theta_0) = \alpha - \underbrace{\beta'(\theta_0)}_{\leq \alpha} > 0$$

$$\begin{aligned} \textcircled{*} \quad 0 &\leq \beta(\theta_1) - \underbrace{\beta'(\theta_1)}_{\leq \alpha} - K [\beta(\theta_0) - \beta'(\theta_0)] \leq \beta(\theta_1) - \beta'(\theta_1) \\ &\Rightarrow \beta(\theta_1) \geq \beta'(\theta_1) \quad \geq 0 \end{aligned}$$

- b) Φ' funzione test di un qualunque test UMP di livello α .

Per il punto a) anche Φ (del test che soddisfa (1) e (2)) è UMP di livello α .
Allora $\beta(\theta_1) = \beta'(\theta_1)$ (altrimenti non sarebbero entrambi UMP).

da $\textcircled{*}$

$$\alpha - \beta'(\theta_0) \leq 0 \Rightarrow \beta'(\theta_0) \geq \alpha$$

Perciò Φ' è UMP di livello $\alpha \Rightarrow \beta'(\theta_0) \leq \alpha \Rightarrow \beta'(\theta_0) = \alpha$

Ma allora $\textcircled{*} = 0$

$$\Rightarrow \int [\Phi(\vec{x}) - \Phi'(\vec{x})] [f(\vec{x}, \theta_1) - K f(\vec{x}, \theta_0)] = 0 \quad - \text{l'unico modo per avere } 0 \text{ è} \\ \Phi' = 0 \text{ tranne che su insieme} \\ \text{di misura nulla A: } P_{\theta_0}(\vec{x} \in A) = P_{\theta_1}(\vec{x} \in A) = 0$$

62) COROLLARIO

TEST HO $\Theta = \Theta_0$ VS $H_1: \Theta = \Theta_1$

$T(\vec{x})$ STAT SUFF per Θ .

$g(T|\theta)$ la legge di T .

Allora ogni test basato su T con reazione di rifiuto S è UMP di livello α SE

$$t \in S \text{ se } g(t, \Theta_1) > kg(t, \Theta_0)$$

$$t \in S^c \text{ se } g(t, \Theta_1) < kg(t, \Theta_0)$$

$$\text{e } \alpha = P_{\Theta_0}(T \in S)$$

↑ lemma di N-S costruito sulla densità di una stat. suff.

dove

$$S: R_C = \{\vec{x} : T(\vec{x}) \in S\}$$

vale il criterio di fattorizzazione: $f(\vec{x}, \Theta_1) = h(\vec{x})g(T(\vec{x}), \Theta_1)$

$$\vec{x} \in R_C \text{ se } f(\vec{x}, \Theta_1) = g(T(\vec{x}), \Theta_1)h(\vec{x}) \geq kg(T(\vec{x}), \Theta_0)h(\vec{x}) = kf(\vec{x}, \Theta_0)$$

$$\vec{x} \notin R_C^c \text{ se } f(\vec{x}, \Theta_1) = g(T(\vec{x}), \Theta_1)h(\vec{x}) < kg(T(\vec{x}), \Theta_0)h(\vec{x}) = kf(\vec{x}, \Theta_0)$$

ESEMPIO

① $X \sim BC(2, \Theta)$

$H_0: \Theta = 1/2$ VS $H_1: \Theta = 3/4$

$$f(x, \Theta_1)$$

$$f(x, \Theta_0) \quad \text{per } x=0, 1, 2$$

← la densità qui è probabilità discreta.

$$\frac{f(0, \frac{3}{4})}{f(0, \frac{1}{2})} = \frac{(\frac{1}{4})^2}{(\frac{1}{2})^2} = \frac{1}{4}$$

USO NP

$$\Rightarrow \frac{3}{4} < k < \frac{9}{4} \quad R_C = \{x=2\} \quad \text{è UMP di livello}$$

$$\alpha = P(X=2 | \Theta = \frac{1}{2}) = \frac{1}{4}$$

$$\frac{f(1, \frac{3}{4})}{f(1, \frac{1}{2})} = \frac{2 \cdot \frac{3}{4} \cdot \frac{1}{4}}{2 \cdot \frac{1}{2} \cdot \frac{1}{2}} = \frac{3}{4}$$

$$\frac{1}{4} < k < \frac{3}{4} \quad R_C = \{x \geq 1\} \quad \text{UMP di livello}$$

$$k < \frac{1}{4} \quad R_C = \{x \geq 0\} \quad \alpha = 1$$

↑ rifiuto sempre

$$\frac{f(2, \frac{3}{4})}{f(2, \frac{1}{2})} = \frac{(\frac{3}{4})^2}{(\frac{1}{2})^2} = \frac{9}{4}$$

$$k > \frac{9}{4} \quad \text{non rifiuto mai, } R_C = \emptyset \quad \alpha = 0$$

2) $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ σ^2 noto.

$$H_0: \mu = \mu_0 \text{ vs } H_1: \mu = \mu_1 > \mu_0$$

Ci interessa dimostrare che X_n è suff. per μ .

$$\bar{X}_n \sim N(\mu, \frac{\sigma^2}{n}) \quad \text{Quindi } g(t, \mu) = \frac{1}{\sqrt{2\pi\sigma^2/n}} \exp \left\{ -\frac{n}{2\sigma^2} (t-\mu)^2 \right\}$$

Applicando il corollario di NP

$$g(t, \theta_1) > k g(t, \theta_0) \leftarrow \text{SE È COSÌ RIPISTO}$$

$$\frac{\sqrt{n}}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2} (t-\mu_1)^2 \frac{1}{\sigma^2/n} \right) > k \frac{\sqrt{n}}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2} (t-\mu_0)^2 \frac{1}{\sigma^2/n} \right)$$

\uparrow prendo il log

$$-\frac{1}{2} \frac{(t-\mu_1)^2}{\sigma^2/n} > -\frac{1}{2} \frac{(t-\mu_0)^2}{\sigma^2/n} + \log k$$

$$-(t-\mu_1)^2 > \frac{2\sigma^2}{n} \log k - (t-\mu_0)^2$$

$$-t^2 + 2t\mu_1 - \mu_1^2 > \frac{2\sigma^2}{n} \log k - t^2 - \mu_0^2 + 2t\mu_0$$

$$t > \left(\frac{2\sigma^2}{n} \log k - \mu_0^2 + \mu_1^2 \right) \frac{1}{2(\mu_1 - \mu_0)} \text{ è UMP.}$$

Il test si fonda quando t è > di una certa quantità

Se avessi avuto $\mu_1 < \mu_0$ avrei avuto $t < \dots$

RC

$$\left\{ \vec{X}: \bar{X}_n > \frac{\frac{2\sigma^2}{n} \log k - \mu_0^2 + \mu_1^2}{2(\mu_1 - \mu_0)} \right\}$$

al crescere din il limite si abbina, la gauss si stringe.

Ma manca il livello.

Io posso imponere giocando con k .

Il livello è

$$P_{\mu=\mu_0}(\text{RC}) \quad \left\{ \vec{X}: \bar{X}_n > \mu_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha} \right\}$$

Potrei riscrivere k in funzione di α .

L'UMP mi dà la formula del livello, poi
impongo il 50%

In realtà non mi interessa ritornare al K iniziale.

Via NP ho dimostrato che $\left\{ \vec{X}: \bar{X}_n > \mu_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha} \right\}$ è UMP di
livello (ϵ dimensione) α per

$$H_0: \mu = \mu_0 \text{ vs } H_1: \mu = \mu_1 \quad \mu_1 > \mu_0$$

Se non avessi pensato a \bar{X}_n , ma avessi usato la stessa del campione
avrei ottenuto lo stesso RC XK di fatto tanto mantiene la media
campionaria.

Se avessi

$$H_0: \mu = 0 \text{ vs } H_1: \mu = 1 \quad \mu_1 > \mu_0 \leftarrow \text{finché vale } \alpha \text{ non cambia nulla.}$$

$$\text{RC} = \left\{ \bar{X}_n > \bar{\mu} \right\} \quad \text{IL LIVELLO GUARDA SOLO } \mu_0!$$

⇒ IL TEST E UMP per $H_0: \mu = \mu_0$ VS $H_1: \mu > \mu_0$

Se la RC non dipende da θ_1

Penso che il test UMP lo è anche x H₀ composta come questo

$$\begin{cases} H_0: \theta \leq \theta_0 \\ H_1: \theta > \theta_0 \end{cases} \text{ test unilateri}$$

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta \neq \theta_0 \end{cases} \text{ test bilateri}$$

$H_0 + RC$

Def Una famiglia di leggi $\{g(t, \theta), \theta \in \Theta\}$ univariata

Ha Likelihood Ratio Monotono (MLR)

se $\forall \theta_2 > \theta_1$

ESEMPIO $\frac{g(t, \theta_2)}{g(t, \theta_1)}$ è una funzione monotona non decrescente ↑ di t

$$g(t, \theta) \sim N(\theta, \sigma^2_{\text{noto}})$$

$$\frac{g(t, \theta_2)}{g(t, \theta_1)} \quad \theta_2 > \theta_1$$

$$= \exp \left[-\frac{1}{2\sigma^2} (t - \theta_2)^2 + \frac{1}{2\sigma^2} (t - \theta_1)^2 \right] = \exp \left\{ -\frac{1}{2\sigma^2} [(t^2 - 2\theta_2 t + \theta_2^2) - t^2 + 2t\theta_1 - \theta_1^2] \right\}$$
$$= \exp \left\{ \frac{t}{\sigma^2} (\theta_2 - \theta_1) + \dots \right\} \rightarrow \text{questa funzione è crescente int}$$

Le gassiane a media incognita e varianza nota sono con LRM

$$g(t, \theta) = f_t(x) C(\theta) \exp \{ t w(\theta) \}$$

↑ se la famiglia è esponenziale in genere basta controllare cosa succede nell'exp

TEOREMA di KARLIN-RUBIN

$$\begin{cases} H_0: \theta \leq \theta_0 \\ H_1: \theta > \theta_0 \end{cases}$$

Sia T una statistica sufficiente per θ e supponiamo che la legge di T,

$\{g(t, \theta)\}$ abbia MLR.

Allora, ∀ t_0 , il test con $RC = \{T > t_0\}$

è UMP di LIVELLO

$$\alpha = P_{\theta_0}(T > t_0)$$

Quindi il Sup ↑ è raggiunto in θ_0

$$\text{dim } \beta(\theta) = P_{\theta}(R > t) \quad (\text{funtione potenza})$$

Sia $\theta' > \theta_0$

e consideriamo il test

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta = \theta' \end{cases} \quad \text{-test dalle ipotesi semplici -}$$

Dato che T ha MLR voglio mostrare che $\beta(\theta)$ è un'ascendente.

Consideriamo

$$\theta_1 < \theta_2 \Rightarrow \frac{d}{dt} [F(t, \theta_2) - F(t, \theta_1)] = g(t, \theta_2) - g(t, \theta_1) =$$

↑ funzione di ripartizione

$$= g(t, \theta_2) \left[\frac{g(t, \theta_2)}{g(t, \theta_1)} - 1 \right]$$

è positiva

È CRESCENTE in t

prima < 0, poi > 0

subito > 0
e continua a crescere

Quindi
il massimo di

$$F(t, \theta_2) - F(t, \theta_1)$$

ove vale 0


Quindi
 $F(t, \theta_2) - F(t, \theta_1)$ può
essere decrescente e poi crescere
o crescere sempre.

$$\Downarrow \quad F(t, \theta_2) \leq F(t, \theta_1) \quad \circledast$$

X > Y stocasticamente, ossia non è che tutti i valori di X sono > di quelli di Y, ma tendenzialmente

Quando $F_X(t) \leq F_Y(t)$

la f.d. raccoglie la "massa" della v.a.



la massa della Y viene
raccolta prima
di quella della X.



Valori che vengono dati da X
sono tendenzialmente + grandi
dei valori dati da Y
(...ma non è che proprio per forza
accade!)

Quindi ho che le funzioni ordinate stocasticamente
 \Rightarrow la mia $\beta(\theta)$ è crescente:

$$\beta(\theta) = P_{\theta}(T > t_0), \quad \theta_2 > \theta_1.$$

$$\beta(\theta_1) = P_{\theta_1}(T > t_0) = 1 - F(t_0, \theta_1) \stackrel{\circledast}{\leq} 1 - F(t_0, \theta_2) = P_{\theta_2}(T > t_0) = \beta(\theta_2)$$

Quindi

Avere MLR crescente

\Downarrow
 $\beta(\theta)$ crescente

$$\text{H}_0: \theta \leq \theta_0 \quad R_C = \{T > t_0\}$$

ha mostrato $\beta(\theta) \uparrow$.

Analogamente vale

$$1) \sup_{\theta \leq \theta_0} \beta(\theta) = \beta(\theta_0) = P_{\theta_0}(T > t_0) = \alpha$$

$$2) \text{Definiamo } k' = \inf_t \frac{g(t, \theta')}{g(t, \theta_0)} \quad (\text{avendo le ipotesi sempre} \quad \begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta = \theta' \end{cases})$$

$$\text{con } T = \{T > t_0, g(t, \theta) > 0\}$$

$$\downarrow \\ T > t_0 \Leftrightarrow \frac{g(t, \theta')}{g(t, \theta_0)} > k'$$

$$\uparrow \\ g(t, \theta') > k' g(t, \theta_0)$$

e grazie al corollario x statistiche sufficienti del lemma NP

test $\{T > t_0\}$ e UMP di livello α . ■

Cerco stat suff con rapporto di likelihood monotono ...

Analogamente

$$\begin{cases} H_0: \theta \geq \theta_0 \\ H_1: \theta < \theta_0 \end{cases}$$

T con rapporto di likelihood crescente

\downarrow
test con $R_C = \{T < t_0\}$ sono UMP di livello
 $\alpha = P_{\theta_0}(T < t_0)$

Spesso abbiamo

$$\begin{cases} H_0: \theta \leq \theta_0 \\ H_1: \theta > \theta_0 \end{cases}$$

e T con rapporto di likelihood monotono
decrescente (x es.

$$\Gamma(x, \beta) \approx \frac{1}{\Gamma(x)} x^{x-1} e^{-\beta x} \beta^x$$

$$\beta_2 > \beta_1 \quad \frac{\frac{1}{\Gamma(x)} x^{x-1} e^{-\beta_2 x} \beta_2^x}{\frac{1}{\Gamma(x)} x^{x-1} e^{-\beta_1 x} \beta_1^x} = e^{-(\beta_2 - \beta_1)x}$$

\downarrow decrescente)

Allora prendo $-T$,
che ha rapporto di likelihood crescente.

Allora avro-

$$R_C = \{-T > t_0\}$$

NP ci dice che

$$\begin{aligned} H_0: \theta &= \theta_0 \\ H_1: \theta &= \theta_1 \\ \theta_1 > \theta_0 \end{aligned}$$

$$\begin{aligned} T \uparrow \text{ UMP} \in \{T > t_0\} \\ \alpha = P_{\theta_0}(T > t_0) \end{aligned}$$

il salto al fatto che sia per

$$\begin{aligned} H_0: \theta &= \theta_0 && \text{è giusto, } \forall n \quad T > t_0 \text{ penale memoria del } \theta_1 \\ H_1: \theta &> \theta_0 \end{aligned}$$

H_0 UMP del Sup,

$$\{T > t_0\} \text{ è UMP di livello } \alpha = P_{\theta_0}(T > t_0) =$$

x la
monotonia
della funzione
potenza $\rightarrow = \sup_{\theta \leq \theta_0} P_{\theta}(T > t_0)$

SEMPRE L'UMP?

ESEMPIO

$$X_1, \dots, X_n \sim N(\mu, \sigma^2) \quad \sigma^2 \text{ noto}$$

Voglio testare l'ipotesi

$$\begin{cases} H_0: \theta = \theta_0 \\ H_1: \theta \neq \theta_0 \end{cases}$$

\bar{X}_n stat suff. abbiamo visto che ha MLR

Fissiamo $\theta_1 < \theta_0$

il test con $RC_1 = \{\bar{X}_n < \frac{\sigma}{\sqrt{n}} z_\alpha + \theta_0\}$ è UMP

TEST 1

con $P_{\theta_0}(R_1) = \alpha$ (quantile di ordine α , ha standardizzato la gaussiana)

Ogni altro test di livello α con potenza in θ_1 pari a quella del test 1 deve avere la stessa R_1 (a meno di un insieme di misura nulla)

TEST 2


$$RC_2 = \{\bar{X}_n > \theta_0 - \frac{\sigma}{\sqrt{n}} z_\alpha\} \quad P_{\theta_0}(R_2) = \alpha$$

$\beta_1(\theta)$ funzione potenza test 1

$\beta_2(\theta)$ " " test 2.

pseudotest $\theta_2 > \theta_0$

$$\beta_2(\theta_2) = P_{\theta_2}\left(\bar{X}_n > \theta_0 - \frac{\sigma}{\sqrt{n}} z_\alpha\right) = P_{\theta_2}\left(\frac{\bar{X}_n - \theta_2}{\sigma/\sqrt{n}} > \frac{\theta_0 - \theta_2}{\sigma/\sqrt{n}} - z_\alpha\right) > 0$$



$$> P(z > -z_\alpha) = 1 - P(z \leq -z_\alpha) = 1 + P(z < z_\alpha)$$

gaussiana standard $> P_{\theta_2}\left(\frac{\bar{X}_n - \theta_2}{\sigma/\sqrt{n}} < z_\alpha + \frac{\theta_0 - \theta_2}{\sigma/\sqrt{n}}\right) < 0$


$$= P_{\theta_2}\left(\bar{X}_n < \theta_0 + \frac{\sigma}{\sqrt{n}} z_\alpha\right) =$$

$$= \beta_1(\theta_2)$$

Quindi ho


$\beta_2(\theta_2) > \beta_1(\theta_2)$. Ma il nostro test era UMP \Rightarrow Assurdo $\Rightarrow \exists$ UMP.

(8) IL TEST 1



TEST 2

$$P_\theta(\bar{X}_n > \theta_0 - \frac{\sigma}{\sqrt{n}} z_\alpha) = 1 - \Phi\left(-z_\alpha + \frac{\theta_0 - \theta}{\sigma/\sqrt{n}}\right)$$



Per $\theta = \theta_0$ vs $\theta + \theta_0$

abbiamo cambiato la classe per fare i test,
XK questi sono eutauksi distorti per $\theta = \theta_0$ vs $\theta + \theta_0$.

NON DISTORTO:

$$\beta(\theta'') > \beta(\theta')$$

$$\forall \theta'' \in H_0^c$$

$$\forall \theta' \in H_0$$


Qui non è vero!

Questi 2 test che sono OMP per $\theta > 0$ o $\theta < 0$
non possono esserlo x il caso bilatero, XK
qui sono distorti

↓
ci restringiamo al caso dei test distorti
e abbiamo

TEST 3

$$R_3 = \left\{ \bar{X}_n > \theta_0 - \frac{\sigma}{\sqrt{n}} z_{\frac{\alpha}{2}} \right\} \cup \left\{ \bar{X}_n < \theta_0 + \frac{\sigma}{\sqrt{n}} z_{\frac{\alpha}{2}} \right\}$$



è non
distorto,
il suo minimo
è proprio nel

↑ non riesce a vincere
gli altri 2 test nei due nuovi
ma vince nella parte non distorta.

NP si può usare anche in un contesto del tipo

$$\begin{cases} H_0: f \sim N(\mu_0, \sigma_0^2) \\ H_1: f \sim \text{Cauchy} \end{cases}$$

faccio il rapporto e rifiuto quando il rapporto è > K.

TEST UNIONE INTERSEZIONE

UI

INTERSEZIONE UNIONE

L'IPOTESI NULLA $H_0: \theta \in \bigcap_{\gamma \in \Gamma} \mathbb{H}_\gamma$

per essere
finito o
misurabile

$$H_1: \theta \in \bigcup_{\gamma \in \Gamma} \mathbb{H}_\gamma^c$$

Supponiamo di conoscere

$$H_{0\gamma}: \theta \in \mathbb{H}_\gamma$$

abbia $RC = R_\gamma$ $\Rightarrow RC$ per test UI

$$H_{1\gamma}: \theta \in \mathbb{H}_\gamma^c$$

$$RC = \bigcup_\gamma R_\gamma$$

ESEMPIO

$$x_1, \dots, x_n \sim N(\theta, \sigma^2)$$

$$H_0: \theta = \theta_0$$

$$H_1: \theta \neq \theta_0$$

posso leggerlo come test unione intersezione:

$$\theta = \theta_0 \quad \mathbb{H}_1 \cap \mathbb{H}_2$$

$$\mathbb{H}_1 = \{\theta \leq \theta_0\}$$

$$RC = \{\bar{x}_n < \dots\}$$

$$\mathbb{H}_2 = \{\theta > \theta_0\}$$

$$RC = \{\bar{x}_n > \dots\}$$

Quindi

$$RC \text{ per } \theta = \theta_0 : RC = \{\bar{x}_n < t_1\} \cup \{\bar{x}_n > t_2\}$$

e t_1 e t_2 le posso scegliere come voglio
per avere livello α ,

Se prendo le due RC a $\frac{\alpha}{2}$ e $\frac{\alpha}{2}$, simmetrico,

ho UMP, ma potrei anche

decidere di non prenderlo simmetrico

(70)

IU

$$H_0: \theta \in \bigcap_{\gamma \in \Gamma} H_\gamma$$

$$H_1: \theta \in \bigcup_{\gamma \in \Gamma} H_\gamma^c$$

$$H_{0\gamma}: \theta \in H_\gamma$$

$$H_{1\gamma}: \theta \in H_\gamma^c$$

ha una regione critica R_γ

$$\Rightarrow RC = \bigcap_{\gamma \in \Gamma} R_\gamma$$

sono false quando sono false tutte,
ossia nello stesso
delle R_γ

21 aprile 2015

> TEST UI

$$H_0: \theta \in \bigcap_{\gamma \in \Gamma} H_\gamma = H_0$$

$$H_1: \theta \in \bigcup_{\gamma \in \Gamma} H_\gamma^c = H_1^c$$

$$RC = \bigcup_{\gamma \in \Gamma} RC_\gamma$$

regioni critiche a γ fissato.

Sia $\lambda_\gamma(\vec{x})$ la LRT statistics per $H_0: \theta \in H_\gamma$
vs $H_1: \theta \in H_\gamma^c$

$\lambda(\vec{x})$ la LRT statistics per $H_0: \theta \in H_0$
vs $H_1: \theta \in H_1^c$

TEOREMA

$$T(\vec{x}) = \inf_{\gamma \in \Gamma} \lambda_\gamma(\vec{x})$$

$$\begin{aligned} \text{Sia } R_T &= \left\{ \vec{x} : \lambda_\gamma(\vec{x}) < c \text{ per almeno un } \gamma \in \Gamma \right\} = \\ &= \left\{ \vec{x} : T(\vec{x}) < c \right\} \end{aligned}$$

$$R_\lambda = \left\{ \vec{x} : \lambda(\vec{x}) < c \right\} \quad (\text{LRT})$$

Allora

$$a) T(\vec{x}) \geq \lambda(\vec{x}) \quad \forall \vec{x}$$

$$b) \beta_T(\theta) \leq \beta_\lambda(\theta) \quad \forall \theta$$

$$c) \text{Se il LRT ha livello } \alpha \Rightarrow \text{anche il U.I.T. ha livello } \alpha$$

test unico
intersezione

dim a) $\mathbb{H}_0 = \bigcap_{\theta \in \Gamma} \mathbb{H}_\theta \subset (\mathbb{H})_\gamma \quad \forall \gamma \in \Gamma$

$$\lambda_\gamma(\vec{x}) = \sup_{\theta \in \mathbb{H}_\gamma} L(\theta, \vec{x}) \frac{1}{\sup_{\theta \in \mathbb{H}} L(\theta, \vec{x})} \geq \frac{\sup_{\theta \in \mathbb{H}_0} L(\theta, \vec{x})}{\sup_{\theta \in \mathbb{H}} L(\theta, \vec{x})} = \lambda(\vec{x}) \quad \forall \gamma$$

\uparrow LRT

Allora abbiamo che $\forall \gamma$
 $\lambda_\gamma(\vec{x}) \geq \lambda(\vec{x})$

il sup su \mathbb{H}_γ è \geq sup su \mathbb{H}
 cioè è
 l'intersezione
 dei \mathbb{H}_γ

$$T(\vec{x}) = \inf_{\gamma} \lambda_\gamma(\vec{x}) \geq \lambda(\vec{x})$$

b) $\beta_T(\theta) = P_\theta(T(\vec{x}) < c) \leq P_\theta(\lambda(\vec{x}) < c) = \beta_\lambda(\theta)$

$$\{\vec{x}: T(\vec{x}) < c\} \subset \{\vec{x}: \lambda(\vec{x}) < c\}$$

(la uso usando la monotonia delle probabilità)

c) $\sup_{\theta \in \mathbb{H}_0} \beta_T(\theta) \leq \sup_{\theta \in \mathbb{H}_0} \beta_\lambda(\theta) \leq \alpha$

■

> TEST IU

$$H_0: \theta \in \bigcup_{\gamma \in \Gamma} \mathbb{H}_\gamma = \mathbb{H}_0$$

$$H_1: \theta \in \bigcap_{\gamma \in \Gamma} \mathbb{H}_\gamma^c = \mathbb{H}_0^c$$

$$R = \bigcap_{\gamma \in \Gamma} R_\gamma$$

TEOREMA

Sia α_γ il livello del test per H_0 e R_γ

Allora il test IU $R = \bigcap_{\gamma \in \Gamma} R_\gamma$ ha livello $\sup_\gamma \alpha_\gamma$

dim

$$\theta \in \mathbb{H}_0: \theta \in \mathbb{H}_\gamma \text{ per qualche } \gamma$$

$$P_\theta(\vec{x} \in R) \leq P_\theta(\vec{x} \in R_\gamma) \leq \alpha_\gamma \leq \alpha = \sup_\gamma \alpha_\gamma$$

f2

TEOREMA

$$H_0 \quad \theta \in \bigcup_{j=1}^k H_j \quad \Gamma = \{1, \dots, k\}$$

$\forall j = 1, \dots, k$ sia R_j regione di rifiuto per un test
di livello α per H_{0j}

e supponiamo che
per qualche $i = 1, \dots, k$ \exists una successione di
parametri $\theta \in H_i$ tc

$$1) \lim_{l \rightarrow +\infty} P_{\theta_l}(\vec{x} \in R_i) = \alpha$$

$$2) \forall j = 1, \dots, k \neq i \quad \lim_{l \rightarrow +\infty} P_{\theta_l}(\vec{x} \in R_j) = 1$$

\Rightarrow il test IU $R = \bigcap_{j=1}^k R_j$ ha dimensione α .

dici

dal teorema precedente: R ha livello α .

$$\theta \in \bigoplus_{i=1}^n H_i \subset \mathbb{R}^n$$

$$\sup_{\theta \in \mathbb{R}^n} P_\theta(\vec{x} \in R) \geq \lim_{l \rightarrow +\infty} P_{\theta_l}(\vec{x} \in R) = \lim_{l \rightarrow +\infty} P_{\theta_l}(\vec{x} \in \bigcap_{j=1}^k R_j) \geq$$

- diseguaglianza di Bonferroni:

$$P\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n P(A_i) - (n-1)$$

$$\geq \lim_{l \rightarrow +\infty} \left[\underbrace{\sum_{j=1}^k P_{\theta_l}(\vec{x} \in R_j)}_{\text{il limite per } j=i \text{ fa } \alpha.} - (k-1) \right] =$$

il limite per $j=i$ fa α .
Negli altri casi fa 1

$$= \underbrace{k-1}_{\text{per } j=i \text{ fa } \alpha} + \alpha - (k-1) = \alpha$$

$$\lim_{l \rightarrow +\infty} \sum_{j=1}^k P_{\theta_l}(\vec{x} \in R_j) = 1 \cdot (k-1) + \alpha \cdot 1$$

per $j=i$
il limite di j fa α
per cui fa 1



ESEMPIO

(73)

Azienda che produce tessuti.

2 parametri importanti per il tessuto.

 θ_1 : resistenza media alla trazione θ_2 : probabilità di passare un test di infiammabilità.

Supponiamo che ci siano degli standard:

 θ_1 deve essere > 50 pounds θ_2 deve essere > 0.95 Dello dimostrare $\theta_1 > 50$ $\theta_2 > 0.95$

Se deve passare entrambi i test è esattamente un DI

$$H_0: \{\theta_1 \leq 50 \circ \theta_2 \leq 0.95\}$$

$$H_1: \{\theta_1 > 50 \wedge \theta_2 > 0.95\}$$

← in H_1 metto quello che voglio dimostrare.

$$X_1 \dots X_n \text{ iid } N(\theta_1, \sigma^2) \quad \leftarrow \text{trazione}$$

LRT, test per H_{01}

$$R_1 = \left\{ \frac{\bar{X}_n - 50}{S/\sqrt{n}} > t \right\}$$

$$Y_1 \dots Y_n \text{ iid } Be(\theta_2) \quad \leftarrow \text{infiammabilità}$$

test per H_{02}

$$R_2 = \left\{ \sum Y_i > b \right\}$$

$$R = \left\{ (\vec{x}, \vec{y}) : \frac{\bar{x} - 50}{S/\sqrt{n}} > t \text{ e } \sum y_i > b \right\}$$

$$\text{Fissiamo } \alpha_1 = \alpha_2 = 0.95$$

$$n = m = 58$$

Se \vec{x} è una successione
dei numeri reali che varia
e se $\vec{x} \in R$

$$t = t_{0.95}(57) = 1.672$$

$$b = 57$$

Posso dire che il test ha dimensione $\alpha = 0.05$ se riesco ad applicare il teorema precedente.

$$\vec{\theta}_0 = (\theta_{01}, \theta_{02}) = (l, 0.95), \vec{\theta}_0 \in \mathbb{H}$$

$$\lim_{l \rightarrow +\infty} P_{\vec{\theta}_0} (\vec{x} \in R_1) = 1$$

$$\lim_{l \rightarrow +\infty} P_{\vec{\theta}_0} (\vec{y} \in R_2) = 0.05$$

Quindi posso applicare il teorema e ho che il test ha dimensione 5%. In questo modo non ho bisogno di modellizzare le dipendenze di x e y .

(74) P-VALUE

Def p-value $p(\vec{x})$ è una statistica che $0 \leq p(\vec{x}) \leq 1$
 Valori piccoli di $p(\vec{x})$ danno evidenza per H_1 vero
 (rifiuto H_0)

Una statistica p-value è valida se $\forall \theta \in \Theta_0$ e
 $\forall 0 \leq \alpha \leq 1$

$$P_{\theta} (p(\vec{x}) \leq \alpha) \leq \alpha$$

sotto H_0 la probabilità di vedere valore piccolo è piccola.

Se $p(\vec{x})$ è un p-value valido è uso

$$RC = \{ \vec{x} : p(\vec{x}) \leq \alpha \}$$

il test ha livello α

$$\text{perché } \sup_{\theta \in \Theta_0} P_{\theta} (RC) = \sup_{\theta \in \Theta_0} P_{\theta} (p(\vec{x}) \leq \alpha) \leq \alpha$$

ESEMPIO

$$x_1 \dots x_n \sim N(\mu, 1)$$

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu \neq \mu_0 \end{cases}$$

$$RC_{\alpha} = \left\{ \left| \bar{x}_n - \mu_0 \right| \sqrt{n} > z_{1-\frac{\alpha}{2}} \right\}$$

Al 1^ anno: p-value: più piccolo α per cui rifiuto H_0


$\forall \alpha > p$ rifiuto

$\forall \alpha \leq p$ accetto

È una statistica tra 0 e 1? è valida?

Possiamo riscrivere:

$$p(\vec{x}) = \inf_{\alpha} \{ \vec{x} \in R_{\alpha} \} \quad \text{è una statistica.}\\ \text{ed è un livello, quando è tra 0 e 1.}$$



$$\begin{aligned} p(\vec{x}) &= \inf_{\alpha} \{ \vec{x} \in R_{\alpha} \} = \\ &= \inf_{\alpha} \left\{ \left| \bar{x}_n - \mu_0 \right| \sqrt{n} > z_{1-\frac{\alpha}{2}} \right\} = \\ &= 2 \left[1 - \Phi \left(\frac{|\bar{x}_n - \mu_0|}{\sqrt{n}} \right) \right] \end{aligned}$$

Costruiamo un test che abbia livello esattamente dove finiscono i miei dati.

Dobbiamo vedere se $\forall \theta \in \Theta_0$ $P_{\theta} (p(\vec{x}) \leq \alpha) \leq \alpha$

Qui H_0 è $\mu = \mu_0$

Venerdì 26 aprile 2019

$$\begin{aligned} P_{\mu_0}(P(\vec{x}) \leq \alpha) &= P_{\mu_0}\left[2(1 - \Phi(|\bar{x}_n - \mu_0|/\sqrt{n})) \leq \alpha\right] = \\ &= P_{\mu_0}\left[\Phi(|\bar{x}_n - \mu_0|/\sqrt{n}) \geq 1 - \frac{\alpha}{2}\right] = \\ &= P_{\mu_0}\left[|\bar{x}_n - \mu_0|/\sqrt{n} \geq \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right] = \end{aligned}$$

Gaussiano standard χ^2
la sto calcolando sotto μ_0
(è come se avessi
 $P(|z| \geq t) = 2[1 - \Phi(t)]$)

$$= 2\left[1 - \Phi\left(\Phi^{-1}\left(1 - \frac{\alpha}{2}\right)\right)\right] = \alpha.$$

Quindi
 $P_{\mu_0}(P(\vec{x})) \leq \alpha = \alpha \Rightarrow$ il p-value del 1^o anno
è lo stesso

Il p-value è una statistica - lo costruiamo a partire solo dai dati

Come Costruire un p-value valido?

TEOREMA

Sia $w(\vec{x})$ una statistica test tc valori grandi di w danno evidenza a favore di H_1 .

$$P(\vec{x}) = \sup_{\theta \in \Theta_0} P_\theta(w(\vec{x}) \geq w(\vec{x})) \quad \text{è un p-value valido}$$

dim

$$\sup_{\theta \in \Theta_0} P_\theta(w(\vec{x}) \geq w(\vec{x}))$$

$F_\theta(w)$ funzione di ripartizione di $-w(\vec{x})$

$$\begin{aligned} P_\theta(\vec{x}) &= P_\theta(w(\vec{x}) \geq w(\vec{x})) = P_\theta(-w(\vec{x}) \leq -w(\vec{x})) = \\ &= F_\theta(-w(\vec{x})) \end{aligned}$$

$$y = F_x(x)$$

$$(DP(Y \leq t)) = P(F_x(X) \leq t) = P(X \leq F_x^{-1}(t)) = F_x(F_x^{-1}(t)) = t$$

Quindi
 $y \sim U$

nel caso continuo (nel discreto è stocasticamente > un'uniforme)

$$\forall 0 \leq \alpha \leq 1$$

sto considerando
anche casi discreti.

$$P_\theta(P_\theta(\vec{x}) \leq \alpha) \leq \alpha$$

$$P(\vec{x}) = \sup_{\theta \in \Theta_0} P_\theta(w(\vec{x}) \geq w(\vec{x})) = \sup_{\theta \in \Theta_0} P_\theta(\vec{x}) \geq P_\theta(\vec{x}) \quad (*)$$

$$\Rightarrow P_\theta(P(\vec{x}) \leq \alpha) = P_\theta\left(\sup_{\theta \in \Theta_0} P_\theta(\vec{x}) \leq \alpha\right) \leq P_\theta(P_\theta(\vec{x}) \leq \alpha) \leq \alpha$$

$$\stackrel{\text{uso } (*)}{P(\vec{x}) \leq \alpha} \subset P_\theta(\vec{x}) \leq \alpha$$

dim.
sia

(76) STIME INTERVALLARI

L'UPPER AUS

$$\theta \in \mathbb{R}$$

$$\vec{x} \in \mathbb{R}^p$$

$$T(\vec{x}): \Omega \rightarrow \mathbb{R}$$

$$T(\vec{x})(w) = t$$

Una stima dice

$\theta \in \Theta(\vec{x})$ regole del gioco i cui livelli sono conoscibili conoscendo solo i dati
 \hookrightarrow STATISTICHE

Def UNA STIMA INTERVALLARE di un parametro reale θ incognito è UNA COPPIA DI STATISTICHE, $L(\vec{x}), U(\vec{x})$ tc

$$L(\vec{x}) \leq U(\vec{x})$$

$$\theta \in [L(\vec{x}), U(\vec{x})]$$

Limite inferiore e limite superiore

(potrebbero anche essere determinati - $U(x) = +\infty, L(x) = -\infty$)

Esempio

$$x_1 \dots x_4 \sim N(\mu, 1)$$

Normalmente fermo ad una x trovare μ massimo visto \bar{x}_4

Una stima intervallare potrebbe essere

$$IC = [\bar{x}_4 - 1, \bar{x}_4 + 1]$$

In qst esempio $P(\bar{x}_4 = \mu) = 0$

\Rightarrow le mie stime puntuali prendono probabilità 0.

Fosso calcolare invece

$$\begin{aligned} P(\mu \in IC) &= P(\bar{x}_4 - 1 \leq \mu \leq \bar{x}_4 + 1) = \\ &= P(|\bar{x}_4 - \mu| \leq 1) = P(|Z| \leq 2) = 0,9544 \\ &\quad \uparrow \\ &\quad \bar{x}_4 \sim N(\mu, \frac{1}{4}) \end{aligned}$$

Mettiamo nel caso delle trazioni di rifiuti.

$$x_1 = 50,1$$

$$x_2 = 50,3$$

$$x_3 = 50,2$$

$$x_4 = 50$$

$$\bar{x}_4 = 50,15$$

$$\text{Costruisco } IC = [49,15; 51,15]$$

(l'intervallo è su un intervallo)

Il μ vero sta lì dentro o no? Bo.

Realizzando un IC, questo lo prende o non ci prende

Non lo posso sapere!

0.9544 mi dice $P(\mu \in [L(\bar{x}), U(\bar{x})])$


o saluto delle variabili aleatorie.

Il 95% degli intervalli dirà la cosa giusta

Similmente, molti intervalli contennero la media, ma il 5% non la terranno

Non è che $\mu \in I_C$ con $P=0.95!!$

$$\hat{P} P(\mu \in [L(\bar{x}), U(\bar{x})]) \approx 0.95$$



Def. DATO UNO STIMATORE INTERVALLARE $[L(\bar{x}), U(\bar{x})]$ PER θ



$P_\theta (\theta \in [L(\bar{x}), U(\bar{x})])$ È DETTA

PROBABILITÀ di COPERTURA

• Dato uno stimatore intervallare $[L(\bar{x}), U(\bar{x})]$ per θ

$$\inf_{\theta} P_\theta (\theta \in [L(\bar{x}), U(\bar{x})]) \text{ È DETTA}$$

LIVELLO o COEFFICIENTE di CONFIDENZA

Nel conoscendo θ , ci interessa sapere se il caso peggiore rispetto a (\bar{x}, \bar{x}) abbia copertura limitata. Lo dobbiamo tenere sotto controllo.

La probabilità totale di copertura è α .

Portenno di intervallo di confidenza di livello $1-\alpha$.

ESEMPIO

$X_1, \dots, X_n \sim U[0, \theta]$ non è esponenziale.

$X_{(n)} = \max(X_1, \dots, X_n)$ è la statistica Y_0 .

$$I_{C_1} = [aX_{(n)}, bX_{(n)}]$$

$$1 \leq a < b$$

→ sarebbe meglio fare una
stima sotto il massimo

$$0 \leq c < d.$$

$$I_{C_2} = [X_{(n)} + c, X_{(n)} + d]$$

$$1) P_\theta (\theta \in I_{C_1}) = P_\theta (aX_{(n)} \leq \theta \leq bX_{(n)}) = P \left(\frac{1}{b} \leq \frac{X_{(n)}}{\theta} \leq \frac{1}{a} \right) =$$

$$= P \left(\frac{1}{b} \leq T \leq \frac{1}{a} \right) =$$

$$= F_T \left(\frac{1}{a} \right) - F_T \left(\frac{1}{b} \right) =$$

$$= \left(\frac{1}{a} \right)^n - \left(\frac{1}{b} \right)^n$$

non dipende
da θ !

Faccendo l'inf resta lui.

= livello di I_{C_1}

$$T = \frac{X_{(n)}}{\theta} \sim ?$$

$$F_{X_{(n)}}(t) = \left(\frac{t}{\theta} \right)^n \Rightarrow F_T(t) = P(T \leq t) =$$

$$= P(X_{(n)} \leq t\theta) =$$

$$= F_{X_{(n)}}(t\theta) = t^n$$

per $0 \leq t \leq 1$

Potro trovare infiniti a e b tali
l'intervalllo abbia $P=95\%$

$$\begin{aligned}
 78) 2) P_\theta(\theta \in IC_2) &= P_\theta(X_m + c \leq \theta \leq X_n + d) = \\
 &= P_\theta\left(1 - \frac{d}{\theta} \leq \frac{X_m}{\theta} \leq 1 - \frac{c}{\theta}\right) = P_\theta\left(1 - \frac{d}{\theta} \leq T \leq 1 - \frac{c}{\theta}\right) = \\
 &= \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n
 \end{aligned}$$

Questa probabilità di confidenza varia al variare di θ .
Ne calcolo l'inf.

Oss $\lim_{\theta \rightarrow +\infty} \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n = 0$

Allora

$$\inf_{\theta} P_\theta(\theta \in IC_2) = 0 \quad \leftarrow \text{livello di confidenza di } IC_2$$

Bleah!

Quindi compro IC_1 .

IC_1 perde memoria di θ xK e è costituito so $\frac{X(n)}{\theta}$,

mentre IC_2 è additivo.

la \uparrow deve dipendere da θ

non è una statistica.
Ma la sua legge
non dipende da θ

Metodi per COSTRUIRE IC

1) INVERSIONE di un TEST

Mettiamo in corrispondenza bionico test e IC.

Esempio

$$x_1, \dots, x_n \sim N(\mu, \sigma^2) \quad \sigma^2 \text{ noto}$$

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu \neq \mu_0 \end{cases} \quad \times \quad R_\alpha = \left\{ \bar{x}: |\bar{x}_n - \mu_0| > Z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right\}$$

Se σ incognita
avrei $t(n-1)$
 \uparrow e quis.

$$P_{\mu_0}(R_\alpha) = \alpha$$

$$P_{\mu_0}(R_\alpha^c) = 1 - \alpha$$

$$\begin{aligned}
 1 - \alpha &= P_{\mu_0}(R_\alpha^c) = P_{\mu_0}(|\bar{x}_n - \mu_0| \leq \frac{\sigma}{\sqrt{n}} Z_{1-\frac{\alpha}{2}}) = \\
 &= P_{\mu_0} \left(\bar{x}_n - \frac{\sigma}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \leq \mu_0 \leq \bar{x}_n + \frac{\sigma}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \right)
 \end{aligned}$$

vale per ogni μ_0

Quindi $\left[\bar{x}_n - \frac{\sigma}{\sqrt{n}} Z_{1-\frac{\alpha}{2}}, \bar{x}_n + \frac{\sigma}{\sqrt{n}} Z_{1-\frac{\alpha}{2}}\right]$ è IC (^{xk no 2 estremiche sono 2 stabili})


di livello $1 - \alpha$ per $\mu \leftarrow xK$ di fatto posso rifare lo stesso con μ_0 .
Dove μ è il mio parametro incognito

$$A(\mu_0) = \left\{ \vec{x} : \mu_0 - \frac{\alpha}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \leq \bar{x}_n \leq \mu_0 + \frac{\alpha}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \right\}$$

$$\mathcal{C}(\vec{x}) = \left\{ \mu : \bar{x}_n - \frac{\alpha}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \leq \mu \leq \bar{x}_n + \frac{\alpha}{\sqrt{n}} Z_{1-\frac{\alpha}{2}} \right\}$$

$$(\vec{x} \in A(\mu_0)) \Leftrightarrow \mu_0 \in \mathcal{C}(\vec{x})$$

Quando faccio un test fisso il parametro è accetto i valori accettabili per l'IIC invece fra i dati e cerco i valori del parametro che sono compatibili.



piattaforma realizzazione della media campionaria sullo spazio dei parametri.
Farsi un indovino, avrei la bisaccia.
Ma invece mi concedo una tolleranza

TEOREMA

1) $\forall \theta_0 \in \Theta$ sia $A(\theta_0)$ la regione di accettazione di un test di livello α per $H_0: \theta = \theta_0$

$$\forall \vec{x} \text{ definiamo } \mathcal{C}(\vec{x}) = \{ \theta_0 : \vec{x} \in A(\theta_0) \}$$

Allora $\mathcal{C}(\vec{x})$ è una regione di confidenza di livello $1-\alpha$

2) Sia $\mathcal{C}(\vec{x})$ una regione di confidenza di livello $1-\alpha$

$$\forall \theta_0 \in \Theta \text{ sia } A(\theta_0) = \{ \vec{x} : \theta_0 \in \mathcal{C}(\vec{x}) \}$$



$A(\theta_0)$ è la regione di accettazione di un test di livello α per $H_0: \theta \leq \theta_0$

dim

$$1) P_{\theta_0}(\vec{x} \notin A(\theta_0)) \leq \alpha \Rightarrow P_{\theta_0}(\vec{x} \in A(\theta_0)) \geq 1-\alpha$$

$$\text{Quindi } \forall \theta_0 \quad P_{\theta_0}(\theta_0 \in \mathcal{C}(\vec{x})) = P_{\theta_0}(\vec{x} \in A(\theta_0)) \geq 1-\alpha$$

↓ se vale $\forall \theta_0$

$$\inf_{\theta} P_{\theta}(\theta \in \mathcal{C}(\vec{x})) \geq 1-\alpha$$

\exists l'IIC di livello $1-\alpha$

80

2) Perimone di 1^a tipo per $H_0: \theta = \theta_0$

$$P_{\theta_0}(\vec{x} \notin A(\theta_0)) = P_{\theta_0}(\theta_0 \notin C(\vec{x})) \leq \alpha$$

Quindi il test ha livello α .

La formula della RC dà la formula della regione di confidenza.

Punica partivo da un intervallo e ottengo un intervallo.

Test bilateri producono intervalli,
test unilateri producono semirette.ESEMPIO $X_1, \dots, X_n \sim N(\mu, \sigma^2)$

$$\begin{cases} H_0: \mu = \mu_0 \\ H_1: \mu < \mu_0 \end{cases}$$

$$\text{LRT: } RC = \left\{ \bar{X}_n < \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha \right\}$$

$$A(\mu_0) = \left\{ \vec{x}: \bar{X}_n > \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha \right\} =$$

$$= \left\{ \vec{x}: \mu_0 < \bar{X}_n - \frac{\sigma}{\sqrt{n}} z_\alpha \right\}$$

Quindi dal teorema:

$$C(\vec{x}) = \left\{ \mu: \mu \leq \bar{X}_n - \frac{\sigma}{\sqrt{n}} z_\alpha \right\} \text{ è regione di confidenza di livello } 1-\alpha$$

$(-\infty, \bar{X}_n - \frac{\sigma}{\sqrt{n}} z_\alpha]$

Quindi ho una semiretta

ESEMPIO

$$X_1, \dots, X_n \sim \mathcal{E}\left(\frac{1}{\lambda}\right)$$

Voglio costruire un intervallo di confidenza per $E[X_i] = \lambda$

$$\begin{cases} H_0: \lambda = \lambda_0 \\ H_1: \lambda < \lambda_0 \end{cases} \quad \text{LRT: } \lambda(\vec{x}) = \frac{\left(\frac{1}{\lambda_0}\right)^n \exp\left(-\sum x_i \frac{1}{\lambda_0}\right)}{\left(\frac{1}{\lambda_{MUE}}\right)^n \exp\left(-\sum x_i \frac{1}{\lambda_{MUE}}\right)} = \frac{\left(\frac{1}{\lambda_0}\right)^n \exp\left(-\sum x_i \frac{1}{\lambda_0}\right)}{\left(\frac{1}{\bar{X}_n}\right)^n \exp\left(-\sum x_i \frac{1}{\bar{X}_n}\right)}$$


$$\left[\lambda_{MUE} = \left(\frac{1}{\bar{X}_n}\right)^n \exp\left(-\frac{\sum x_i}{\bar{X}_n}\right) \quad \bar{X}_{MUE} = \bar{X}_n \right]$$

$\hookrightarrow -n \log \lambda - \frac{\sum x_i}{\lambda} \Rightarrow \text{denovo} \Rightarrow -\frac{n}{\lambda} + \frac{\sum x_i}{\lambda^2} = 0$

Quindi


$$\lambda(\vec{x}) = \left(\frac{\sum x_i}{n \lambda_0}\right)^n e^{-\frac{\sum x_i}{\lambda_0}} \quad \boxed{\text{statistica test}}$$

$$A(\lambda_0) = \left\{ \vec{x}: \left(\frac{\sum x_i}{n \lambda_0}\right)^n e^{-\frac{\sum x_i}{\lambda_0}} > K \right\} \quad K \in K(\alpha)$$



Quindi

$$\mathcal{C}(\vec{x}) = \left\{ \lambda : \left(\frac{\sum x_i}{\lambda} \right)^n e^{-\frac{\sum x_i}{\lambda}} \geq \kappa \right\}$$



23 aprile 2015

2) QUANTITÀ PIVOTALE

Def QUANTITÀ PIVOTALE

una variabile aleatoria $Q(\vec{x}, \theta) = Q(x_1, \dots, x_n, \theta)$ è una ^{e-mail è una} statistica! e' detta quantità pivotale se la legge di $Q(\vec{x}, \theta)$ non dipende da θ .

- $x_1, \dots, x_n \sim U(\alpha, \beta)$

$$T = \frac{x_n}{\theta} \quad F_T(t) = t^n \rightarrow \text{non dipende da } \theta \Rightarrow \text{la legge non dipende da } \theta$$

$\Rightarrow \frac{x_n}{\theta}$ È QUANTITÀ PIVOTALE

- $x_1, \dots, x_n \sim N(\mu, \sigma^2)$

$$\frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}} \sim t(n-1) \quad \text{Quindi } \frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}} \text{ è quantità pivotale.}$$

- $x_1, \dots, x_n \sim \mathcal{E}(\frac{1}{\lambda})$

$$\sum x_i \sim \Gamma(n, \frac{1}{\lambda})$$

Possiamo costruire, a partire da quest', un Q ?
Sì:
 $\frac{\sum x_i}{\lambda} \sim \Gamma(n, 1) \quad \left(\begin{array}{l} x_k \sim \Gamma(\alpha, \beta) \\ \forall k \end{array} \right)$

Per molti di
comodato ci si riporta spesso a una χ^2

$$\chi^2(m) \sim \Gamma(\frac{m}{2}, \frac{1}{2})$$

Quindi è utile costruire

$$\frac{2\sum x_i}{\lambda} \sim \Gamma(\frac{2n}{2}, \frac{1}{2}) \sim \chi^2(2n)$$

è non è una statistica, ma è ora quantità pivot.

Perché sono utili a costruzione IC?

Rendiamo $Q(\vec{x}, \theta)$ quantità pivot e

$$\text{coppia } (a, b) \text{ tc } P(a \leq Q(\vec{x}, \theta) \leq b) = 1 - \alpha$$

a e b non dipendono da θ

$$\mathcal{C}(\vec{x}) = \left\{ \theta : a \leq Q(\vec{x}, \theta) \leq b \right\} = \left\{ L(\vec{x}, a\theta) \leq \theta \leq U(\vec{x}, b\theta) \right\}$$

SE Sono in grado di
invertire la quantità pivotale

82) ESEMPIO

$$1) X_1, \dots, X_n \sim \mathcal{E}(\frac{1}{\lambda})$$

Voglio un IC per λ So che $\sum_{i=1}^n X_i \sim \chi^2(2n)$ = sezione IC in modo simmetrico

$$1-\alpha = P\left(\chi_{\frac{n}{2}}^2(2n) \leq \frac{\sum X_i}{\lambda} \leq \chi_{1-\frac{\alpha}{2}}^2(2n)\right)$$

$$\Downarrow \\ 1-\alpha = P\left(\frac{\sum X_i}{\chi_{1-\frac{\alpha}{2}}^2(2n)} \leq \lambda \leq \frac{\sum X_i}{\chi_{\frac{n}{2}}^2(2n)}\right)$$

$$2) X_1, \dots, X_n \sim N(\mu, \sigma^2)$$

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim t(n-1)$$

$$\text{Io so} \\ 1-\alpha = P\left(t_{\frac{n}{2}}^{(n-1)} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq t_{1-\frac{\alpha}{2}}^{(n-1)}\right)$$

$$\Downarrow \\ 1-\alpha = P\left(\frac{\bar{X}_n - \bar{\mu}}{\sigma/\sqrt{n}} + t_{\frac{n}{2}}^{(n-1)} \leq \mu \leq \bar{X}_n - \frac{\bar{\mu}}{\sigma/\sqrt{n}} + t_{1-\frac{\alpha}{2}}^{(n-1)}\right)$$

È ugualmente all'che avevo scritto

$$= \left[\bar{X}_n - \frac{\bar{\mu}}{\sigma/\sqrt{n}} + t_{1-\frac{\alpha}{2}}^{(n-1)} \right]$$

Poi questo è poi.

Ma ho scelto di farlo

simmetrico. Nessuno mi vieta di farlo

simmetrico.

Perché ho fatto questa scelta?

* Se avessi scelto $\bar{\mu}$ avrei avuto un intervallo + lungo

Metodi per VALUTARE IC

A parià di confidenza ($1-\alpha$) cerco l'intervallo di lunghezza minima

X_k se minimizzo la lunghezza, quando prendo un intervallo che è anche preciso

C'è però ovviamente un trade-off tra confidenza e lunghezza degli intervalli

(Non posso avere confidenza 100% e piccolo IC, ma dovrò avere tutto lo resto)

$$X_1, \dots, X_n \sim N(\mu, \sigma^2) \quad \sigma^2 \text{ noto}$$

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$$

$$P(0 \leq Z \leq b) = 1-\alpha$$

$$\left[a \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq b \right]$$

\Updownarrow

$$\left[\bar{X}_n - \frac{b\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n - \frac{a\sigma}{\sqrt{n}} \right]$$

la varianza dell'IC è

$$L(IC) = \frac{\sigma}{\sqrt{n}} (b-a) \text{ dipende proprio dai quantili.}$$

Data la simmetria della legge di z, si ha che $b-a$ è minimizzato quando $a = -b$.

Questa proprietà vale \forall :

Def si dice che $f_x(x)$ è UNIMODALE se $\exists x^*$ tc
 $f_x(x)$ è una decrescente $\forall x \leq x^*$ e crescente $\forall x > x^*$
 (ha un solo massimo, può essere non simmetrica)



TEOREMA

I Sia $f_x(x)$ una densità unimodale.
 Se l'intervallo $[a, b]$ soddisfa


a) $\int_a^b f_x(x) dx = 1-\alpha$

b) $f_x(a) = f_x(b) > 0$ e

c) $a \leq x^* \leq b$ dove x^* è la moda di f

Il $[a, b]$ è l'intervallo di larghezza minima tra quelli che soddisfano a)

Se avessi




ma
sia
che
simmetrica
rispetto all'asse delle mode

Dico

Sia $[a', b']$ un intervallo tc $b'-a' < b-a$ (*)
 Non perdiamo generalità prendendo $a' < a$

i) Sia $b' \leq a \Rightarrow a' \leq b' \leq a \leq x^*$



$$\int_{a'}^{b'} f_x(x) dx \leq f_x(b') (b'-a') \leq f_x(a) (b'-a') \\ < f_x(a) (b-a)$$

XK le
forniture sta crescendo,
sono prime del massimo (★)

$$\leq \int_a^b f_x(x) dx = 1-\alpha$$


Quindi se
prendono intervallo
+ corto, tutto asx dia
un da- $\int f_x(x) dx < 1-\alpha$

Quindi non sono nella classe di intervalli
che soddisfano a.)

(84) ii) $(b' - a') < b - a$

$$b' > a$$

Quindi $a' \leq a < b' < b$



$$\begin{aligned} \int_{a'}^{b'} f_x(x) dx &= \int_a^b f_x(x) dx + \int_{a'}^a f_x(x) dx - \int_{b'}^b f_x(x) dx \\ &= (1-\alpha) + \underbrace{\int_{a'}^a f_x(x) dx}_{\text{voglio mostrare che è < 0.}} - \underbrace{\int_{b'}^b f_x(x) dx}_{\text{voglio mostrare che è < 0.}} \end{aligned}$$

• $\int_{a'}^a f_x(x) dx \leq f_x(a) [a - a']$

• $\int_{b'}^b f_x(x) dx \geq f_x(b) [b - b']$ (vale sia che b' sia prima che dopo la moda)

Allora

$$\int_{a'}^a f_x(x) dx - \int_{b'}^b f_x(x) dx \leq f_x(a) [a - a'] - f_x(b) [b - b']$$

ma $f_x(a) = f_x(b)$ per b)

$$= \underbrace{f_x(a)}_{>0} \left[(b' - a') - (b - a) \right]$$

ma io ho detto che $[a', b']$
ha lunghezza minore di $[a, b]$
quindi est è < 0
in totale.

Quindi di nuovo ho
preso un intervallo + corto
ma ne ho cambiato la confidenza.



Ma noi cercavamo l'IC di lunghezza minima.

$$Z \sim \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \quad \text{cerco } a, b : P(a \leq Z \leq b) = 1 - \alpha$$

Essendo unimodale il più corto è quello per cui:

$$f_Z(a) = f_Z(b) \quad \text{con } a < c < b$$

$$\text{IC era } \left[\bar{X}_n - b \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + a \frac{\sigma}{\sqrt{n}} \right]$$

la cui lunghezza è proporzionale a $b - a$.

Allora scelgo i quantili simmetrici

$$X \sim \Gamma(n, \frac{1}{\beta})$$

(85)

$Q = \frac{\chi^2}{\beta} \sim \Gamma(n, 1)$ è pivot ed è onimodale. per TCL per $n \geq 300$ va a una gaussiana

$$P(a < Q < b) = 1 - \alpha$$

$\min(b - a) \Rightarrow$ poiché è unimodale: $f_X(b) = f_X(a)$
 $\Rightarrow a < x^* < b$.

Allora il mio L è

$$[a \leq Q \leq b] \Leftrightarrow \left[\frac{Q}{b} \leq \beta \leq \frac{Q}{a} \right]$$

Quindi:

$$L(L) = Q \left(\frac{1}{a} - \frac{1}{b} \right)$$

Quindi devo minimizzare $\frac{1}{a} - \frac{1}{b}$.

Il teorema mi risolve il problema

Quando la lunghezza è proporzionale a $b-a$.

Quindi cosa faccio?

Se ho

$$P(a \leq Q \leq b) = 1 - \alpha \Rightarrow b = b(a) \quad (\text{una volta scelto } a, b \text{ è una s.s. funzione}).$$

Minimizzazione la lunghezza che è $\left[\frac{1}{a} - \frac{1}{b} \right] = \left[\frac{1}{a} - \frac{1}{b(a)} \right]$

con vincolo $b(a)$

$$\int_a^b f_Q(x) dx = 1 - \alpha$$

Quindi

$$L = \left[\frac{1}{a} - \frac{1}{b(a)} \right]$$

per trovare il minimo

$$\frac{\partial L}{\partial a} = 0 \Rightarrow 0 = -\frac{1}{a^2} + \frac{b'}{b^2(a)} \Rightarrow \frac{db}{da} = \frac{b^2}{a^2}$$

$$b' = \frac{db}{da}$$

$$\text{derivo } \frac{d}{da} \left[\int_a^b f_Q(x) dx \right] = 0 = f_Q(b) b' - f_Q(a)$$

non dipende da a .

Dovendo il vincolo:

da prima

$$0 = f_Q(b) b' - f_Q(a) = f_Q(b) \frac{b^2}{a^2} - f_Q(a)$$

$$f_Q(b) b^2 = f_Q(a) a^2 \quad \leftarrow \begin{array}{l} \text{i punti che minimizzano} \\ \text{sono quelli che soddisfano} \\ \text{QST.} \end{array}$$

Nel caso la lunghezza

fosse stata $b-a$ sarei tornata ad avere $f(b) = f(a)$

(8) $X_1 \dots X_n \sim U(a, b)$

$\frac{X_n}{\theta} \cong T$ con $F_T(t) = t^n$ per $0 \leq t \leq 1$.

Allora posso usare queste come quantità pivot:

$$[a \leq T \leq b]$$

$$\text{con } b^n - a^n = 1 - \alpha$$

e' un'area e' fdlR in b - FdlR in a.

$$\text{L'IC e'} [a \leq \frac{X_{(n)}}{\theta} \leq b] \Rightarrow \frac{X_{(n)}}{b} \leq \theta \leq \frac{X_{(n)}}{a}$$

$$\text{Ic dlc } f_T(a) a^2 = f_T(b) b^2$$

$$f_T = n t^{n-1}$$

$$\text{Devo imponere che } na^{n-1} a^2 = nb^{n-1} b^2$$

ma non e' possibile XK a deve essere < b.

$$1 - \alpha = b^n - a^n \quad \frac{db}{da}$$
$$0 = nb^{n-1} \cancel{(b)} - na^{n-1}$$

Quindi

$$b' = \frac{a^{n-1}}{b^{n-1}}$$

Quindi

$$\frac{\partial L}{\partial a} = \left[-\frac{1}{a^2} + \frac{b'}{b^2} \right] = \left[-\frac{1}{a^2} + \left(\frac{a^{n-1}}{b^{n-1}} \right) \frac{1}{b^2} \right] = \frac{-b^{n+1} + a^{n+1}}{a^2 b^{n+1}}$$

e sempre < 0 \rightarrow < 0

tanto + decresce a
tanto piu' decresce la lunghezza

Se la lunghezza decrese allora devo far crescere a il + possibile.

Allora anche b.

Alla b non puo' andare piu' so di 1.



Devo scegliere il + grande a $\Rightarrow b = 1$.

Allora ho $1 - \alpha = b^n - a^n = 1 - a^n$

$$a = \sqrt[n]{\alpha}$$

Quindi l'IC di

lunghezza minima

$$\text{sono} \quad \left[X_{(n)} \leq \theta \leq \frac{X_{(n)}}{\sqrt[n]{\alpha}} \right]$$

STATISTICA ASINTOTICA

28 aprile 2015 (87)

n (ampiezza o dimensione del campione) $\rightarrow +\infty$

Quando n è sufficientemente grande da dire che siamo a convergenza all' ∞ ?

$$X_n \xrightarrow{qc} X$$

$$X_n \xrightarrow{P} X \downarrow \text{se cost.}$$

$X_n \xrightarrow{L^2} X$ (convergenza frazioni caratteristiche e anche delle funzioni generatrice dei momenti)

$X_1 \dots X_n$ iid $\mathcal{L}(X_i)$

Se ho una statistica $T = T(\vec{X}) = \frac{1}{n} \sum X_i$

per $n \geq 0$

considereremo una successione di stimatori: la T la vedremo come T_n , X_n dipende dall'ampiezza del campione

$$T_n = \left\{ X_1, \frac{X_1+X_2}{2}, \frac{X_1+X_2+X_3}{3}, \dots \right\}$$

Lo chiameremo stimatore, ma di fatto si intende una successione che dipende da n

Valle le

$$\text{LGN} : \frac{\sum X_i}{n} \xrightarrow{P} E[X_i]$$

$$\text{e TCL} : \sqrt{n} \left(\bar{X}_n - E[X] \right) \xrightarrow{D} N(0, 1)$$

Def una successione di stimatori $W_n = W_n(X_1 \dots X_n)$ è detta **SUCCESSIONE CONSISTENTE** di STIMATORI per θ
SE $\forall \varepsilon > 0$

$$\lim_{n \rightarrow +\infty} P(|W_n - \theta| < \varepsilon) = 1 \equiv W_n \xrightarrow{P} \theta$$

(**CONSISTENZA FORTE**: $W_n \xrightarrow{qc} \theta$)

CONSISTENZA IN L^2 : $W_n \xrightarrow{L^2} \theta$

DEBOLMENTE CONSISTENTE : $W_n \xrightarrow{P} \theta$)

Le implicazioni sono le solite delle convergenze.

ESEMPIO

$X_1 \dots X_n$ iid $N(\theta, 1)$

\bar{X}_n studiamo la consistenza.

\bar{X}_n è consistente per θ ?

(88) • LGN: $\frac{\sum x_i}{n} \xrightarrow{a.s.} \theta$ quindi abbiamo
fonte di consistenza \rightarrow abbiam
consistenza
(e se ho convergenza qc. anche $g\left(\frac{\sum x_i}{n}\right) \xrightarrow{a.s.} g(\theta)$)

- Potremo anche osservare che

$$\begin{aligned} \text{MSE}(\bar{x}_n) &= E[(\bar{x}_n - \theta)^2] = \text{Var}[\bar{x}_n] + \text{bias}^2 = \\ &= \frac{\sigma^2}{n} \rightarrow 0 \Rightarrow \text{Ho anche consistenza in } L^2 \\ &\quad \downarrow \text{consistenza in probabilità} \end{aligned}$$

- Oppure potremo dire:

$$\forall \varepsilon > 0$$

$$P(|\bar{x}_n - \theta| < \varepsilon) = \int_{\theta-\varepsilon}^{\theta+\varepsilon} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{n}{2}(x-\theta)^2\right) dx$$

$$\downarrow$$

$$\bar{x}_n \sim N(\theta, \frac{\sigma^2}{n})$$

chiamiamo $Y = X - \theta$

$$\begin{aligned} &= \int_{-\varepsilon}^{\varepsilon} \sqrt{\frac{n}{2\pi}} \exp\left(-\frac{n}{2}y^2\right) dy = \downarrow t = y\sqrt{n} \\ &= \int_{-\varepsilon\sqrt{n}}^{\varepsilon\sqrt{n}} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt = \\ &\quad \text{distribuzione di una gaussiana standard} \\ &= \Phi(\varepsilon\sqrt{n}) - \Phi(-\varepsilon\sqrt{n}) \end{aligned}$$

Quindi

$$\lim_{n \rightarrow +\infty} P(|\bar{x}_n - \theta| < \varepsilon) = \lim_{n \rightarrow +\infty} [\Phi(\varepsilon\sqrt{n}) - \Phi(-\varepsilon\sqrt{n})] = 1$$

\Rightarrow la media campionaria è
fortemente consistente,
è consistente eol e
consistente in L^2 .

AEEEE

Se so

$MSE_{\theta}(W_n) \rightarrow 0$ $\Rightarrow W_n$ è consistente per θ ?
convergenza in L^2 mi implica quella in probabilità?

Per la DISEGUAGLIANZA di CHEBICHEV

$$P(|W_n - \theta| > \varepsilon) \leq \frac{E[(W_n - \theta)^2]}{\varepsilon^2}$$

Vale $W_n \Rightarrow$ vale anche al limite

$$\lim P(|W_n - \theta| > \varepsilon) \leq \lim_{n \rightarrow +\infty} \frac{E[(W_n - \theta)^2]}{\varepsilon^2}$$

$$\downarrow \quad \Leftarrow \quad \downarrow \text{ se l'MSE} \rightarrow 0 \text{ ast}$$

se l'MSE $\rightarrow 0$ tende a 0 quella dx e quindi quella sx.
(vale senza mettere il quadrato - diseguaglianza di Markov)

OSS

$$MSE_{\theta}(W_n) = \underbrace{\text{Var}[W_n]}_{\downarrow 0} + \underbrace{(E[W_n] - \theta)^2}_{\downarrow 0}$$

allora è consistente

← se riesco a mostrare che entrambe le varianze $\rightarrow 0$ e media $\rightarrow \theta$

Def Se $E[W_n] \rightarrow \theta$ (sommamenti)

si dice che W_n è asintoticamente non distorto

$$S^2 = \frac{1}{n-1} \sum (x_i - \bar{x}_n)^2 \text{ etc } E[S^2] = \sigma^2$$

$$S_0^2 = \frac{1}{n} \sum (x_i - \bar{x}_n)^2 \text{ etc } E[S_0^2] = \left(\frac{n-1}{n}\right) \sigma^2$$

è distorto,
ma per $n \rightarrow +\infty \rightarrow \sigma^2$

è distorta ma è
asintoticamente non distorta.

Crescendo con n la distorsione si riduce.

90) MA POSSIAMO DIRE QUA L'OSA SULLA LEGGE ASINTOTICA W_n ?

Def W_n successione di stimatori

se

$$K_n \text{Var}(W_n) \xrightarrow{n \rightarrow \infty} \tau^2 < +\infty$$

τ^2 viene chiamata varianza limite

Se ho \bar{X}_n ho $\text{Var}[\bar{X}_n] = \frac{\sigma^2}{n}$ se scelgo $K_n = n$

ho che la varianza limite è σ^2

Def W_n successione di stimatori tali che

$$K_n(W_n - \theta) \xrightarrow{d} N(0, \sigma^2)$$

Allora σ^2 è detta VARIANZA ASINTOTICA

Tipicamente si sceglie $K_n = \sqrt{n}$ xKadtra con TLC

Se ho convergenza in legge posso guardare stimatori ≠ valutando la loro varianza asintotica, vorrei che le varianze asintotiche siano piccole

[LGN: $\bar{X}_n \xrightarrow{d} \mu$
TLC: $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N(0, 1)$ Incredibile!]

ESEMPIO (Modelli gerarchici)

$$Y_n | W_n = w_n \sim N(0, w_n + (1-w_n)\sigma_n^2)$$

dove

$$W_n \sim \text{Be}(p_n) \leftarrow \text{lancia una moneta } t_n \text{ con una probabilità di successo}$$

$$\begin{aligned} \text{Var}[Y_n] &= E[\text{Var}[Y_n | W_n]] + \text{Var}[E[Y_n | W_n]] = \\ &= E[W_n + (1-W_n)\sigma_n^2] + 0 = p_n + (1-p_n)\sigma_n^2 \end{aligned}$$

$P(Y_n \leq a)$ (funzione di ripartizione di Y_n)

$$= P(Y_n \leq a | W_n = 1) \cdot P(W_n = 1) + P(Y_n \leq a | W_n = 0)P(W_n = 0)$$

$$= P(z \leq a) p_n + P(z \leq \frac{a}{\sigma_n}) (1-p_n)$$

\uparrow
 $y_n | W_n = 1$ è dunque
gaussiana standard

\uparrow
 $y_n | W_n = 0 \sim N(0, \sigma_n^2)$
qui vuol dire standardizzare.

prendiamo una successione $p_n \rightarrow 1$

$$\text{e } \sigma_n^2 \rightarrow +\infty$$

$$\text{mettendo } (1-p_n)\sigma_n^2 \rightarrow +\infty$$

$$\left(\text{per es: } p_n = 1 - \frac{1}{\sqrt{n}}, \sigma_n = n \right)$$

Quanto vale quindi la varianza limite?

$$\lim (p_n + (1-p_n) \sigma_n^2) = +\infty$$

Quanto vale la varianza asintotica?

$$P(Y_n \leq a) \rightarrow \phi(a) \Rightarrow Y_n \xrightarrow{d} N(0, 1)$$

Non ci sono a priori regole per cui la varianza asintotica sia = alla varianza limite.

MA QUANTO VALE LA VARIANZA ASINTOTICA?

Def una successione di stimatori W_n è asintoticamente efficiente per $\tau(\theta)$ se

$$\sqrt{n} [W_n - \tau(\theta)] \xrightarrow{d} N(0, V(\theta))$$

$$\text{con } V(\theta) = \frac{[\tau'(\theta)]^2}{E_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(x, \theta) \right)^2 \right]} = \frac{[\tau'(\theta)]^2}{I_1(\theta)}$$

^{la varianza asintotica raggiunge il limite di CR}

^{informazione di Fisher}

$$W_n - \theta \text{ è AN}(0, \sigma^2)$$

$$\text{se } \sqrt{n} (W_n - \theta) \xrightarrow{d} N(0, \sigma^2) \Leftrightarrow \text{ASINTOTICAMENTE NORMALE}$$

Per n grande

$$W_n - \theta \approx N(0, \frac{\sigma^2}{n}) \quad \begin{matrix} \text{non posso dire che} \\ \text{converge XK} \\ \text{dipendebbe da n.} \end{matrix}$$

$$\Rightarrow \begin{cases} \text{Per n grande} \\ W_n - \theta \approx N(0, \frac{V(\theta)}{n}) \\ \frac{V(\theta)}{n} = \frac{[\tau'(\theta)]^2}{n I_1(\theta)} = \frac{[\tau'(\theta)]^2}{I_n(\theta)} \end{cases}$$

Uno stimatore è asintoticamente efficiente quando

- È asintoticamente normale
- Varianza asintotica è il limite di CR

TEOREMA: EFFICIENZA ASINTOTICA degli MLE

$$x_1, \dots, x_n \sim f(x, \theta)$$

$\hat{\theta}_{MLE}$ è lo stimatore ML di θ

$$\Rightarrow \sqrt{n} [\tau(\hat{\theta}_{MLE}) - \tau(\theta)] \xrightarrow{d} N(0, V(\theta))$$

Quindi gli stimatori di massima verosimiglianza sono asintoticamente efficienti

^{1 la varianza asintotica è la più piccola possibile XK e minima cr.}

92 Nasconde di dentro c'è anche la consistenza:

OSS L'asintotica normalità \Rightarrow consistenza:

di cui

$$\frac{\sqrt{n} (W_n - \tau(\theta))}{\sigma} \xrightarrow{d} N(0, 1)$$

↑
VARIANZA
ASINTOTICA

Voglio vedere se $W_n \xrightarrow{P} \tau(\theta)$

$$W_n - \tau(\theta) = \frac{\sigma}{\sqrt{n}} \left(\frac{\sqrt{n}}{\sigma} (W_n - \tau(\theta)) \right)$$

↓ ↓
0 $N(0, 1)$

per teorema di Slutsky

$$\xrightarrow{\sigma} 0$$

converge in
legge al prodotto.

Dato che il limite è costante la convergenza in legge a una cost.
implica la convergenza in probabilità

$$\downarrow \\ W_n - \tau(\theta) \xrightarrow{P} 0$$

A.N: $\sqrt{n}(W_n - \theta) \xrightarrow{d} N(0, \sigma^2)$



Consistenza

A. Efficienza = A.N + $\sigma^2 \rightarrow$ limite ce.

Stimatori MLE sono AE

Def ASINTOTICA EFFICIENZA RELATIVA

W_n e V_n tc

$$\sqrt{n} [W_n - \tau(\theta)] \xrightarrow{d} N(0, \sigma_w^2)$$

$$\sqrt{n} [V_n - \tau(\theta)] \xrightarrow{d} N(0, \sigma_v^2)$$

ARE = Asymptotic Relative Efficiency ASYMPTOTIC

di V_n rispetto a W_n è

$$ARE(V_n, W_n) = \frac{\sigma_w^2}{\sigma_v^2}$$

Se è > 1 V_n è + efficiente di W_n

Scegli quello con
varianza asintotica minima

ESEMPIO

$$X_1 \dots X_n \sim \text{NP}(\lambda)$$

$$P(X=0) = e^{-\lambda} = T(\lambda)$$

1) Possibile stimatore è

$$\hat{\tau} = \frac{1}{n} \sum y_i = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{(x_i=0)} \quad Y_i \sim \text{Be}(T(\lambda))$$

2) Altro possibile stimatore

$$\hat{\tau}_1 = e^{-\bar{x}_n} \quad \text{è MLE}$$

\uparrow
x il principio di barianza, VK $\hat{\lambda}_{MLE} = \bar{x}_n$

Un aspetto vince il secondo

$$I_1(\lambda) = \mathbb{E} \left[\left(\frac{\partial}{\partial \lambda} \log f(x, \lambda) \right)^2 \right] = \mathbb{E} \left[\left(\frac{\partial}{\partial \lambda} (-\lambda + x \log \lambda) \right)^2 \right] = \mathbb{E} \left[\frac{1}{\lambda^2} [x - \lambda]^2 \right] = \frac{1}{\lambda}$$

Stimazione 1) è una media campionaria \Rightarrow possa essere t.c.

$$\sqrt{n} (\hat{\tau} - e^{-\lambda}) \xrightarrow{d} N(0, e^{-\lambda}(1-e^{-\lambda}))$$

\uparrow
varianza della
singola bernoulli

Stimatore 2) uso teo sugli MLE:

$$\sqrt{n} (\hat{\tau}_1 - e^{-\lambda}) \xrightarrow{d} N(0, \underbrace{\frac{e^{-2\lambda}}{\lambda} \cdot \lambda}_{\text{calcolato con } \frac{(T'(\theta))^2}{I_\theta(\theta)}}) \quad \text{xK } \hat{\lambda}_{MLE} = \bar{x}_n$$

$$ARE[\hat{\tau}, \hat{\tau}_1] = \frac{\lambda e^{-2\lambda}}{e^{-\lambda}(1-e^{-\lambda})} = \frac{\lambda}{e^\lambda - 1} \quad \text{è decrescente}$$

•

13 maggio 2015

Succesione di stimatori X_n AN
e vogliamo capire se l'asintotica normalità si trasmette se
prendo $g(x_n)$

METODO DELTA

$$Y_n : \sqrt{n} (Y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$$

Prendiamo g con $g'(\theta) \neq 0$. g differentiable con $g''(\theta) \neq 0$.

$$\Rightarrow \sqrt{n} [g(Y_n) - g(\theta)] \xrightarrow{d} N(0, \sigma^2 g'(\theta)^2)$$

(94) Si basa sullo sviluppo di Taylor

$$g(x) = g(\theta) + g'(\theta)(x-\theta) + \epsilon(x-\theta)$$

$$\sqrt{n}(y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$$

$$g(y_n) = g(\theta) + g'(\theta)(y_n - \theta) + \epsilon(y_n - \theta)$$

$$\mathbb{E}[g(y_n)] \approx g(\theta)$$

Asintotica
normalità
consistenza
 $\mathbb{E}[y_n - \theta] = 0$

$$\text{Var}[g(y_n)] = \mathbb{E}[(g(y_n) - g(\theta))^2]$$

$$\approx \mathbb{E}[(g'(\theta))(y_n - \theta)^2] = g''(\theta) \cdot \sigma^2$$

Variante
asintotica

Tutto questo discorso cambia se $g'(\theta) = 0$.

METODO DELTA del SECONDO ORDINE

$$y_n : \sqrt{n}(y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$$

$$g \in C^2$$

$$g'(\theta) = 0$$

$$g''(\theta) \neq 0$$

$$\Rightarrow n[g(y_n) - g(\theta)] \xrightarrow{d} \sigma^2 \frac{g''(\theta)}{2} X_1^2$$

Ancora si basa sullo sviluppo di Taylor.

$$g(x) = g(\theta) + g'(\theta)(x-\theta) + \frac{1}{2} g''(\theta)(x-\theta)^2 + \epsilon(x-\theta)^2$$

$$n[g(y_n) - g(\theta)] = \frac{1}{2} g''(\theta)n(y_n - \theta)^2 + \dots$$

$$\text{io so } \sqrt{n} \frac{y_n - \theta}{\sigma} \xrightarrow{d} N(0, 1)$$

si può dimostrare

$$n \frac{[y_n - \theta]^2}{\sigma^2} \xrightarrow{d} X_1^2 \quad (\text{x è il quadrato di una normale standard})$$

$$n[g(y_n) - g(\theta)] = \frac{\sigma^2}{2} g''(\theta) n \underbrace{\frac{(y_n - \theta)^2}{\sigma^2}}_{X_1^2}$$

ESEMPI

(95)

$$\bullet X_1 \dots X_n \sim \text{Be}(p) \quad \bar{X}_n$$

Via TLC sappiamo $\sqrt{n}(\bar{X}_n - p) \xrightarrow{\text{distr}} N(0, p(1-p))$

un parametro importante per la Bernoulli era l'odds: $\frac{p}{1-p}$
(vale 1 se la moneta è equilibrata)

Come valutare l'odds?

la prima cosa che mi viene in mente è usare $\frac{\bar{X}_n}{1-\bar{X}_n}$,
che è stimatore di massima
verosimiglianza e vale il principio di invarianza.

$$g(x) = \frac{x}{1-x}$$

$$g'(x) = \frac{1-x+x}{(1-x)^2} = \frac{1}{(1-x)^2} \neq 0$$

Possiamo usare il metodo Δ primo.

$$g(\bar{X}_n) = \frac{\bar{X}_n}{1-\bar{X}_n}$$

sia
rl

Delta 1

$$\sqrt{n} \left[\frac{\bar{X}_n}{1-\bar{X}_n} - \frac{p}{1-p} \right] \xrightarrow{\text{distr}} N\left(0, p(1-p) \frac{1}{(1-p)^4}\right) = N\left(0, \frac{p}{(1-p)^3}\right)$$

Se non avessimo usato il metodo delta:

$$\frac{\bar{X}_n}{1-\bar{X}_n} \text{ è MLE di } \frac{p}{1-p} = \tau(p)$$

$$\sqrt{n} \left[\frac{\bar{X}_n}{1-\bar{X}_n} - \frac{p}{1-p} \right] \xrightarrow{\text{distr}} N(0, \sigma^2(p)) = N\left(0, \frac{\tau^2(p)}{I(p)}\right) =$$

$$\text{limite di Cramér-Rao} = N\left(0, \frac{1}{(1-p)^4} \cdot p(1-p)\right)$$

$\frac{\tau'(p)}{I_1(p)}$ facendo calcoli che seguono: ok.

Allora devo calcolare

l'informazione di Fisher × il campione di ampiezza 1.

$$I(p) = E[(\log f(x, p))^2] = E\left[\left(\frac{\partial}{\partial p} (\log p + (1-x)\log(1-p))\right)^2\right] =$$

$$f(x, p) = p^x (1-p)^{1-x} \mathbb{1}_{\{0,1\}}(x)$$

$$= E\left[\left(\frac{x}{p} - \frac{1-x}{1-p}\right)^2\right] = E\left[\left(\frac{(x-p)-(p-x)}{p(1-p)}\right)^2\right] = \frac{1}{p^2(1-p)^2} E[(x-p)^2]$$

$$= \frac{\text{Var}(x)}{p^2(1-p)^2} = \frac{1}{p(1-p)}$$

96) Quindi ho

$$\sqrt{n} \left[\frac{\bar{X}_n}{1-\bar{X}_n} - \frac{p}{1-p} \right] \xrightarrow{\mathcal{L}} N\left(0; \frac{p}{(1-p)^3}\right)$$

OSS

Nbi abbiamo $\frac{\left[\frac{\bar{X}_n}{1-\bar{X}_n} - \frac{p}{1-p} \right] \sqrt{n}}{\sqrt{\frac{p}{(1-p)^3}}}$

$\downarrow e$

$N(0, 1)$

$\sqrt{\frac{\frac{p}{(1-p)^3}}{\frac{\bar{X}_n}{(1-\bar{X}_n)^3}}}$

$\downarrow p$

dalla legge forte dei Grandi Numeri
 $\bar{X}_n \xrightarrow{qc} p$
 quindi converges $f(\bar{X}_n) \xrightarrow{qc} f(p)$
 quindi in probabilità

SLLTZY
 \downarrow
 $\xrightarrow{\mathcal{L}} N(0, 1)$

Quindi di fatto a

qst punto butto via i due $\sqrt{\frac{p}{(1-p)^3}}$
 e ho

$$\frac{\sqrt{n} \left[\frac{\bar{X}_n}{1-\bar{X}_n} - \frac{p}{1-p} \right]}{\sqrt{\frac{\bar{X}_n}{(1-\bar{X}_n)^3}}} \xrightarrow{\mathcal{L}} N(0, 1)$$

Costruire un IC asintotico per $\frac{p}{1-p}$
 cui permette allora di avere una gaussiana

\downarrow

$$IC(ODDS) = \frac{\bar{X}_n}{1-\bar{X}_n} \pm \frac{\sqrt{\frac{\bar{X}_n}{1-\bar{X}_n}}}{\sqrt{n}} \cdot Z_{1-\frac{\alpha}{2}}$$

posso farlo XK

adesso al limite qst è una gaussiana standard.

- $X_1 \dots X_n \sim \text{Be}(p)$ Ora voglio stimare la varianza $p(1-p)$ PF

$g(x) = x(1-x)$ si annulla la derivata prima in $\frac{1}{2}$.

$\forall p \neq \frac{1}{2}$ posso dire

$$g'(x) = 1 - 2x$$

$$\sqrt{n} [\bar{X}_n(1-\bar{X}_n) - p(1-p)] \xrightarrow{\mathcal{L}} N\left(0, p(1-p) \underbrace{(1-2p)^2}_{g'(p)^2}\right)$$

$$\cdot p = \frac{1}{2}$$

mi serve $g''(x) = -2$

$$\begin{aligned} n \underbrace{[\bar{X}_n(1-\bar{X}_n) - p(1-p)]}_{\text{poi}} &\xrightarrow{\mathcal{L}} -2 \cdot \frac{1}{2} \cdot \frac{1}{4} \chi^2_1 \\ &= -\frac{1}{4} \chi^2_1 \end{aligned}$$

Quando se asintoticamente
mi va come una normale o
come una χ^2

e capisco in quale dei
due casi

$$\begin{array}{ccc} g'' & \downarrow & \downarrow \\ \frac{1}{4} & & \frac{1}{4} \chi^2_1 \\ \uparrow & & \uparrow \\ \text{torna che sia } < 0 & & \chi^2_1 \end{array}$$

\bar{X}_n è compreso tra 0 e 1.
A sx ho ora quantità < $\frac{1}{4}$ \Rightarrow converge a qlcs
 < 0 .

$$\text{IC}(p) \quad \left[\bar{X}_n \pm \frac{\sqrt{\bar{X}_n(1-\bar{X}_n)}}{\sqrt{n}} Z_{\frac{1-\alpha}{2}} \right]$$

mi sappiamo

$$\sqrt{n} \frac{(\bar{X}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{\mathcal{L}} N(0, 1)$$

diciamo

$$\sqrt{n} \frac{(\bar{X}_n - p)}{\sqrt{p(1-p)}} \frac{\sqrt{p(1-p)}}{\sqrt{\bar{X}_n(1-\bar{X}_n)}} \xrightarrow{\mathcal{L}} N(0, 1)$$

ASINTOTICAmente posso quindi avere quell'IC,
ma solo ASINTOTICAmente.

(98)

TEOREMA

$$H_0: \theta = \theta_0 \quad vs \quad H_1: \theta \neq \theta_0$$

$$x_1, \dots, x_n \sim f(x, \theta)$$

$\hat{\theta}$ l'MLE (lo assumiamo intero)

Sotto H_0 $-2 \log \lambda(\vec{x}) \xrightarrow{\mathcal{L}} \chi^2_{\nu}$

la statistica della LRT è sempre tra 0 e 1
Quindi i segni sono giusti.

dim

$$-2 \log \lambda(\vec{x}) = -2 \log \left(\frac{L(\theta_0, \vec{x})}{L(\hat{\theta}, \vec{x})} \right) = -2 \ell(\theta_0, \vec{x}) + 2 \ell(\hat{\theta}, \vec{x})$$

↑ si sa solo tutto è raggiunto in $\hat{\theta}$

OSS

$$\ell(\theta_0, \vec{x}) = \ell(\hat{\theta}, \vec{x}) + \ell'(\hat{\theta}, \vec{x})(\hat{\theta} - \theta_0) + \ell''(\hat{\theta}, \vec{x}) \frac{(\hat{\theta} - \theta_0)^2}{2} + \dots$$

ma $\hat{\theta}$ è l'MLE, quindi $\ell'(\hat{\theta}, \vec{x}) = 0$

$$\Rightarrow -2 \log \lambda(\vec{x}) = -2 \ell(\theta_0, \vec{x}) + 2 \ell(\theta_0, \vec{x}) - \ell''(\hat{\theta}, \vec{x})(\theta_0 - \hat{\theta})^2$$

Sotto opportune ip di regolarità:

$$\frac{1}{n} (-\ell''(\hat{\theta}, \vec{x})) \xrightarrow{P} I(\theta_0)$$

ma noi
balziamo
la dim.

$$-2 \log \lambda(\vec{x}) = -\ell''(\hat{\theta}, \vec{x}) (\hat{\theta} - \theta_0)^2 = -\frac{\ell''(\hat{\theta}, \vec{x})}{n I(\theta_0)} \left(\frac{\sqrt{n}(\hat{\theta} - \theta_0)}{\sqrt{1/I(\theta_0)}} \right)^2$$

$\downarrow P$
 $+ 1$

$$(N(0, 1))^2$$

per Slutsky

$$\xrightarrow{\mathcal{L}} + \chi^2_{\nu}$$

ASINTOTICA
NORMALITÀ
STIMATORI
MLE

ROBUSTEZZA

99

\bar{X}_n per il modello gaussiano è molto bello.

$X_1 \dots X_n \sim N(\mu, \sigma^2)$ modello puro e gaussiano.

Se il modello è contaminato, ossia ho una piccola parte di dati che non è gaussiana non ho più varianza di \bar{X}_n . Ma vorrei che \bar{X}_n restasse bello anche se ho piccole perturbazioni o comunque non voglio catastrofi.

La media campionaria è robusta per un solo!! basta un dato per farla sbagliare.

Vorrei misurare la robustezza.

$$X_1 \dots X_n \sim N(\mu, \sigma^2)$$

\bar{X}_n best

$$x_i = (1-y)w + yv_i$$

$$w \sim N(\mu, \sigma^2)$$

$$v_i \sim f \quad E[v] = \theta, \quad \text{Var}[v] = \tau^2$$

$$y \sim \text{Be}(\delta) \quad \text{con } \delta \text{ piccolo}$$

$$x_i = \begin{cases} N(\mu, \sigma^2) & \text{prob } 1-\delta \\ f & \text{prob } \delta \end{cases}$$

$$\text{Var}[x_i] = \text{Var}[\mathbb{E}[x_i|y]] + \mathbb{E}[\text{Var}[x_i|y]]$$

$$\mathbb{E}[\text{Var}[x_i|y]] = \underbrace{\sigma^2}_{\text{Var}(1-y)} \underbrace{(1-\delta)}_{\mathbb{E}[y]} + \underbrace{\tau^2}_{\text{Var}(yv_i)} \underbrace{\delta}_{\mathbb{E}[y]}$$

$$\text{Var}[\mathbb{E}[x_i|y]] = \text{Var}[(1-y)\mu + y\theta] = \text{Var}[y(\theta - \mu)] = \delta(1-\delta)(\theta - \mu)^2$$

$$\Rightarrow \text{Var}[x_i] = (1-\delta)\sigma^2 + \delta\tau^2 + \delta(1-\delta)(\theta - \mu)^2$$

Quindi per il modello contaminato

$$\text{Var}[\bar{X}_n] = (1-\delta) \frac{\sigma^2}{n} + \delta \frac{\tau^2}{n} + \delta(1-\delta)(\theta - \mu)^2$$

↑ tiene conto delle differenze tra le 2 medie

Per piccole deviazioni ($\tau^2 \approx \sigma^2$, $\delta \approx \mu$) ok. Le 2 medie. Ma se ho una Cauchy, che non ha varianza finita, questa cosa mi esplode.

Brunta \bar{X}_n , no robusta!

(100) Per misurare la robustezza

Def BREAKDOWN POINT

$x_{(1)}, \dots, x_{(n)}$ T_n : statistica

T_n ha valore di breakdown b $0 \leq b \leq 1$ se $\forall \varepsilon > 0$

$$\lim_{n \rightarrow \infty} T_n < +\infty$$

$$x_{(\sum_{i=1}^n - b)} \xrightarrow{n \rightarrow \infty}$$

$$\lim_{n \rightarrow \infty} T_n \rightarrow \infty$$

$$x_{(\{1-(b+\varepsilon)\}n)} \xrightarrow{n \rightarrow \infty}$$

\hat{x}_n ha $b=0$, x K basta che un punto vada a ∞
perche' tutto vada a ∞

Mediana ha $b = \frac{1}{2}$, x avere che sia ∞
devo mancare poco piu' delle
meta' dei miei dati a ∞

Teoricamente by def:
b mi dice la "frazione di dati" che devo mandare all' ∞
perche' T_n vada all' ∞

19 maggio

MODELLI LINEARI

19 maggio 2015 (10)

y = risposta (v.a.)

vogliamo modellizzare la ~~risposta~~ di dipendenza di y dai valori di n quantità reali (z_1, \dots, z_n) predittori

Si immagina che siano alleatorie le risposte e i predittori.

Ma in realtà noi penseremo che i predittori siano noti, quantità osservabili (metratura cosa, distanze dal centro...) e vogliamo vedere come cambia la risposta al variazione dei predittori.

Modello

$$Y = \beta_0 + \beta_1 z_1 + \dots + \beta_n z_n + \epsilon$$


$$\vec{\beta} = (\beta_0, \beta_1, \dots, \beta_n)^T$$

è un vettore di parametri incogniti

ϵ è una v.a., $E[\epsilon] = 0$

$Var[\epsilon] = \sigma^2$ costante qualunque sia il predittore

Passo al caso $n = 1$, un solo predittore.



la media sta su qst retta, e poi ho una variabilità che ha media 0

immagino che valga un modello di qst genere:
in realtà devo fare la diagnostica del modello, capire se ha senso che i dati vengano da un modello così

Se leggiamo

$$E[Y|z_1, \dots, z_n] = \beta_0 + \beta_1 z_1 + \dots + \beta_n z_n$$

è comunque il valor medio della y .

La parola lineare è riferita a "lineare in β ", io potrei pensare invece di avere

$$Y = \beta_0 + \beta_1 \sqrt{z_1} + \beta_2 \log z_2 + \epsilon$$

ed è ancora lineare xk la linearità è nei β .

Non è lineare invece

$$Y = \beta_0 \sin(\beta_1 z_1)$$

02) Vogliamo stimare i parametri incogniti e capire se l'adattamento del modello è buono e poi fare previsioni.

Noi abbiamo n osservazioni delle mie variabili, abbiamo $y_1 \dots y_n$ che non sono più iid

MATRICE DISEGNO

$$Z = \begin{bmatrix} 1 & z_{11} & \dots & z_{1n} \\ 1 & z_{21} & \dots & z_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & \dots & z_{nn} \end{bmatrix}$$

$\uparrow \beta_0$ \uparrow metratura \uparrow distanza dal
Modello che 1^o casa, centro 1^o casa,
Genera i 2^o casa, 2^o casa,
dati
 n^o casa.
 n^o casa.

$$\vec{Y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = Z \vec{\beta} + \vec{\epsilon}$$
$$\vec{\epsilon} = \begin{bmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

v.a. a media 0 e varianza σ^2

I parametri incogniti sono 2:

$$\vec{\beta} \in \mathbb{R}^{n+1}$$

$$\vec{\epsilon}, \mathbb{E}[\vec{\epsilon}] = \vec{0} \quad \text{Cov}(\vec{\epsilon}) = \sigma^2 \mathbf{I}^n$$

L'altro parametro incognito è σ^2 .

Parametri incogniti: $\vec{\beta}$ e σ^2

Esempi: la regressione semplice

Come si stimano i parametri incogniti

$$\hat{\vec{\beta}} = (\beta_0 \dots \beta_n)^T, \sigma^2$$

STIME AI MINIMI QUADRATI

$$\hat{\vec{\beta}}_{LS}$$

Io fio $\vec{Y} \in \mathbb{R}^n$. Voglio trovare i β per cui la distanza tra \vec{y} e lo spazio lineare di Z sia minima:

$$\hat{\beta} = \underset{\substack{\vec{b} \in \mathbb{R}^{n+1}}}{\operatorname{ArgMin}} (\vec{y} - Z\vec{b})^T (\vec{y} - Z\vec{b})$$

$$= \underset{\substack{\vec{b} \in \mathbb{R}^{n+1}}}{\operatorname{ArgMin}} \text{de } (\vec{y}, Z\vec{b})$$

il problema è ben posto

(103)

distanza euclidea (sommatoria dei quadrati)

TEOREMA

Supponiamo che Z sia a rango pieno ($n+1 \leq n$)

con 3 osservazioni esiste
ha senso che voglio
scegliere 3 parametri.

1) $\hat{\beta} = (Z^T Z)^{-1} Z^T \vec{y}$ $\hat{\beta}$ è trasformazione lineare delle y .

2) Siano

$$H = Z(Z^T Z^{-1})Z^T \quad \text{hat matrix}$$


$$\hat{y} = Z \hat{\beta} = H \vec{y} \quad \text{fitted values}$$

3) $\hat{\epsilon} = \vec{y} - \hat{y} = (I - H)\vec{y}$ residual

$$\Rightarrow Z^T \hat{\epsilon} = 0 \quad \text{e quindi} \quad \hat{y}^T \hat{\epsilon} = 0 \quad \hat{y} \perp \hat{\epsilon}$$

Prendiamo $n=1$.

$$\vec{y} \in \mathbb{R}^3$$



SOTOSPAZIO LINEARE,
SPAN Z , ($L(Z)$)
possibili combinazioni
lineari delle colonne di Z .
la proiezione di \vec{y} su $\text{Span } Z$,
che è quella che minimizza la distanza euclidea
tra tutte le possibili combinazioni di Z .

$\hat{y} \in \text{SPAN } Z$, e'

la proiezione di \vec{y} su $\text{Span } Z$,

che è quella che minimizza la distanza euclidea
tra tutte le possibili combinazioni di Z .

104 dim

Ho bisogno di una base ortonormale

$\mathcal{L}(z)$ $z^T z$ matrice $(n+1) \times (n+1)$
definita positiva
range(z) = $n+1$

$$z^T z = \sum_{i=1}^{n+1} \lambda_i \vec{e}_i \vec{e}_i^T$$

colonna riga

\vec{e}_i

$(n+1) \times (n+1)$

λ_i sono gli autovalori
 \vec{e}_i sono gli autovettori di $z^T z$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_{n+1} > 0$$

Quindi posso scrivere $z^T z$:

$$(z^T z)^{-1} = \sum_{i=1}^{n+1} \frac{1}{\lambda_i} \vec{e}_i \vec{e}_i^T$$

(tramite decomposizione spettrale)

Chiamo

$$\vec{q}_i = \frac{1}{\sqrt{\lambda_i}} z \vec{e}_i \quad i = 1 \dots n+1$$

$\vec{q}_i \in \mathcal{L}(z) \times \mathbb{K}$ è combinazione delle colonne di z .

Voglio sapere se i \vec{q}_i sono base ortonormale

$$\begin{aligned} \vec{q}_i^T \vec{q}_j &= \frac{1}{\sqrt{\lambda_i \lambda_j}} (\vec{e}_i^T z^T)(z \vec{e}_j) = \frac{1}{\sqrt{\lambda_i \lambda_j}} \vec{e}_i^T \lambda_j \vec{e}_j = \\ &= \sqrt{\frac{\lambda_j}{\lambda_i}} \vec{e}_i^T \vec{e}_j = \\ &= \begin{cases} 1 & i=j \\ 0 & i \neq j \end{cases} \end{aligned}$$

$\lambda_j \vec{e}_j$
 $\times \vec{e}_i$ era
autovettore

Quindi i \vec{q}_i sono base ortonormale per $\mathcal{L}(z)$

Proiezione di y sullo spazio lineare di z minimizza la distanza euclidea:

$$\begin{aligned} \hat{y} &= \sum_{i=1}^{n+1} \vec{q}_i (\vec{q}_i^T \vec{y}) = \sum_{i=1}^{n+1} \frac{1}{\lambda_i} z \vec{e}_i ((z \vec{e}_i)^T \vec{y}) = \\ &= \sum_{i=1}^{n+1} \frac{1}{\lambda_i} z \vec{e}_i \vec{e}_i^T z^T \vec{y} = \\ &= z \left[\sum_{i=1}^{n+1} \frac{1}{\lambda_i} \vec{e}_i \vec{e}_i^T \right] z^T \vec{y}. \end{aligned}$$

Proiezione
ortogonale
di y su $\mathcal{L}(z)$

$$= z (z^T z)^{-1} z^T \hat{y} = \text{proietta } \mathcal{D} \text{ su } \mathcal{L}(z)$$

105

$$= z \hat{\beta}$$

→ stimatore ai minimi quadrati.

Lo stimatore dei $\hat{\beta}$ è $(z^T z)^{-1} z^T \hat{y}$

$$\hat{y} = z \hat{\beta}$$

→ variabili aleatorie.

Poi quando ci sono i dati sono solo i dati

$$\hat{\epsilon} = \vec{y} - \hat{y} = [1 - H] \vec{y} = [1 - (z)(z^T z)^{-1} z^T] \vec{y}$$

ortogonale al sottospazio lineare generato da $z \mathcal{L}(z)$

$$z^T \hat{\epsilon} = z^T [1 - z(z^T z)^{-1} z^T] \vec{y} = z^T \vec{y} - z^T \vec{y} = 0$$

Quindi anche

$$\hat{y}^T \hat{\epsilon} = 0 \quad \text{perché } \hat{y} \in \mathcal{L}(z), \text{ quindi se } \hat{\epsilon} \in \mathcal{L}^{\perp} \text{ lo è anche a } \hat{y}.$$


Ora volti che ho gli stimatori ho anche i valori per le \hat{y}_i .

Supponiamo di avere un solo regressore, regressione lineare semplice.

$$\begin{bmatrix} 1 & z_1 \\ \vdots & \vdots \\ 1 & z_n \end{bmatrix} \quad \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

$$\hat{y} = z \hat{\beta} + \hat{\epsilon}$$

ho dati la cui media sta su una retta e poi ho un errore.




questo è quello che genererebbe il modello.


Ma β_0 e β_1 sono incogniti.
Quindi ho solo i dati.

concretamente
Guardo tutte le possibili combinazioni lineari di z , quindi
Guardo tutte le rette e guardo quale mi minimizza la distanza euclidea:

$$\sum (y_i - \beta_0 - \beta_1 z_{i1})^2$$



106 I valori previsti sono quelli che stanno sulla retta.
E i residui sono $y - \hat{y}$



Quando la matrice non ha rango pieno

$Z(Z^T)$ ha dim $K < n+1$.

$$Z^T Z = \sum_{i=1}^{n+1} \lambda_i \vec{e}_i \vec{e}_i^T \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_K > \lambda_{K+1} = 0 = \dots = \lambda_{n+1}$$

Ho un po' di autovalori che sono 0,
quindi non posso fare il gioco di
primo.

Serve allora la Pseudo inversa

$$(Z^T Z)^{-1} = \sum_{i=1}^K \frac{1}{\lambda_i} \vec{e}_i \vec{e}_i^T \quad \text{Inversa generalizzata di } Z^T Z$$

Prendo allora

$$\vec{q}_i = \frac{1}{\sqrt{\lambda_i}} Z \vec{e}_i \quad i = 1 \dots K$$

Quindi

$$\hat{\beta} = (Z^T Z)^{-1} Z^T \vec{y}$$

VALE ANCHE PER PREDITTORI CATEGORICI

Preditore Categorico:

y_i :

z_i = categorie -

sto esandando il consumo al litro di benzina. Io faccio x 4 categorie di motori.

Nel modello lineare modellizzo la media. Voglio capire come cambia la media al cambiare del modello.
Per ottenere ho il consumo e le categorie - motori 1, 2, 3, 4.

Come posso costruire la mia matrice diretta?

Dov invantone un modo x dare l'"etichetta" del gruppo.

Si inseriscono variabili dummies.

$$\left[\begin{array}{cccc} 1 & \{1\}_{n_1} & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \{1\}_{n_2} & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & 0 & \{1\}_{n_3} \\ & & & 0 \\ & & & \{1\}_{n_4} \end{array} \right] \quad n = n_1 + n_2 + \dots + n_j$$

107

Invisibili dummie: sono 1 se sta in quel gruppo,
0 altrimenti

$$\left[\begin{array}{c} X_{11} \\ \vdots \\ X_{1n_1} \\ X_{21} \\ \vdots \\ X_{2n_2} \\ X_{31} \\ \vdots \\ X_{3n_3} \\ X_{41} \\ \vdots \\ X_{4n_4} \end{array} \right] = \vec{y}$$

Quando scrivo
 $y = \beta_0 + \beta_1 x + \varepsilon$

ottengo

$$j = 1, \dots, n_1$$

$$X_{1j} = \beta_0 + \beta_1 + \varepsilon_j$$

$$j = n_1 + 1, \dots, n_2$$

$$X_{2j} = \beta_0 + \beta_1 + \varepsilon_j$$

la stima sui β mi stime
 come cambia la media
 tra i gruppi.

$$E[X_j] = \beta_0 + \beta_1$$

$$E[X_{2j}] = \beta_0 + \beta_1$$

potrò testare quindi se c'è differenza o meno
 tra i gruppi

Anova: matrice di segue dove il predittore è
 categorico

La matrice non ha pero' rango pieno

$$\hat{\beta}_{LS} = (Z^T Z)^{-1} Z^T \vec{y}$$

È plausibile che i nostri dati siano generati da un modello del genere?

DECOMPOSIZIONE della VARIANZA

$\vec{y} = \hat{\vec{y}} + \vec{\varepsilon}$ è la nostra decomposizione ortogonale

$$\vec{y}^T \vec{y} = \hat{\vec{y}}^T \hat{\vec{y}} + \vec{\varepsilon}^T \vec{\varepsilon}$$

data l'ortogonalità fra y e ε , di fatto è il teo di Pitagora



$$\sum_{i=1}^n y_i^2 = \sum_{i=1}^n \hat{y}_i^2 + \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Vorremmo capire come spezzare la varianza



$$\sum_{i=1}^n y_i^2 - n\bar{y}^2 = \sum_{i=1}^n \hat{y}_i^2 - n\bar{y}^2 + \sum_{i=1}^n \hat{\varepsilon}_i^2$$

$\bar{y} = \frac{1}{n} \sum y_i$
sommatoria degli scarti delle medie al quadrato

qui ho la media delle y , ma non delle \hat{y}
Ma

OSS $n\bar{y} = \sum_{i=1}^n \hat{y}_i = \hat{y}^T \vec{1} = (H\vec{y})^T \vec{1} = (Z(Z^T Z)^{-1} Z^T \vec{y})^T \vec{1} =$

$$(H^T = H)$$

vettore di uno

$$\hookrightarrow = \vec{y}^T Z (Z^T Z)^{-1} Z^T \vec{1} = \vec{y}^T H \vec{1} =$$

$$= \vec{y}^T \vec{1} = \sum_{i=1}^n y_i = n\bar{y}$$

He è il proiettore sul sottospazio lineare generato da Z . $\vec{1} \in \mathcal{L}(Z)$
e $\vec{1}$ è la prima colonna di Z .
Quindi il proiettore lo manda in se stesso

↓
La media delle y è = alla media di \hat{y} .

$$\Rightarrow \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{\epsilon}_i^2$$

369

Formula di decomposizione della varianza

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \text{Sum of Square tot}, SS_{\text{tot}}$$

Somma totale delle y degli scarti dalla media al quadrato

$$\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = SS_{\text{reg}}$$


Somma degli scarti al quadrato della media dei valori interpolati, fittati

$$\sum_{i=1}^n \hat{\epsilon}_i^2 = SS_{\text{res}}$$

Somma dei quadrati dei residui

La formula di decomposizione della varianza
(vale quando in 2 ho gli 1)

$$SS_{\text{tot}} = SS_{\text{reg}} + SS_{\text{res}}$$



La variabilità dei dati intorno alla media
la posso spezzare
in variabilità della media e in
variabilità dell'errore

Coefficiente di determinazione

$$R^2 = \frac{SS_{\text{reg}}}{SS_{\text{tot}}} = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

$$0 \leq R^2 \leq 1$$

$$R^2 = 1 \text{ significa } SS_{\text{res}} = 0, \sum_{i=1}^n \hat{\epsilon}_i^2 = 0$$

Ossia la retta interpole perfettamente i dati, i dati sono già sulla retta.

$$\hat{\epsilon}_i = 0 \quad \forall i$$

110

$$R^2 = 0 \iff SS_{\text{reg}} = 0$$

$$\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = 0$$

$$\hat{y}_i = \bar{y} \quad \forall i$$

la retta
interpolatrice
è una costante

↓

la nostra
previsione è
tutta uguale ed
 \bar{y} = alla media delle y .

È inutile in tal caso fare regressione,
xk sto prediccendo tutto con la media,
tutto costante.
La variabilità del fenomeno è
tutta racchiusa nelle variabilità
dell'errore.

Anche $R^2 = 1$ non ci dice xk botto a 0 l'errore. I dati $\in \mathcal{L}(z)$

Se la variabilità del modello mi consente abbastanza le
variabilità del fenomeno sono carente.
 R^2 deve essere abbastanza alto (60% almeno)

(Posso togliere l'intercetta però $R^2 > 1$,
xk m'iente garantisce più la decomposizione
della varianza)

Come stimare σ^2 ?

AE

TEOREMA

$$\text{Range}(z) = n+1.$$

1) $\mathbb{E}[\hat{\beta}] = \vec{\beta}$ stimatore non distorti $\Rightarrow \hat{\beta} \rightarrow$ stimatore
non distorto di $\vec{\beta}$

$$2) \text{Cov}[\hat{\beta}] = \sigma^2 (z^T z)^{-1}$$

$$3) \mathbb{E}[\hat{\epsilon}] = 0$$

$$4) \text{Cov}[\hat{\epsilon}] = \sigma^2 [I - H]$$

$$5) \mathbb{E}[\hat{\epsilon}^T \hat{\epsilon}] = \sigma^2 (n - n - 1)$$

$$S^2 = \frac{\hat{\epsilon}^T \hat{\epsilon}}{n - n - 1} = \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{n - n - 1}$$

È STIMATORE
non distorto
per σ^2

$$\text{Cov}(\hat{\beta}) = \begin{bmatrix} \text{Var}[\hat{\beta}_0] & \text{Cov}(\hat{\beta}_i, \hat{\beta}_j) \\ & \vdots \\ & \text{Var}[\hat{\beta}_n] \end{bmatrix}$$

Gli elementi diagonali mi danno la varianza di ogni stimatore. Ci interessa anche la covariabilità tra $\hat{\beta}_i$ e $\hat{\beta}_j$.

Se l'inverso di $Z^T Z$ è "bello", quindi ho autovetori abb. grandi quindi l'inversa è stabile (non numero di condizionalmente), sono contento. (Le colonne di $Z^T Z$ sono collineari).

Se le colonne sono molto dipendenti $Z^T Z$ diventa brutta e tutto diventa casuale.

Come trattare se c'è correlazione tra le colonne degli Z ? Scopriremo solo viverello

dim

$$1) E[\hat{\beta}] = E[(Z^T Z)^{-1} Z^T \vec{y}] = (Z^T Z)^{-1} Z^T E[\vec{y}] = (Z^T Z)^{-1} Z^T E[Z\beta + \vec{\epsilon}] = (Z^T Z)^{-1} Z^T Z \underbrace{\beta}_{\text{deterministico}} = \vec{\beta}$$

$$2) \text{Cov}[\hat{\beta}] = ? \quad \text{è come una trasformazione}$$

utilizziamo qst risultato:

$$\vec{y} = A\vec{x}$$

$$\text{Cov}(\vec{y}) = A \text{Cov}(\vec{x}) A^T$$

$\text{Cov}(\vec{\epsilon})$ \times la parte $Z\beta$ deterministica viene maneggiata

$$\text{Cov}[(Z^T Z)^{-1} Z^T \vec{y}] = (Z^T Z)^{-1} Z^T \text{Cov}(\vec{y}) Z (Z^T Z)^{-1} = (Z^T Z)^{-1} Z^T (\sigma^2 \mathbb{I}) Z (Z^T Z)^{-1} = \sigma^2 (Z^T Z)^{-1}$$

$$3) E[\vec{\epsilon}] = E[\vec{y} - \hat{\vec{y}}] = E[(\mathbb{I} - H)\vec{y}] = (\mathbb{I} - H) E[\vec{y}] = (\mathbb{I} - H) Z \vec{\beta} = Z \vec{\beta} - H Z \vec{\beta} = Z \vec{\beta} - Z (Z^T Z)^{-1} Z^T Z \vec{\beta} = 0$$

infatti H proietta sulla spazio di Z quindi un'aspetto che $H Z \vec{\beta} = Z \vec{\beta}$

$$4) \text{Cov}(\vec{\epsilon}) = \text{Cov}((\mathbb{I} - H)\vec{y}) = (1 - H) \text{Cov}(\vec{y}) (1 - H)^T = (1 - H) \sigma^2 (1 - H)^T = \sigma^2 (1 - H)^2 = \sigma^2 (1 - H)$$

proprietà dei proiettori
Sono idempotenti:
 $(1 - H)^2 = 1 - H$
 $H^2 = H$.

1 - H proietta sull'ortogonale di $\text{im}(Z)$.
Vale $(1 - H)^T = 1 - H$
e $H^T = H$ (autoaggiunto simmetrico)

la matrice $\mathbf{1} - \mathbf{H}$ non ha rango pieno n
proietta su un sottospazio di dimensione $n - R - 1$

$$5) \mathbb{E}[\vec{\varepsilon}^T \hat{\vec{\varepsilon}}] = \mathbb{E}\left[\sum_{i=1}^n \hat{\varepsilon}_i^2\right] = \mathbb{E}[\text{tr}(\vec{\varepsilon} \vec{\varepsilon}^T)] =$$

$$= \mathbb{E}[\text{tr}((\mathbf{1} - \mathbf{H}) \vec{Y} ((\mathbf{1} - \mathbf{H}) \vec{Y})^T)] -$$

| —
no
matrice
 $n \times n$ con
 $\vec{\varepsilon}^T$ la diagonale
 $\hat{\varepsilon}_i^2$

OSS

$$(\mathbf{1} - \mathbf{H}) \vec{Y} = (\mathbf{1} - \mathbf{H})(z\vec{\beta} + \vec{\varepsilon}) = (\mathbf{1} - \mathbf{H})\vec{\varepsilon}$$

$\mathbf{1} - \mathbf{H}$ proietta $z\vec{\beta}$ + $\vec{\varepsilon}$
 $\ni (\mathbf{1} - \mathbf{H})z = 0$

$$= \mathbb{E}[\text{tr}((\mathbf{1} - \mathbf{H})\vec{\varepsilon} \vec{\varepsilon}^T (\mathbf{1} - \mathbf{H}))]$$

abbiamo visto $(\mathbf{1} - \mathbf{H})^T = (\mathbf{1} - \mathbf{H})$

$\text{tr}(AB) = \text{tr}(BA)$

permuto

$$\downarrow = \mathbb{E}[\text{tr}((\mathbf{1} - \mathbf{H})\vec{\varepsilon} \vec{\varepsilon}^T)] = \text{tr}(\mathbf{1} - \mathbf{H}) \underbrace{\mathbb{E}[\vec{\varepsilon} \vec{\varepsilon}^T]}_{\text{la media di } \vec{\varepsilon} \text{ è } 0, \text{ quindi qst è la matrice variancovarianza}} =$$

$\text{cov}(\vec{\varepsilon}) = \sigma^2 \mathbf{I}$

la traccia di un proiezione
è la dimensione dello spazio in cui proietto
(sarebbe $\text{tr}(\mathbf{1}) - \underbrace{\text{tr}(z(z^T z)^{-1} z^T)}_{\text{tr}(\mathbf{1} \text{ dimensione } n+1)}$)
 $= \sigma^2(n - R - 1)$

Quindi ottengo che

$$\mathbb{E}[\hat{\varepsilon}_i^2] = \sigma^2(n - R - 1)$$

\Downarrow

$$S^2 = \frac{\sum \hat{\varepsilon}_i^2}{n - R - 1}$$

$\hat{\varepsilon}^T$ è stima
non distorta per σ^2
è l' SS res.

AE

TEOREMA GAUSS-MARKOV

113

ASSUMIAMO CHE Z ABBAI RANGO = $R+1$.

$$\forall \vec{c} \in \mathbb{R}^{n+1}$$

$\vec{c}^T \hat{\vec{\beta}}$ è lo stimatore di varianza minima per stimare $\vec{c}^T \vec{\beta}$ tra tutti gli stimatori che soddisfano

- a) non distorti per $\vec{c}^T \hat{\vec{\beta}}$
- b) sono della formula

$$a_1 Y_1 + a_2 Y_2 + \dots + a_n Y_n \quad (\text{lineari in } \vec{Y})$$

ovvero

$\vec{c}^T \hat{\vec{\beta}}$ è il BUE = Best Linear Unbiased Estimator

- Quello a varianza minima nella classe degli stimatori lineari in Y non distorti

Se assumiamo che $\vec{\epsilon} \sim N(\vec{0}, \sigma^2 \mathbb{I}_n)$

$$\vec{Y} = Z \vec{\beta} + \vec{\epsilon} \Rightarrow \vec{Y} \sim N_n(Z \vec{\beta}, \sigma^2 \mathbb{I}_n)$$

ndimensionale

26 maggio 2015

Assumiamo

$$\vec{\epsilon} \sim N_n(\vec{0}, \sigma^2 \mathbb{I})$$

la struttura lineare del modello fa in modo che \vec{Y} sia normale e quindi anche $\hat{\vec{\beta}}$, XK è funzione di Y .

TEOREMA

Rango (Z) = $R+1$ (rango pieno)

$$\vec{\epsilon} \sim N(0, \sigma^2 \mathbb{I})$$

- 1) $\hat{\vec{\beta}}$ e $\hat{\sigma}^2 = \frac{\hat{\vec{\epsilon}}^T \hat{\vec{\epsilon}}}{n} = \frac{n-R-1}{n} S^2$ sono gli stimatori MLE di $\vec{\beta}$ e σ^2
- 2) $\hat{\vec{\beta}} \sim N_{R+1}(\vec{\beta}, \sigma^2 (Z^T Z)^{-1})$ abbiamo in più la gaussiuità
- 3) $\hat{\vec{\epsilon}} \sim N_n(\vec{0}, \sigma^2 (I - H))$ ($I - H$) ha rango $n - R - 1$, in \mathbb{R}^n non ha rango pieno, si può ancora scrivere con le f. canoni.
- 4) $\hat{\vec{\beta}} \perp \hat{\vec{\epsilon}}$ indipendenza stocastica
- 5) $n \hat{\sigma}^2 = \hat{\vec{\epsilon}}^T \hat{\vec{\epsilon}} = n \sum \hat{\epsilon}_i^2 \sim \sigma^2 \cdot \chi^2(n - R - 1)$

(14) Posso così fare mai più solo inferenza parametrica.

dim

1) ^{sol} Gaussian Wicksell

$$\vec{\epsilon} \sim N(\vec{0}, \sigma^2 \mathbb{I})$$

$$\vec{y} \sim N(z\vec{\beta}, \sigma^2 \mathbb{I})$$

Quindi scrivendone la verosimiglianza

$$L(\beta, \sigma^2, \vec{y}) = \dots \exp(-\sum (y_i - z_i \vec{\beta})^2)$$

massimizzare la verosimiglianza in β

non dà il minimo questa distanza euclidea.

la struttura di una gaussiana

$$\hat{\vec{\beta}}_{ML} = \hat{\vec{\beta}}_{LS}$$

Viene distorto, ma non si stoppa XK nel caso gaussiano
la ML non ci dà la media campionaria.

2... 4)

$$\begin{bmatrix} \vec{\beta} \\ \vec{\epsilon} \end{bmatrix} \begin{cases} R+1 \\ n \end{cases}$$

$$\in \mathbb{R}^{n+R+1}$$

$$\begin{bmatrix} \vec{\beta} \\ \vec{\epsilon} \end{bmatrix} = \begin{bmatrix} (Z^T Z)^{-1} Z^T \\ \mathbb{I} - Z(Z^T Z)^{-1} Z^T \end{bmatrix} \vec{y}$$

\vec{y} è gaussiano
 XK
 $\vec{\epsilon} \sim N(0, \sigma^2 \mathbb{I})$

$$\vec{y} \sim N_n(z\vec{\beta}, \sigma^2 \mathbb{I})$$

quindi

$$\begin{bmatrix} \vec{\beta} \\ \vec{\epsilon} \end{bmatrix} \text{ è gaussiano } XK \text{ trasformazione
lineare di } \vec{y} \sim N$$

$$\begin{pmatrix} \hat{\beta} \\ \hat{\epsilon} \end{pmatrix} \sim N_{n+R+1} \begin{pmatrix} \vec{\beta} \\ 0 \\ ; \end{pmatrix} ; \sigma^2 \otimes$$

↑
fa senso le medie dei $\hat{\beta}$ e $\hat{\epsilon}$

*) matrice varianza covarianza.

$$\begin{bmatrix} (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \\ \mathbf{I} - \mathbf{H} \end{bmatrix} \quad \text{devo moltipicarla} \\ \times \text{il suo trasposto}$$

vive matrice a blocchi

$$\begin{bmatrix} (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T [(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T]^T & (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T (\mathbf{I} - \mathbf{H})^T \\ \hline (\mathbf{I} - \mathbf{H}) [(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T]^T & (\mathbf{I} - \mathbf{H}) (\mathbf{I} - \mathbf{H})^T \end{bmatrix} =$$

$$= \begin{bmatrix} (\mathbf{Z}^T \mathbf{Z})^{-1} & 0 \\ 0 & \mathbf{I} - \mathbf{H} \end{bmatrix} \quad \text{xK } (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \text{ sta} \\ \text{nel sottospazio lineare,} \\ \text{e } \mathbf{I} - \mathbf{H} \text{ proietta} \\ \text{nell'ortogonale.}$$

questi già li sapevamo,
xK la matrice di varianza e covarianza
di $\hat{\beta}$ ed $\hat{\epsilon}$ era così

Quindi

$$\begin{pmatrix} \hat{\beta} \\ \hat{\epsilon} \end{pmatrix} \sim N_{n+R+1} \begin{pmatrix} \vec{\beta} \\ 0 \\ ; \end{pmatrix} ; \sigma^2 \left[\begin{array}{cc} (\mathbf{Z}^T \mathbf{Z})^{-1} & 0 \\ 0 & \mathbf{I} - \mathbf{H} \end{array} \right]$$

dato che sono nel
mondo gaussiano le
correlazioni ci dà
l'indipendenza, quindi
 $\hat{\beta} \perp \hat{\epsilon}$.

(110) 5) $\vec{x} \sim N(\vec{\mu}, \Sigma) \Rightarrow$ si può dimostrare che
 $(\vec{x} - \vec{\mu})^T \Sigma^{-1} (\vec{x} - \vec{\mu}) \sim \chi^2(n)$

\uparrow
di fatto mi
diventa la
Somma di Gauss i cui
al quadrato.

\uparrow
i gradi di
libertà sono
il range della
matrice Σ

$$\hat{\vec{\epsilon}}^T \underbrace{(\mathbb{I} - H)^{-1}}_{\text{metto la}} \frac{1}{\sigma^2} \vec{\epsilon} \sim \chi^2(n - k + 1)$$

\uparrow
i gradi di
libertà sono
il vero range

\downarrow
di $\sigma^2 (\mathbb{I} - H) \times K$
pst non è invertibile

Io so $H \hat{\vec{\epsilon}} = 0$ x ortogonalità.

Quindi $\hat{\vec{\epsilon}} = (\mathbb{I} - H) \hat{\vec{\epsilon}}$ xK $\mathbb{I} - H$ proiettare
vive $\hat{\vec{\epsilon}}$.

Quindi posso scrivere

$$\hat{\vec{\epsilon}}^T (\mathbb{I} - H)^{-1} (\mathbb{I} - H) \hat{\vec{\epsilon}} \frac{1}{\sigma^2} \sim \chi^2(n - R - 1)$$



$$\hat{\vec{\epsilon}}^T \hat{\vec{\epsilon}} \sim \sigma^2 \chi^2(n - R - 1)$$

Corollario

$$\frac{1}{\sigma^2} (\hat{\vec{\beta}} - \vec{\beta})^T (Z^T Z) (\hat{\vec{\beta}} - \vec{\beta}) \sim \chi^2(R + 1)$$

\uparrow
sto togliendo a un
vettore gaussiano la sua media

\uparrow
matrice variazione
colossalità

\uparrow
qualità
pivot

$$\frac{n \hat{\sigma}^2}{\sigma^2} \sim \chi^2(n - R - 1)$$

mi permetteranno di scrivere IIC.
ma è incognito sia β che σ^2 , quindi dovrò usare
entrambi i risultati. Il vantaggio è che le due quantità
sono indipendenti.

Per fare inferenza su β devo togliere il α^2 .

Potrei fare il quoziente.

Il quoziente di due χ^2 indipendenti è una Fisher.

$$\frac{\chi^2(p)/p}{\chi^2(q)/q} \sim F(p, q)$$

Allora sfruttando questo risultato:

$$\frac{(\hat{\beta} - \vec{\beta})^T (z^T z) (\hat{\beta} - \vec{\beta}) \cdot \frac{1}{R+1}}{n \hat{\alpha}^2 \cdot \frac{1}{n-R-1}} \sim F(R+1, n-R-1)$$

quantità pivotale

$$S^2 = \frac{\hat{\epsilon}^T \hat{\epsilon}}{n-R-1} \Rightarrow \text{stimatori uali distorti di } \alpha^2$$

Per costruire un IC di livello $1-\alpha$ per i miei $\hat{\beta}$
Regioni di confidenza

$$R(1-\alpha) = \left\{ \hat{\beta} \in \mathbb{R}^{R+1} : \frac{(\hat{\beta} - \vec{\beta})^T (z^T z) (\hat{\beta} - \vec{\beta})}{(R+1) S^2} \leq F_{1-\alpha}^{(R+1, n-R-1)} \right\}$$

ellissoidale
centrato in $\hat{\beta}$
in cui ~~sono~~
gli assi sono
detti dagli
autovettori e autovettori $(z^T z)^{-1}$

stima
puntuale di S^2

↓
più la matrice disegno è fatta male $(z^T z)$ mai
condizionata, tanto più l'ellissoidale degenera.

Ogni volta che perco da una gaussiana
un punto memorio di $(z^T z)^{-1}$

(118) Spesso si costruiscono gli intervalli di confidenza uno alla volta,
"ONE AT A TIME"

$$\hat{\beta}_j \sim N(\beta_j; \sigma^2 \underbrace{\text{diag}_j(z^T z)^{-1}}_{\text{elemento } j\text{-esimo sulla diagonale}})$$

→ elemento j -esimo sulla diagonale.

Posso stimare con s^2 e avere una t.

Quindi gli tc che si creano sono marginali:

$$\hat{\beta}_j \pm \sqrt{s^2 \text{diag}_j(z^T z)^{-1}} t_{1-\frac{\alpha}{2}}(n-(R+1))$$

In R avranno lo stesso di

$$\hat{\beta}_j \quad \text{per una statistica test} \begin{cases} \hat{\beta}_j = 0 \\ \hat{\beta}_j \neq 0 \end{cases}$$

Così deudo marginalmente se
quella covariata entra nel modello oppure no.
Posso fare selezione delle covariate, sotto del modello.

Però così perdo la matrice di libertà.

E prima avevo una Fisher, qui ho ora t.
Cosa centra?

Si ha che ~~le quantile~~ i quantili della t al quadrato
sono quelli delle Fisher a 1 gall.

Abbiamo un legame stretto tra
livello, p-value e regione di accettazione.

TEST sui Parametri

C matrice $p \times (R+4)$

Posso fare test qualsiasi del tipo (mi chiamo sia

$\beta_j = 0$ vs $\beta_j \neq 0$

che
combinazioni dei β_j)

$H_0: C\vec{\beta} = 0$

$H_1: C\vec{\beta} \neq 0$

$$c\hat{\beta} \sim N_p(\vec{0}, \sigma^2 C(z^T z)^{-1} C)$$

\uparrow non posso usarlo come statistica test
perché C è σ^2 .

Ma posso ricondorarmi che

infatti $\frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-R-1)$

$$\frac{(c\hat{\beta})^T (C(z^T z)^{-1} C)^{-1} c\hat{\beta}}{s^2 p} \sim F(p, n-R-1)$$

\uparrow gal del numeratore
(no range di C pieno)
dovrei dividere
per $n\hat{\sigma}^2$ ma ho messo qst

Rifiuto H_0 se qst è $> F_{1-\alpha}$:

$$(c\hat{\beta})^T (C(z^T z)^{-1} C)^{-1} c\hat{\beta} \geq s^2 p F_{1-\alpha}(p, n-R-1)$$

con $n=1$
mi ritrovo il t-test.

Con questo posso fare tutti i controlli sui vari coefficienti

Vogliamo dire se un blocco
di coefficienti è 0 o no x considerare blocchi di covariate.

$$H_1 \quad \beta_{n-p+2} = \dots = \beta_{n+p} = 0 \quad \text{almeno uno } \neq 0$$

$\hookrightarrow \beta_j = 0$ prendere la covariata associata.
Se è 0 non mi interessa se prenderlo o no
la covariata nel modello.
Se le covariate fossero tra loro + mai avrei problema
di ordine, ma se non lo sono no.

$$Z = \begin{bmatrix} z_1 & | & z_2 \\ \downarrow & & \downarrow \\ n & & n \\ R+p & & p \end{bmatrix} \quad Y = Z \hat{\beta} + \hat{\epsilon} \quad \text{modello globale}$$

$$Y = z_1 \hat{\beta} + \hat{\epsilon} \quad \text{modello ridotto.}$$

Se z_2 mi dà le covariate = 0, ho che i due modelli
sono uguali. Quindi prenderei il secondo.

A20

Prendo allora

$$SS_{res}(z) = \hat{\epsilon}^T \hat{\epsilon}$$

$$SS_{res}(z_1) = \hat{\epsilon}_1^T \hat{\epsilon}_1 \quad (\text{usati con } z_1)$$

mi aspetto che

$$SS_{res}(z_1) - SS_{res}(z)$$

$\underbrace{\phantom{SS_{res}(z_1)}}$ nel modello ridotto
è più grande

$\underbrace{\phantom{SS_{res}(z)}}$ ho ammesso
il modello,
quindi solo meno residuo

RIFIUTO Ho, RIFIUTO IL FATTO CHE non misurano i pezzi in z_2 SE
QUESTA QUANTITÀ È "GRANDE"

se la DIFFERENZA È piccola invece AGGIORNERE z_2 NON MI
DA TROPPE INFO IN PIÙ.

Si può dimostrare che

$$\frac{SS_{res}(z_1) - SS_{res}(z)}{S^2 p} \sim F(p, n-p)$$

\uparrow
dimensione
delle colonne che stiamo
togliendo

Rifiuto se è + grande del quantile di ordine $1-\alpha$
delle Fisher.

Testare l'ipotesi che: β_j legato alle variabili di z_2
 $H_0: \beta_j = 0$ o almeno ora $\neq 0$.

Se $p=1$ torna al test $\beta_j = 0$

$\beta_j \neq 0$

PREVISIONE

(121)

Supponiamo di fissare $\vec{z}_0 = (1, z_{01}, \dots, z_{0n})^T$ generico valore delle nostre covariate.

So che


$$\mathbb{E}[y|\vec{z}_0] = \vec{z}_0^T \hat{\beta}$$

Io so che lo stimatore blie di $\vec{\beta}$ è $\hat{\beta}$.

la stima che faccio

$$\mathbb{E}[y_0] = \vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}^T y = \vec{z}_0^T \hat{\beta}$$

misbina la media della mia risposta in z_0



se metto dentro z_0

valuto la

risposta

che ho in z_0 ,

proprio quella sulla retta.

Errore

$$\vec{\epsilon} \sim N_n(0, \sigma^2 \mathbb{I})$$

$$\vec{z}_0^T \hat{\beta} \sim N_1(\vec{z}_0^T \vec{\beta}, \sigma^2 \vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}_0)$$

è indipendente da

$$\frac{n \hat{\epsilon}^T \hat{\epsilon}}{\sigma^2} \sim \chi^2(n-R-1)$$

Allora è come fare il test sulla
media di una gaussiana avremo incognita.

Quindi

$$\frac{\vec{z}_0^T (\hat{\beta} - \vec{\beta})}{\sqrt{\vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}_0}} \cdot \frac{1}{\sqrt{s^2}} \sim t(n-R-1)$$

Quindi IC di livello $1-\alpha$ per $\mathbb{E}[y|\vec{z}_0] = \vec{z}_0^T \vec{\beta}$
è $\vec{z}_0^T \hat{\beta} \pm s \sqrt{\vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}_0} t_{\frac{n-R-1}{2}}$

IC per la media

stimopuntuale della media

stima intervallo, tenere
conto delle variabilità



IC X
val media
reg. livello
1^n anno

$$(122) \quad \vec{Y} = \vec{Z}\vec{\beta} + \vec{\epsilon}$$

27 maggio 2015

assumiamo che i nostri dati vengano da un modello lineare.

Vogliamo costruire delle quantità x fare prefezione;

faccio un vettore di covariate \vec{z}_0 e la corrispondenza di questo

ho $y_0 = \vec{z}_0^T \vec{\beta} + \varepsilon_0$, risposta che ho assunto
quel set di covariate.

(gli z_0 possono mai essere presenti nel mio dataset)

$$E[y_0] = \vec{z}_0^T \vec{\beta}$$

Possiamo costruire degli IC di per la media di y_0 ?

$\vec{z}_0^T \hat{\vec{\beta}}$ è una v.a., posso calcolarne la varianza
per costruire IC

$$\frac{\vec{z}_0^T (\hat{\vec{\beta}} - \vec{\beta})}{\sqrt{\vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}_0}} \sim \frac{1}{\sqrt{s^2}} t(n-R-1)$$

Quantità pivot.

Posso inventare rispetto a $\vec{z}_0^T \vec{\beta}$,
che è quello di cui voglio stimare

Quindi

IC di livello $1-\alpha$ per $\vec{z}_0^T \vec{\beta}$ (che è la media di y_0)

$$\vec{z}_0^T \hat{\vec{\beta}} \pm S \sqrt{\vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}_0} t_{1-\frac{\alpha}{2}}(n-R-1)$$

$\vec{z}_0^T \hat{\vec{\beta}}$ è la trasformazione di uno gaussiano

$$\vec{z}_0^T \hat{\vec{\beta}} \sim N(\vec{z}_0^T \vec{\beta}, \sigma^2 \vec{z}_0^T (\vec{z}^T \vec{z})^{-1} \vec{z}_0) (*)$$

ma so anche $\hat{\vec{\beta}}^T \hat{\vec{\beta}} = \sum_i x_k^T x_k$

$$\frac{n \hat{\vec{\beta}}^T \hat{\vec{\beta}}}{\sigma^2} \sim \chi^2(n-R-1)$$

$$e^{10 \text{ ho}} \quad \frac{z}{\sqrt{x^2(p)/p}} \sim t(p)$$

(123)

Allora standardizzo (*) e divido per quello sotto
e sono a posto

[Weisberg - Applied linear regression ha i calcoli fatti in modo esplicito]
Avevamo tratto che la varianza, in regressione semplice,
era


$$S^2 \left(\frac{1}{n} + \frac{(z_0 - \bar{z})^2}{S_{zz}} \right)$$

$$\text{con } S_{zz} = \sum_{i=1}^n (z_i - \bar{z})^2$$

qui altri scritti
 $\sum_{i=1}^n (z_i - \bar{z})^2$


la variabilità dipende da
 S^2 (variabilità errore)

e $(z_0 - \bar{z})^2$: distanza del punto rispetto al
bou centro (media campionaria \bar{z})



la variabilità aumenta
tanto più mi allontano
dal bou centro
più mi allontano dal bou centro
dei dati su cui ho costruito il modello,
tanto più la mia stima è soggetta a errore:
PROBLEMA dell'ESTRAZIONE

Se ho per es



Se riesco ad
analizzare
solo questi

non capisco da
quale dei due
modelli sono
generati i miei
dati

(124) Problema in cui si è sbagliata la stima ha fatto esplodere
il space shuttle

Vogli i tener conto della variabilità × poter fare la previsione.

$$Y_0 = \vec{z}_0^\top \hat{\beta} + \varepsilon_0 \quad \varepsilon_0 \sim N(0, \sigma^2)$$

e ipotizziamo $\varepsilon_0 \perp \hat{\varepsilon}$
 $Y_0 \perp \hat{\beta}$, XK sono indip. da $\hat{\varepsilon}$

Allora si può dimostrare che

$$Y_0 - \vec{z}_0^\top \hat{\beta} \sim N(0, \sigma^2 (1 + \vec{z}_0^\top (\vec{z}^\top \vec{z})^{-1} \vec{z}_0))$$

\uparrow
ha anche
variabilità dei $\hat{\beta}$.

$$\frac{n\sigma^2}{\sigma^2} \sim \chi^2(n-R-1)$$

Quindi

$$P\left[Y_0 \in (\vec{z}_0^\top \hat{\beta} \pm t_{1-\alpha/2}(n-R-1) \sqrt{s^2 (1 + \vec{z}_0^\top (\vec{z}^\top \vec{z})^{-1} \vec{z}_0)})\right] = 1-\alpha$$

\uparrow
in cui intervallo
la massa di $Y_0 \in (1-\alpha)$

Intervallo di Previsione.

Ha un s^2 in più sotto radice rispetto a prima.
E' quindi un pochino più ampio di quello di prima
XK contiene un errore in più, ho anche
un pezzo di variabilità dovuta all'errore.

In R: confidence
prevision a scende di
quale dei due
voglio costruire.


Se posso $\vec{z}_0 = \vec{z}_i$ che è uno dei miei dati
vedo le bontà del mio modello,
vedo $\hat{y} - y$, quindi di fatto grande i residui.

Le Z sono deterministiche.

Ci sono due tipi di matrici diverse:

MATRICE Sperimentale e Osservazionale

Data set in cui studio l'altezza delle figlie rispetto a quelli delle madri



studio
osservazionale

Io sperimentatore statistico non
ho controllo su quello che succede

Boglio capire se la produzione del temulo aumenta
all'avventare del concime.
Sono io che sperimentalmente posso "disegnare" il
mio modello



Se osservo correlazione tra X e Y, al crescere di X cresce Y,
nell'osservazionale non posso arrivare a una
conclusione di causalità,
mentre nello sperimentale, a parità di tutte le cose
tra cui il concimante, posso avere un rapporto
di causalità.

Fattore di confondimento: le acque che portano i bambini
Si era dimostrato che più acque ci sono in un paese
e più c'erano bambini. Il fattore di confondimento
era che quod usciva il bambino si scaldava l'acqua
nel cammino e le acque facevano il vizio sui coniugi

(126) Supponiamo di avere

$$\vec{Y} = \vec{Z} \vec{\beta} + \varepsilon$$

cos'è

$$\beta_j?$$

fissate tutte le altre covariate $\vec{z}_1, \dots, \vec{z}_{j-1}, \vec{z}_{j+1}, \dots, \vec{z}_n$
 β_j rappresenta l'aumento
nello medio della risposta all'aumentare
di una unità di z_j .

$$\beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_3 z_3$$

se ho

$$\beta_0 + \beta_1 z_1 + \beta_2 (z_2 + 1) + \beta_3 z_3$$

all'aumentare di 1 elemento delle
covariate z_2 mi dà di quanto aumenta la
medio all'aumentare unitario delle covariate.

Dobbiamo sempre stare attenti alle unità di misura
e gli ordinini di grandezza.

bisogna avere matrici disegno che corrispondono a
covariate categgoriche.
Come si scrive la matrice disegno in un caso del genere?

MODELLO ANOVA

$$\vec{Y} = \begin{bmatrix} x_{11} \\ \vdots \\ x_{1m} \\ x_{21} \\ \vdots \\ x_{2n_2} \\ \vdots \\ x_{gng} \end{bmatrix}$$

x_{ij} rispetta $i=1 \dots n_j$
nel gruppo $j=1 \dots g$

Prendiamo lo stesso numero di
osservazioni uguali x
risparmiare geno
 $n_1 = n_2 = \dots = n_g = m$.

$$\vec{Z} = \begin{bmatrix} x_{11} \\ \vdots \\ x_{1n_1} \\ x_{21} \\ \vdots \\ x_{2n_2} \\ \vdots \\ x_{gng} \end{bmatrix}$$

ci verrebbe da sorire

(127)

$$\begin{bmatrix} n_1 & \begin{bmatrix} 1 & 1 & 0 & 0 \\ \vdots & \ddots & \ddots & \vdots \\ 1 & 1 & 0 & 0 \end{bmatrix} \\ \hline n_2 & \begin{bmatrix} \cdot & 0 & 1 & 0 \\ \cdot & \ddots & \ddots & \vdots \\ \cdot & \cdot & 1 & 0 \end{bmatrix} \\ \hline n_3 & \begin{bmatrix} \cdot & 0 & 1 & \dots \\ \cdot & \ddots & \ddots & \vdots \\ 1 & 0 & 0 & 0 \end{bmatrix} \end{bmatrix}$$

Quando faccio la stima ottengo

$$\mathbb{E}[X_{j|i}] = \beta_0 + \beta_j \quad \text{tanto l'errore è a media nulla}$$

Ma la matrice è mal condizionata.
Ne voglio scrivere una uscile ma invertibile.

Allora immagino

$$\mathbb{E}[X_{ij}] = \underbrace{\mu_j}_{\text{medio che dipende dal gruppo}} = \mu + (\mu_j - \mu) = \mu + \tau_j; \quad \boxed{\sum \tau_j = 0}$$

medio globale + discostamento dalla media globale

L'ANOVA:
 se mi metto nell'ip di gaussianità guardo se la
 media è la stessa nel gruppo oppure no.
 Un'anova con 2gruppi è come fare un t-test di confronto.
 Se $Von[\bar{\epsilon}] = \alpha^2$ significa che la varianza delle medie
 la stessa.

$$x_{ij} \sim N(\mu_i, \sigma^2)$$

$X_{ij} \sim N(\mu_i, \sigma^2)$
 fissa capire quindi se il consumo medio delle macchine
 cambia o no al cambiare della marca.

$$Z = \begin{bmatrix} 1 & \cdots & n_1 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 0 \\ 1 & \cdots & n_g \\ \vdots & \ddots & \vdots \\ 1 & \cdots & 0 \end{bmatrix} \quad B_g$$

$$\begin{aligned}\mathbb{E}[X_{i1}] &= \beta_0 + \beta_1 & t_1 = \beta_1 \\ \mathbb{E}[X_{i2}] &= \beta_0 + \beta_2 & t_2 = \beta_2 \dots \\ \mathbb{E}[X_{ig}] &= \beta_0 + \beta_1 - \beta_2 - \beta_g - 1\end{aligned}$$

matrice con 9 colonne,
una in meno rispetto a prima.

$$X = \begin{bmatrix} x_{11} & \dots \\ x_{12} & \dots \\ x_{1g} & \dots \end{bmatrix}$$

(128)

Brother

Fiat

Toyota

 $\frac{1 \text{ km}}{\text{e}}$ $\frac{10 \text{ km}}{\text{e}}$

...

passo un dataset

la matrice di seguito toglie una categoria, di solito la 1^a in ordine alfabetico.

le stime prodotte diventano

$\hat{\beta}_0$ media nel primo gruppo (BMW)

$\hat{\beta}_1$ = differenza tra consumo Fiat e BMW

\Rightarrow Per ricostruire il consumo delle Fiat: $\hat{\beta}_1 - \hat{\beta}_0$

Cosa fa l'ANOVA?

Produce un p-value

Matrice

$$z_1 \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$$

$$\hat{\bar{y}} = \bar{X}_{..} = \frac{1}{mg} \sum_{i,j} x_{ij}$$

osservazione
 = x tutto
 media su
 gli gruppi che
 osservazione

Nella matrice di seguito 2

si ha

$$\hat{\bar{y}} = \begin{bmatrix} \bar{X}_{1.} & \{ m \\ \bar{X}_{2.} & \{ m \\ \vdots & \\ \bar{X}_{g.} & \{ m \end{bmatrix} \text{ media sul primo Gruppo}$$

\uparrow prendendo in realtà x ogni
gruppo la media
del gruppo.

Voglia un'opinione se c'è differenza tra il modello
completo e quelli delle singole.

TEST:

$$\frac{SS_{res}(z_1) - SS_{res}(z)}{SS_{res}(z) \cdot (g-1)} = \frac{\sum_{i=1}^g \sum_{j=1}^m (x_{ij} - \bar{X}_{i.})^2 - \sum_{i=1}^g \sum_{j=1}^m (x_{ij} - \bar{X}_{..})^2}{(g-1) \sum_{i=1}^g \sum_{j=1}^m (x_{ij} - \bar{X}_{i.})^2}$$

$\underbrace{(mg-g)}$
 gal di $SS(z)$
 range z,
 che ha $g-1$ colonne

Se i no prevedo

$$\sum_{i=1}^g \sum_{j=1}^m (x_{ij} - \bar{x}_{..})^2$$

e faccio $\pm \bar{x}_i$.

i doppi prodotti si annullano.
Quindi ho

$$\sum_{i=1}^g \sum_{j=1}^m (\bar{x}_{ij} - \bar{x}_{i..})^2 + m \sum_{i=1}^g (\bar{x}_{i..} - \bar{x}_{..})^2$$

per la linearità della media.

variabilità nei gruppi:

SS_b

↑
within

Per ogni gruppo grande
lo scarto con le medie.

SS_b between
grande la
variabilità tra i gruppi.
Grande la variabilità
tra la media del
gruppo e la media totale

$$\Rightarrow \frac{g-1}{\text{d.o.f. totale}} = \frac{\overline{SS_b / (g-1)}}{\overline{SS_w / ((g-1)m)}} = \frac{MS_b}{MS_w}$$

mean square

Rifiutare H_0 (medie tutte uguali)
vs H_1 (c'è una media +)

$H_0 : T_1 = \dots = T_g = 0$

$H_1 : \text{almeno un } T_i \neq 0$


(ed essendo a $\Sigma = 0$
in realtà saremo almeno due +0)

Rifiuto se

$$\frac{SS_b / (g-1)}{SS_w / ((g-1)m)} > F_{1-\alpha} (g-1; (g-1)m)$$

cioè se è troppo grande.

Poiché la variabilità ~~delle medie~~
mi porta a parlare delle medie?



sappiamo
abbiamo
tutti le stesse medie

media diversa

SS between: distanza della media del gruppo rispetto a quell totale
Nel primo caso qst deve essere confrontabile con le
variabilità nel gruppo.

Nel secondo caso invece la variabilità delle medie è
molto + grande della variabilità nel gruppo singolo.

ANALISI della VARIANZA \rightarrow

Caso particolare di modello lineare

La decomposizione della varianza vale ancora e dà
risposta al fatto che le medie sono uguali o \neq .

P-value piccolo \Rightarrow i modelli sono \neq ,
l' $\vec{\beta}$ del gruppo è importante

Nel caso generale

$SS_b \in SS_{reg}$

$$\vec{Y} = z \vec{\beta} + \vec{\varepsilon}$$

$$\vec{\varepsilon} \sim N_h(0, \sigma^2 I)$$

28 maggio 2015

Diagnistica del Modello

Noi assumiamo che i dati siano generati da $\vec{Y} = z \vec{\beta} + \vec{\varepsilon}$.
Ma è vero che i dati sono generati da questo modello?
E se il modello non va bene devo buttare via tutto?

DIAGNOSTICA: controllo delle assunzioni fatte sul modello che
genera i dati.

MODELLO TEORICO

$$\mathbb{E}[\vec{\varepsilon}] = 0$$

$$\text{Cov}(\vec{\varepsilon}) = \sigma^2 \mathbf{I}$$

$$\vec{\varepsilon} \sim N_n(\vec{0}, \sigma^2 \mathbf{I})$$

MODELLO ADATTATO

$$\mathbb{E}[\hat{\vec{\varepsilon}}] = 0$$

$$\text{Cov}(\hat{\vec{\varepsilon}}) = \sigma^2 (\mathbf{I} - \mathbf{H})$$

$$\hat{\vec{\varepsilon}} \sim N_n(\vec{0}, \sigma^2 (\mathbf{I} - \mathbf{H}))$$

OSSERVAZIONE

La varianza di ε_i : $\text{Var}[\varepsilon_i] = \sigma^2$

$$\text{Var}[\hat{\varepsilon}_i] = \sigma^2 (1 - h_{ii})$$

h_{ii} = leverage dell'i-esimo dato
se è troppo alto ($h_{ii} = 1$)
avremo somma del
residuo nello
→ il modello viene fatto passare
da lì,
il punto sta facendo leva x
spingere il modello adattato a
passare x quel punto, e non va bene.

RESIDUI STUDENTIZZATI


$$\hat{\varepsilon}_i^* = \frac{\hat{\varepsilon}_i}{\sqrt{s^2(1-h_{ii})}} \leftarrow \text{studiabilità } \hat{\varepsilon}_i$$

Grafi o plot di diagnostica

Lo STEP 1 è fare un plot dei dati: se vuoi guardi i dati
ma poi sapere se stai x andare sulla strada giusta.

plot(z, y)
per s

\leftarrow se hai tanti predittori
fa gli scatterplot di tutte le combinazioni
nelle varie variabili




Guarda le variabili
che spiegano in
modo lineare la
risposta

- (132) STEP 2: GRAFICI dei RESIDUI
- Scatterplot ($\hat{\epsilon}_i, \hat{z}_{ik}$)
 - ↑ preditore
 - Scatterplot ($\hat{\epsilon}_i, y_i$)
 - ↑ previsti
 - Scatterplot ($\hat{\epsilon}_i, i$)


Quale che sia il grafico dei residui,
vogliamo vedere una nube caotica rispetto all'asse o



non vogliamo vedere



nei




xx la
vulnerabilità nel
nostro modello
eno = x tutte
eteroschedasticità

Se usiamo residui
standardizzati li abbiamo già riscalati
e non sono più dello stesso ordine di grandezza

STEP 3: QQ PLOT

modo grafico per capire se i residui sono normali.



se è gaussiano
valori da retta e sono ||

$$X \sim N(\mu, \sigma^2)$$

$$x_\alpha = \mu + \sigma z_\alpha$$

↑
quantili empirici

TEST di SHAPIRO:

H_0 : dati gaussiani

H_1 : dati non gaussiani

Vorremmo avere p-value alto,
non avere evidenze a rifutare H_0

VALUTAZIONE R²


look for Anscombe quartet in internet

4 dataset x far vedere che quando i punti da solo non servono a niente.

le stime di \hat{B}_0 e \hat{B}_1 sono sempre valide, e anche $R^2 \approx 65\%$.

Quindi direi che non vanno bene tutti.


In realtà voglio a vedere i dati e ho



→ il plot dei residui dovrebbe essere
e avrei capito che non andava bene



dati perfettamente
allineati tranne uno, che fa effetto luce
e quindi non va bene



Anche qui da un effetto perciò il modello
de la stessa retta,
ma ovviamente non va bene.

Ponti ANOMALI rispetto alla nostra osservazione dei dati: outlier

Noi sappiamo

$$\hat{y} = Z \hat{B} = H \vec{y}$$

Allora

$$\hat{y}_i = \sum_{j=1}^n h_{ij} y_j = h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j$$

$$H \mathbb{1} = \mathbb{1}$$

$\mathbb{1} = \sum_{j=1}^n h_{ij} \Rightarrow$ la somma degli elementi di h ci dà 1.

$\sum_{i=1}^n h_{ii} = \text{tr}(H) = n+1 \leftarrow$ la traccia di un proiettore
ci dà il range.

Se h_{ii} è alto sto forzando il modello a
passare x quell punto, quindi lo forzo a ignorare
di più il resto.

Supponiamo che tutti i punti hanno \geq lo stesso leverage.

$$\Rightarrow h_{ii} \approx \frac{n+1}{n}$$

Regola del pollice: plotto gli h_{ii} e metto una retta $\frac{2(n+1)}{n}$



e i punti sopra questa
retta sono quelli
influenti

(134) Se ho una linea molto alta, oppure ho un outlier, cosa faccio?
 Dipende da cosa sto studiando.
 Devo vedere se è la colpa del dato sia un errore.
 Magari è un errore di input, e il dataset che è sbagliato

$$R^2 = \frac{SS_{err}}{SS_{tot}}$$

~~Se stiamo confrontando un R^2 a pochi predittori, SS_{err} diminuisce,~~

R^2 aumenta se continuo ad aggiungere predittori, ma non se migliora il modello.

$$R^2_{adj} \Rightarrow 1 - R^2_{adj} = \frac{SS_{err}/(n-R-1)}{SS_{tot}/(n-1)}$$

Si può dimostrare

$$R^2_{adj} = 1 - \frac{SS_{err}/(n-R-1)}{SS_{tot}/(n-1)} = 1 - (1-R^2) \frac{n-1}{n-R-1}$$



Realizzo l' R^2

per il numero di predittori ↑

Allo statistico non importa l'interpolazione, ma interessa che i miei dati siano generati da un modello + errore

Press: $\sum \hat{e}_i / 1-h_{ii}$ lo voglio basso

Cp Mallows

} indici che si possono andare a vedere.

Esempio: dataset con n predittori

y, z

Quanti sotto modelli potrei costruire?

Per $K = 1 \dots n$ ho $\binom{n}{K}$ possibili sottomodelli

Sceglio per ogni K un modello migliore M^*
 e poi confronto i modelli tra i vari K ,
 e selezio il modello finale.

Ma è una procedura computazionalmente troppo onerosa.

Metodi Step wise

135

1) FORWARD SELECTION:

aggiunge iterativa mente un predittore alla volta.
(parto da modello 0)

2) BACKWARD SELECTION:

modello con tutti i predittori e ne togliono alla volta

3) BOTH

fai un po' di backward e un po' di forward

$$M_K(i), M_{K'}(i+1)$$

i: indice dell'iterazione

pensiamo $K' > K$.

Posso fare il test F:

$$F = \frac{SS_{res}(M_K(i)) - SS_{res}(M_{K'}(i+1))}{(K' - K) \left(\frac{SS_{res}(M_{K'}(i+1))}{n - K' - 1} \right)}$$

l'SS_{res} è grande
quando ho un modello
con meno predittori.

Mi ferisco quando ho un pessimo abit. $\hat{\imath}$ gole modello $M_{K'}$

S posso usare 1, 2 o 3 ma ottengo lo stesso modello;
ma è che mi portano entrambe il modello ottimo.
Dobbiamo sempre pensare a cose sto mettendo o togliendo
dal modello

OUTLIERS

punti strani, diversi



$$Q_3 - Q_1 = 1QR$$

confini a $Q_3 + 1,5 IQR$

$$Q_1 - 1,5 IQR$$

e i punti fuori da queste sono outlier, di coda,
ma stavano vicino ai dati.

Alcuni outlier vengono generati con prob. bassa.

$$Z \sim N(0, 1)$$

Posso calcolare: $Z_{0,25}, Z_{0,75}, \dots l = Z_{0,25} - 1,5 IQR$

IQR

$$U = Z_{0,75} + 1,5 IQR$$

e poi $P(Z > U) + P(Z < l)$ probabilità di generare
 ≈ 0.007 dati che sono
outlier.

Q36) Ho probabilità non trascurabile che il modello generi un outlier.

Ottore

(1- δ) genero da $Z \sim N(0,1)$

e con prob. ε perturbo $x \sim \varepsilon(z)$

Qst dati sono outlier in un senso che siano generati da un altro modello.

y_i sia un outlier.

$$\left\{ \begin{array}{l} y_j = \vec{z}_j^T \vec{\beta} + \varepsilon_j \quad j \neq i \\ y_i = \vec{z}_i^T \vec{\beta} + \delta + \varepsilon_i \end{array} \right.$$

~ modello con intercetta \neq .

Posso testare la probabilità che y_i sia un outlier?

$$U = [u_1 \dots u_n]^T \text{ con } u_j = 0 \quad j \neq i \\ u_i = 1$$

↑ vettore che mi indica le nza del potenziale outlier.

$$\tilde{z} = [z, U]$$

$$\tilde{y} = \tilde{z}^T \vec{\beta}' + \tilde{\varepsilon} \quad \vec{\beta}' = (\beta_0, \beta_1, \dots, \beta_n, \delta)$$

So fare test marginali x dare se un certo coeff è $= 0$ o $\neq 0$.

$$H_0: \delta = 0$$

$$H_1: \delta \neq 0$$

$$\left(\hat{\beta}_{n+1}' - 0 \right) / \sqrt{s^2 \text{diag}_{n+2}(\tilde{z}^T \tilde{z})^{-1}} \stackrel{\text{sotto } H_0}{\sim} t(n-n+2)$$

stimatore
del δ vera media sotto H_0 \uparrow bieibilità

Costruisco il mio test

e posso concludere se

Accettò $H_0 \Rightarrow y_i$ non è outlier

Rifiutò $H_0 \Rightarrow y_i$ è un outlier.

DATI INFUENTI

$Z_{(i)}$ matrice a cui tolgo la riga i . Quindi ho matrice $(n-1) \times (n+1)$.

Posso fare $\overset{[(n+1) \times (n+1)]}{\overbrace{[Z_{(i)}^T Z_{(i)}]}} \overset{[(n-1) \times (n+1)]}{\overbrace{[Z_{(i)}^T Y_{(i)}]}} \Rightarrow [Z_{(i)}^T Z_{(i)}]^{-1} Z_{(i)}^T Y_{(i)}$

$$\hat{\beta}_{(i)} = (Z_{(i)}^T Z_{(i)})^{-1} Z_{(i)}^T \overset{(n+1) \times (n-1)}{Y_{(i)}} \quad \text{dimensionalmente viene un vettore } n+1.$$

Quindi ho le mie due stime. $\overset{(n+1) \times (n-1)}{\overbrace{Z_{(i)}^T Z_{(i)}}} \overset{(n-1)}{\overbrace{Z_{(i)}^T Y_{(i)}}}$

Se il punto i è influente

$\hat{\beta}$ e $\hat{\beta}_{(i)}$ devono essere vicini.

$\hat{\beta}$ è la stima dei parametri.

Come misuro la distanza?

DISTANZA di COOK (1977)

$$D_i = \sqrt{\frac{(\hat{\beta}_{(i)} - \hat{\beta})^T Z^T Z (\hat{\beta}_{(i)} - \hat{\beta})}{(n+1) s^2}}$$

È fatto su tutto il modello

Non misura la distanza euclidea \rightarrow deve tenere conto delle struttura di varianza e cov, che di fatto è tenuta conto in $\frac{Z^T Z}{s^2}$

Si costruiscono le linee di livello di D_i .

Perché è questa la distanza giusta?


Se noi prendiamo x gaussiano

Abbiamo la distanza di Mahalanobis


$$(\vec{x} - \vec{\mu})^T \bar{Z}^{-1} (\vec{x} - \vec{\mu}) \text{ è definita positiva}$$

\rightarrow ha forma quadratica

\uparrow è la distanza \rightarrow distanza induce la distanza giusta \times calcolare la realizzazione di un dato e la media.



due punti su qst hanno distanza + da qst



I punti + distanti dalla media

Sono quelli che stanno a 4σ , ma sono $+\infty$ e $-\infty$.

I punti a 4σ sono tutti alla stessa distanza dalla loro media.

Devo tener conto della matrice varianza-covarianza


29 maggio 2015

(138)

$$\hat{\beta} \sim N(\vec{\beta}, \sigma^2(z^T z)^{-1})$$

L'inverso della matrice $(z^T z)^{-1}$ è $\frac{z^T z}{\sigma^2}$,
ma σ^2 non lo so quindi lo stimo.

Posso costruirne le curve di livello e definire un punto
non influente se è fuori da una data curva di livello



OSSERVAZIONE

$$\hat{Y} = z \hat{\beta}$$

$$D_i = \frac{(\vec{Y}_{(i)} - \hat{Y})^T (\vec{Y}_{(i)} - \hat{Y})}{(R+1) S^2}$$

distanza quasi euclidea
tra le osservazioni, ma ho S^2 a denominatore.

È di fatto la
distanza di Mahalanobis sulle $\vec{Y}_{(i)}$.

Si può dimostrare che

$$D_i = \frac{1}{(R+1)} R_i^2 \left(\frac{h_{ii}}{1-h_{ii}} \right)$$

$$R_i = \frac{\hat{\epsilon}_i}{S\sqrt{1-h_{ii}}} \quad \begin{matrix} \text{residuo} \\ \text{s標準izzato} \end{matrix}$$

Ponti con alto leverage
fanno esplodere questa distanza e quindi
fanno esplodere la distanza di Cook \Rightarrow punti influenti.

E SE i TEST di DIAGNOSTICA NON FUNZIONA?

Rifatti zero il modello e riproviamo.

ETEROSCEDASTICITÀ dei RESIDUI

$$\sum \quad \sum$$

Si risolvono con
REGRESSIONE CON PESI

- TRASFORMAZIONI di Y
cambiano la varianza.

$$\vec{y} = z\vec{\beta} + \vec{\epsilon}$$

trasformo xK scopo che ϵ sia $\perp \text{ il gusto}$.
Allora faccio
 $\sqrt{y} = z\vec{\beta} + \vec{\epsilon}$, e vedo che va bene.
Poi mi devo ricordare

Succintamente:

- SE $\text{Var}[\epsilon_i] \propto E[y_i]$

prendi una trasformazione tipo $\sqrt{y} \circ \sqrt{y+1}$

- SE $\text{Var}[\epsilon_i] \propto E[y_i]^2 \Rightarrow \log(y)$

- SE $\text{Var}[\epsilon_i] \propto E[y_i]^4 \Rightarrow \frac{1}{y} \circ \frac{1}{y+1}$

la trasformazione

logaritmica viene spesso usata se
la variabilità delle y è molto grande

Supponiamo di avere scoperto

$$\vec{y} = z\vec{\beta} + \vec{\epsilon}$$

$$\text{Cov}(\vec{\epsilon}) = \sigma^2 \Sigma$$

Supponiamo

$$\exists c \text{ tc } c^T c = c c^T = \Sigma^{-1} \quad (\text{pseudo radice quadrata di } \Sigma^{-1})$$

$$\begin{aligned} \text{Var}(c\vec{\epsilon}) &= c \text{Var}(\vec{\epsilon}) c^T = \\ &= c \sigma^2 \Sigma c^T = \sigma^2 c \underbrace{(cc^T)^{-1}}_{(\Sigma^{-1})^{-1}} c^T = \sigma^2 \mathbf{1} \end{aligned}$$

Così riporto

ad avere uno
comportamento omoschedastico
 $c\vec{\epsilon}$.

Applico c a tutto il mio modello:

$$c\vec{y} = cz\vec{\beta} + c\vec{\epsilon}$$

$$\text{Se chiamo } \vec{w} = c\vec{y}, \vec{z} = cz, \vec{\epsilon}' = c\vec{\epsilon}$$

ho modello delle forme

$$\vec{w} = \vec{z}\vec{\beta} + \vec{\epsilon}' \quad \text{così } \vec{\epsilon}' \text{ rispetta l'omoschedasticità.}$$

? Se fatto il modello

$$\hat{\vec{\beta}} = (\vec{z}^T \vec{z})^{-1} \vec{z}^T \vec{w} = ((cz)^T cz)^{-1} (cz)^T (c\vec{y}) = \\ = (\vec{z}^T \underbrace{c^T c}_{\Sigma^{-1}} \vec{z})^{-1} (\vec{z}^T c^T c) \vec{y} = (\vec{z}^T \Sigma^{-1} \vec{z})^{-1} \vec{z}^T \vec{y}$$

$$= (Z^T \Sigma^{-1} Z)^{-1} (Z^T Z^{-1} Y)$$

regressione con peso,
peso dato da Σ^{-1}

Se Σ ha struttura diagonale, tipo

$$\Sigma = \begin{pmatrix} \frac{1}{n_1} & & \\ & \ddots & \\ & & \frac{1}{n_h} \end{pmatrix} \quad \text{se per es. } Y \text{ vengono da una media di determinate misure.}$$

Y pancerà media autoretica di misure con lo stesso σ^2 dallo stesso campione.

Se le numerosità sono t , la variabilità di pesatura è in modo inversamente proporzionale alla numerosità.

$$\tilde{Z} = \begin{bmatrix} \sqrt{n_1} & \sqrt{n_1} z_{11} \\ \vdots & \vdots \\ \sqrt{n_h} & \sqrt{n_h} z_{h1} \end{bmatrix} \quad \tilde{W} = \begin{bmatrix} \sqrt{n_1} y_1 \\ \vdots \\ \sqrt{n_h} y_n \end{bmatrix}$$

peso le mie osservazioni \Rightarrow regressione con peso.

Anche nel caso di violazione di normalità:

RESIDUI NON GAUSSIANI

mi saltano gli intervalli di confidenza,
 β non sono più gaussiani

Si risolve con

- TRASFORMAZIONE BOX-COX

$$\begin{cases} y' = \frac{y^\lambda - 1}{\lambda} & \lambda \neq 0 \\ y' = \log y & \lambda = 0 \end{cases}$$

trasformo o con polinomio o con logaritmo.

Come scelgo il λ ?

λ : massima vero simiglianza gaussiana di y'

max mi massimizza la gaussianità dei dati.

$\lambda = 0.47$ non funziona a 0.47, ma la $N\bar{Y}$,
e poi il dato fa devi raccapone,
se $\lambda \approx 1$ significa che i dati erano già abbastanza
gaussiani.

Così rischio di perdere l'omoschedasticità dei dati

Di solito se non ho residui gaussiani o non ho schedasticità
trasformando y si risolvono i problemi

REGRESSIONE POLINOMIALE (o con iterazione)

$$\hat{y} = \beta_0 + \beta_1 \vec{z}_1 + \beta_2 \vec{z}_1^2 + \dots + \beta_d \vec{z}_d + \vec{\epsilon}$$

\uparrow se per y è superficie e z_2 radice.
oppure XK dedi che può servire

È ancora un modello lineare in cui la matrice di design
sono:

$$\begin{bmatrix} 1 & z_1 & z_1^2 & \dots \end{bmatrix}$$

Se va solo su con d posso interpolare \approx qualsiasi nuvola di punti.
I dati elevandoli al quadrato, cubo etc. esplodono,
se già ho range \neq di $z_1, z_2 \dots$

A volte si tiene conto delle iterazioni.

Supponiamo di avere

$$y = \beta_0 + \beta_1 \vec{z}_1 + \beta_2 \vec{z}_2 + \beta_{21} \vec{z}_1^2 + \beta_{22} \vec{z}_2^2 + \beta_{12} \vec{z}_1 \cdot \vec{z}_2 + \vec{\epsilon}$$

Ho aggiunto un'interazione
tra le due variabili

$\underbrace{\quad}_{\text{termine di}} \text{interazione.}$

Per capire il significato

supponiamo di guardare un modello semplificato

$$\vec{y} = \beta_0 + \beta_1 \vec{z}_1 + \beta_2 \vec{z}_2 + \beta_{12} \vec{z}_1 \vec{z}_2 + \vec{\epsilon}$$

i test mi dicono che i termini al quadrato
posso buttarli via, ma non posso buttare via

$$\beta_{12} \vec{z}_1 \vec{z}_2$$

142

FISSIAMO

 z_2 e spostiamo z_1 in z_1+1 .

$$Y = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_{12} z_1 z_2$$

ora trasformo

$$Y' = \beta_0 + \beta_1(z_1+1) + \beta_2 z_2 + \beta_{12}(z_1+1)z_2$$

$$\Delta Y = \cancel{\beta_0 + \beta_1(z_1)} + \beta_1 + \beta_2 z_2 + \cancel{\beta_{12} z_1 z_2} + \cancel{\beta_{12} z_2} - \\ - \cancel{\beta_0} - \cancel{\beta_1 z_1} - \cancel{\beta_2 z_2} - \cancel{\beta_{12} z_2} =$$

$$= \beta_1 + \beta_{12} z_2$$

\Rightarrow SE C'È INTERAZIONE l'incremento che si ha nelle risposte dipende da z_2 .

È ancora più facile vedere questa interazione quando una delle due variabili è categorica.

$$Y = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \beta_{12} z_1 z_2$$

Sia z_2 una variabile categorica.

$$z_2 = \begin{cases} 0 & \text{maschio} \\ 1 & \text{femmina} \end{cases}$$


 \downarrow

$$Y_i^M = \beta_0 + \beta_1 z_1$$


$$Y_i^F = \beta_0 + \beta_1 z_1 + \beta_2 + \beta_{12} z_1 = (\beta_0 + \beta_2) + (\beta_1 + \beta_{12}) z_1$$

 \Rightarrow se $\beta_2 = 0$,

$$\begin{aligned} \text{se } \beta_2 = 0 \\ \beta_{12} \neq 0 \end{aligned}$$


Se $\beta_2 = \beta_{12} = 0$ i due modelli coincidono

$$\begin{aligned} \text{Se } \beta_2 \neq 0 \\ \beta_{12} \neq 0 \end{aligned}$$




$$\beta_2 \neq 0$$

$$\beta_{12} = 0$$



Se ho una covariata continua e una categorica
quod faccio lo scatterplot faccio x per gruppo 1, o x gruppo 2



se i modelli sono $\approx //$
mi aspetto che l'interazione sia 0.

L'aumento di varianza di un'unità della mia risposta media
dipende da β_2 se ho pendente +,
sono quelle delle cose nette che sto guardando che mi dicono
di quanto sale



Se la matrice Z è altamente collineare

$(Z^T Z)^{-1}$ mi diventa un problema.

Sia XK è instabile

Sia XK la varianabilità dei $\hat{\beta}$ diventa enorme.

Sia XK la varianabilità dei $\hat{\beta}$ diventa enorme.

Come mi accorgo che ho collinearità?

VIF

$z_1 \dots z_n$

Quanto il fattore $\hat{\beta}_j$ forza la varianza

faccio un modello dove

$$z_j = \gamma_0 + \gamma_1 z_1 + \dots + \gamma_{j-1} z_{j-1} + \gamma_{j+1} z_{j+1} + \dots + \gamma_r z_r$$

$$VIF_j = \frac{1}{1 - R_j^2}$$

R_j^2

Ancora a calcolare il VIF posso vedere quale è
più correlata alle altre.

(44) FARE RIDGE-REGRESSION

mettuta nelle tecniche di Shrinkage (restringimento)

Centriamo i dati \Rightarrow prevediamo le coordinate centrate $\Rightarrow \beta_0 = 0$

$$\hat{\vec{\beta}}_{LS} = \underset{\vec{b}}{\operatorname{Argmin}} \|\vec{y} - \vec{z}\vec{b}\|^2 = \operatorname{Argmin}_{\vec{b}} (\vec{y} - \vec{z}\vec{b})^T (\vec{y} - \vec{z}\vec{b})$$

Fare Ridge Regression: mettere un vincolo, una penalizzazione
e se non altrimenti le stime possano esplodere.

$$\left\{ \begin{array}{l} \operatorname{Argmin}_{\vec{b}} \|\vec{y} - \vec{z}\vec{b}\|_2^2 \\ \|\vec{b}\|_2^2 \leq s \end{array} \right. \Leftrightarrow \text{vincolo}$$

\downarrow
Ho problema di minimo vincolato

Formulazione lagrangiana

$$L(\vec{\beta}, \lambda) = (\vec{y} - \vec{z}\vec{\beta})^T (\vec{y} - \vec{z}\vec{\beta}) + \lambda (\vec{\beta}^T \vec{\beta} - s)$$

$$\left\{ \begin{array}{l} \frac{\partial L}{\partial \vec{\beta}} = -2\vec{z}^T (\vec{y} - \vec{z}\vec{\beta}) + \lambda \vec{\beta} = 0 \\ \frac{\partial L}{\partial \lambda} = \vec{\beta}^T \vec{\beta} - s = 0 \end{array} \right.$$

$$\left\{ \begin{array}{l} \vec{z}^T \vec{y} = (\vec{z}^T \vec{z} + \lambda \mathbb{I}) \vec{\beta} \end{array} \right.$$

$$\left\{ \begin{array}{l} \vec{\beta}^T \vec{\beta} = s \end{array} \right.$$

trovo un λ per cui è soddisfatto $\vec{\beta}^T \vec{\beta} = s$.

fissato s

$$\left\{ \begin{array}{l} \hat{\vec{\beta}}_{RE} = (\vec{z}^T \vec{z} + \lambda \mathbb{I})^{-1} \vec{z}^T \vec{y} \end{array} \right.$$

$$\left\{ \begin{array}{l} \|\hat{\vec{\beta}}_{RE}\| \leq s \end{array} \right.$$


Così ho risolto i miei problemi,

$\text{X}^T \text{X} + \lambda \text{I}$ ora è invertibile e posso quindi fare le moltiplicazioni.


$$\hat{\beta}_{RR} = \operatorname{Arg\,min} \|\vec{y} - \vec{X}\vec{b}\|^2 + \lambda(s) \|\vec{b}\|_2^2$$

più è alta la penalità sulla norma tanto più vincolo il mio problema a stare in una palla piccola

$$\lambda \downarrow 0 \quad s \uparrow +\infty \quad \hat{\beta}_{RR} = \hat{\beta}_{LS}$$



se è vincolato penalizzato molto la norma L^2 .



La soluzione allora del problema ridge sono il punto di contatto delle regioni di confidenza e il vincolo

~~Ridgeless~~ Però $\hat{\beta}_{RR}$ sono distorti

Restringere il vincolo sulla norma L^2 è una delle possibili.

Regressione LASSO: vincolo che $\sum |\beta_j| < s$ vincolo la norma 1



la ridge è + regolare.

la lasso invece è popolare perché i punti di tangenza vanno a finire negli angoli

Quindi $\beta_1 = 0$

Quindi sto in qualche modo facendo selezione delle variabili.



Modelli Lineari Generalizzati

[A. Agresti,
"categorical data analysis"] 4 giugno 2015

GLM

Modelli lineari con risposta y non gaussiana.

$y_i \sim Be(p_i)$ è il caso + importante

$$\vec{Y} = Z\vec{\beta} + \vec{\varepsilon}$$

Viamo specificare 3 componenti

- 1) Random Component: y v.a. risposta con la sua legge
- 2) Componente sistematica: Z matrice dei predittori deterministica
- 3) Link function: specifica quale funzione della $E[y]$ vogliamo spiegare con la componente sistematica

(Nel caso Gaussiano
la link function è id : $E[y] = Z\beta$)

Per ogni tipo di
variabile c'è una link function privilegiata, ma non è l'unica.

- 1) y v.a. risposta

(y_1, \dots, y_n) da y_1, \dots, y_n indipendenti
appartenenti alla famiglia esponenziale:

$$f(y_i; \theta_i) = a(\theta_i) b(y_i) \exp [y_i Q(\theta_i)]$$

↓
Parametro naturale

\leftarrow i parametri cambiano al cambiare della y .

- 2) $Z\vec{\beta} = (\eta_1, \dots, \eta_n)^T$ componente sistematica

η_i è il predittore lineare

$\vec{\beta} \in \mathbb{R}^{n+1}$ incosulti

$$\eta_j = \sum_{i=0}^n \beta_i z_{ij} \quad j=1, \dots, n$$

- 3) link function

$$\mu_i = E[y_i]$$

$$g: g(E[y_i]) = \eta_i$$

prendendo le medie la parte aleatoria viene tolta.

$g(\cdot) = Q(\cdot)$ Link function ottimale

14+

ESEMPIO : BERNOULLI

$$Y_i \sim \text{Be}(p_i)$$

$$\mu_i = p_i$$

$$f(y_i, p) = p^y (1-p)^{1-y} \mathbb{1}_{\{0,1\}}(y) = (1-p) \mathbb{1}_{\{0,1\}}(y) \cdot \exp[y \log(p) - \log(1-p)]$$

La link function canonica è

$$\text{logit}(p_i) = \log \frac{p_i}{1-p_i}$$

È QUESTO IL PARAMETRO NATURALE della BERNOULLI.

Quindi il mio modello cercherà di spiegare

$$\text{logit}(p_i) = \eta_i$$

+ Quideranno fra i miei parametri incogniti β .

$$(\eta_i = \text{nmbre } i \text{ di } z\beta)$$

η_i ha purtroppo un range da $-\infty$ a $+\infty$

p_i va da 0 a 1

Ma la funzione $\text{logit}(p) : [0,1] \rightarrow [-\infty, +\infty]$

Quindi i valori ammissibili di logit sono compatibili con quelli del predittore

ESEMPIO : Poisson

$$Y \sim P(\mu)$$

$$f(y, \mu) = \frac{e^{-\mu} \mu^y}{y!} \mathbb{1}_N(y) = \frac{e^{-\mu} \mu^y}{y!} \exp[y \log \mu]$$

⇒ la link function è

$$\text{log}(\mu_i) = \eta_i$$

cercheremo di spiegare il log della media con η_i

Ci servono degli indici per confrontare i modelli

AIC (Indice di Informazione di AKAIKE)

$$-2\ln(L) + 2K$$

K: numero dei parametri del modello

Vorrei aumentare la verosimiglianza, ma se lo faccio

aumento K non da benissimo

Vorlio massimizzare la verosimiglianza ma avere pochi parametri

smaller is better

DEVIANZA

$$\vec{y} = (y_1 \dots y_n)^T$$

Possiamo alla logverosimiglianza come
 $l(\hat{\mu}, \vec{y})$

Sia

$l(\hat{\mu}, \vec{y})$ la ^{log-}verosimiglianza del modello

Tra tutti i possibili modelli chiamiamo

MODELLO SATURATO $\hat{\mu} = \vec{y}$

possiamo calcolare

$l(\vec{y}, \vec{y})$ è la massima verosimiglianza
 tra tutti i modelli

Stimo la media
 con l'osservazione, così
 massimizzo la logverosimiglianza

Quindi la posso vedere
 come colo stimo, così
 posso percorrendo quanto
 un modello dista da lei.

Chiamo DEVIANZA

$$-2 [l(\hat{\mu}, \vec{y}) - l(\vec{y}, \vec{y})]$$

e la uso per confrontare due modelli

È meglio il modello con devianza + bassa

$$\text{logit}(p_i) = \eta_i$$

$$z \text{ nx2: } \beta_0 + \beta_1 z$$

$$\text{Voglio sapere } \text{logit}(p(z)) = \beta_0 + \beta_1 z$$


p_i sarebbe p che comunque
 dipende dalla variabile z .

$$\frac{p(z)}{1-p(z)} = \exp[\beta_0 + \beta_1 z]$$



$$p(z) = \frac{\exp[\beta_0 + \beta_1 z]}{1 + \exp[\beta_0 + \beta_1 z]}$$

Così e abbastanza chiaro il ruolo di β_0 e β_1 .
 $\beta_1 > 0 \rightarrow$ mu notava cresce e con z .
 (anche x_K e l'inverso del logit
 che lo era)




Ha l'ANDAMENTO di una FUNZIONE di RIPARTIZIONE!

In fatti a volte al posto del logit si usa $\phi(p_i)$


$$\text{probit} : \text{logit } (p_i) \xrightarrow{z} \phi(p_i)$$

Posso voler spiegare il mio
successo con una variabile continua
(eta) e probabilità di avere In.farto)



voglio modellizzare $\text{logit}(p_i)$

Divido la mia variabile in fasce e calcolo le medie per fascia



Oenco la migliore funzione di x che mi
modellizza le probabilità di avere un attacco cardiaco

(150) Metodi per Stimare i Parametri Incogniti

$$f(y_i; \theta_i, \phi) = \exp \left[\frac{(y_i \theta_i - b(\theta_i))}{a(\phi)} + c(y_i, \phi) \right]$$

ϕ parametro di dispersione, ma dipende dalla predizione lineare
ma $e = x$ tutte (x le Gauss è la varianza)

ϕ : parametro di dispersione

θ_i : parametro notionale

se ϕ nota

$$Q(\theta) = \frac{\partial}{\partial \phi}$$

$$a(\theta_i) = \exp \left[- \frac{b(\theta_i)}{a(\phi)} \right]$$

$$b(y_i) = \exp c(y_i, \phi)$$

Ma noi ci mantengiamo nella generalità con ϕ non noto

Andiamo a lavorare su f per stimare i parametri del modello.

Stimiamo la log verosimiglianza:

$$l_i = [y_i \theta_i - b(\theta_i)] / a(\phi) + c(y_i, \phi)$$

$$\frac{\partial l_i}{\partial \theta_i} = [y_i - b'(\theta_i)] / a(\phi)$$

$$\frac{\partial^2 l_i}{\partial \theta_i^2} = - \frac{b''(\theta_i)}{a(\phi)}$$

$$\mathbb{E} \left[\frac{\partial l_i}{\partial \theta_i} \right] = 0 \quad (\text{è } \int \frac{\partial l_i}{\partial \theta_i} = \int \frac{\partial}{\partial \theta} \log f \cdot f = 0)$$

$$\mathbb{E} \left[- \frac{\partial^2 l_i}{\partial \theta_i^2} \right] = \mathbb{E} \left[\left(\frac{\partial l_i}{\partial \theta_i} \right)^2 \right]$$

scambiando derivate e
integrale risulta $\int t=0$)

informazione
di Fisher

$$\mathbb{E}\left[\frac{\partial \ell_i}{\partial \theta_i}\right] = 0 \Leftrightarrow \mathbb{E}[Y_i] = b'(\theta_i)$$

Quando si è
la funzione
aspettativa
 $E[Y_i]$

$$\begin{aligned} -\mathbb{E}\left[\frac{\partial^2 \ell_i}{\partial \theta_i^2}\right] &= \frac{b''(\theta_i)}{a(\phi)} = \mathbb{E}\left[\left(\frac{\partial \ell_i}{\partial \theta_i}\right)^2\right] = \mathbb{E}\left[\left(\frac{Y_i - b'(\theta_i)}{a(\phi)}\right)^2\right] = \\ &= \frac{1}{a^2(\phi)} \text{Var}[Y_i] \end{aligned}$$

Quindi riconosco che

$$\begin{cases} \mathbb{E}[Y_i] = b'(\theta_i) \\ \text{Var}[Y_i] = b''(\theta_i) \cdot a(\phi) \end{cases}$$

Le funzioni b e le sue derivate determinano media e varianza della y .

ESEMPIO

$$Y_i \sim P(\mu_i)$$

$$f(Y_i, \mu_i) = \exp \left[Y_i \underbrace{\log \mu_i}_{\theta_i} - \mu_i - \underbrace{\log(\mu_i)}_{b(\theta_i)} \right] \underbrace{c(Y_i, \phi)}$$

$a(\phi)$ -identità

$$\theta_i = \log(\mu_i)$$

Se

$$\mu_i = b(\theta_i) \Rightarrow b(\theta_i) = \exp[\log(\mu_i)]$$

$$\text{Quindi } b(\circ) = \exp(\circ)$$



$$\mathbb{E}[Y_i] = \exp(\theta_i) = \mu_i$$

$$\text{Var}[Y_i] = b''(\theta_i) = \exp(\theta_i) = \mu_i$$

Quindi ritrovo i parametri media e varianza delle Poisson.



fase x le Bernoulli

(152) La nostra Likelihood è

$$l(\vec{\beta}) = \sum_{i=1}^n \log f(y_i; \theta_i, \phi)$$

\wedge i parametri incogniti $\vec{\beta}$
sono dentro il θ_i

$$= \sum_{i=1}^n \left(\frac{y_i \theta_i - b(\theta_i)}{a(\phi)} \right) + \sum_i c(y_i, \phi)$$

ora voglio derivare rispetto a β_j .

punto = 0 e trovare i candidati di massima verosimiglianza.

$$\frac{\partial l}{\partial \beta_j} = \sum_{i=1}^n \frac{\partial l_i}{\partial \beta_j} = 0 \quad \forall j = 0, \dots, n$$

trovo così gli MLE di $\vec{\beta}$

$$\frac{\partial l_i}{\partial \beta_j} = \frac{\partial l_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \beta_j}$$

REGOLA
CHAIN RULE
x la derivata

$$\text{predittore lineare} \quad \eta_i = g(\mu_i) = \sum_j z_{ij} \beta_j$$

$$\cdot \frac{\partial l_i}{\partial \theta_i} = \frac{y_i - b'(\theta_i)}{a(\phi)} = \frac{y_i - \mu_i}{a(\phi)}$$

$$\text{ma } b'(\theta_i) = E[y_i]$$

$$\cdot \frac{\partial \mu_i}{\partial \theta_i} = \frac{\partial b'(\theta_i)}{\partial \theta_i} = b''(\theta_i) = \frac{\text{Var}[y_i]}{a(\phi)}$$

$$\cdot \frac{\partial \mu_i}{\partial \eta_i} =$$

dipende da g

$$\text{e } g(\mu_i) = \eta_i$$

$$\cdot \frac{\partial \eta_i}{\partial \beta_j} = z_{ij}$$

Globalmente:

$$\frac{\partial l_i}{\partial \beta_j} = \frac{y_i - \mu_i}{a(\phi)} \frac{a(\phi)}{\text{Var}[y_i]} \frac{\partial \mu_i}{\partial \eta_i} z_{ij} = \frac{(y_i - \mu_i) z_{ij}}{\text{Var}[y_i]} \frac{\partial \mu_i}{\partial \eta_i}$$

La mia storia di massima verosimiglianza,

$\hat{\beta}_{MLE}$ risolvono

$$\sum_{i=1}^n \left(\frac{y_i - \mu_i}{\text{Var}(y_i)} \right) z_{ij} \frac{\partial \mu_i}{\partial \eta_i} = 0 \quad \forall j = 0, 1, \dots, n$$

I β ci sono dentro il fatto che

$$\mu_i = g^{-1}(\eta_i) = g^{-1}\left(\sum_j z_{ij} \beta_j\right)$$

non sostituisco
xk dipende da g

Nel caso Gaussiano, con g identità, mi trovo tutto come sempre

Quasi in tutti questi problemi

dovendo usare metodi nuovi x risolvere le

EQUAZIONI DI VERO SIMIGLIANZA

de y comparendo con media e varianza.

9 giugno 2015

$$y \\ z \vec{\beta}$$

g link function $g(\mu_i) = z \vec{\beta}$

$$\log L(\vec{\beta}) = \sum_{i=1}^n \log f(y_i; \theta_i; \phi) = \sum_{i=1}^n \frac{y_i - b(\theta_i)}{a(\phi)} + c(y_i; \phi)$$

\uparrow qui c'è i nostri β

$\sum \frac{\partial \ell_i}{\partial \beta_j} = 0$ ci dà gli stimatori di massima verosimiglianza

EQUAZIONI di VERO SIMIGLIANZA

$$\sum_{i=1}^n \left(\frac{y_i - \mu_i}{\text{Var}[y_i]} \right) z_{ij} \underbrace{\frac{\partial \mu_i}{\partial \eta_i}}_{\text{che cos' e?}} = 0 \quad \forall j = 0, \dots, n$$

(154)

 $y_i \sim \text{Be}(p_i)$

$$\sum_{i=1}^n \underbrace{\frac{y_i - p_i}{p_i(1-p_i)}}_{\text{Varianza della Bernoulli}} \cdot z_{ij} \frac{\partial p_i}{\partial \eta_i} = 0$$

 $\text{logit}(p_i) = \eta_i \leftarrow \text{predizione lineare}$

il logit è la link function

$$\log \frac{p_i}{1-p_i} = \eta_i \Rightarrow \frac{p_i}{1-p_i} = \exp^{\eta_i}$$

↑

$$p_i (1 + \exp^{\eta_i}) = \exp(\eta_i)$$

$$p_i = \frac{\exp\left(\sum_{j=0}^k z_{ij} \beta_j\right)}{1 + \exp\left(\sum_{j=0}^k z_{ij} \beta_j\right)}$$

$$\begin{aligned} \frac{\partial p_i}{\partial \eta_i} &= \left(\frac{\partial}{\partial \eta_i} \eta_i \right)^{-1} = \left(\frac{\partial}{\partial \eta_i} \text{logit} p_i \right)^{-1} = \\ &= \left(\frac{\partial}{\partial \eta_i} \log \frac{p_i}{1-p_i} \right)^{-1} = \left(\frac{1-p_i}{p_i} \frac{(1-p_i)+p_i}{(1-p_i)^2} \right)^{-1} = p_i(1-p_i) \end{aligned}$$

Quindi le nostre equazioni di verosimiglianza nel caso di
una Bernoulli diventano

$$\sum_{i=1}^n \frac{(y_i - p_i)}{p_i(1-p_i)} z_{ij} p_i(1-p_i) = \sum_{i=1}^n \underbrace{(y_i - p_i)}_{\text{qui ho i f}} z_{ij} = 0 \quad \forall j = 1 \dots n$$

$$\sum \left(y_i - \frac{\exp\left(\sum_{j=0}^k \beta_j z_{ij}\right)}{1 + \exp\left(\sum_{j=0}^k \beta_j z_{ij}\right)} \right) z_{ij} = 0$$

ma riusciamo a scrivere
in forma chiusa, $\beta_j = \text{qualcosa}$ dipende solo dalle
osservazioni y_i e
dalle matrice disegnoE otengo i β via

ma di fatto non serve a scriverli

Pero' in R Vena' comunque dato un risultato, questo grazie all'asintotica normalita' degli stimatori di vero si muovendo così posso fare test sui β . Pero' ho bisogno di grande

$y_i \sim P(\mu_i)$

link fonetico $\log(\mu_i) = \eta_i \Leftrightarrow \mu_i = \exp(\eta_i)$

equazioni di verosimiglianza:

$$\frac{\partial \mu_i}{\partial \eta_i} = \exp(\eta_i) = \mu_i$$

$$\sum_{i=1}^n \frac{y_i - \mu_i}{\text{Var}(y_i)} \cdot z_{ij} \cdot \frac{\partial \mu_i}{\partial \eta_i} = 0$$

$$\Downarrow$$

$$\sum_{i=1}^n \underbrace{\frac{y_i - \mu_i}{\mu_i}}_{\text{Var}(y_i)} \cdot z_{ij} \cdot \mu_i = 0$$

$$\Downarrow$$

$$\sum_{i=1}^n (y_i - \mu_i) \cdot z_{ij} = 0$$

Io i β sono nascosti qui,

$$\Downarrow$$

$$\sum_{i=1}^n (y_i - \exp\left(\sum_{j=0}^R \beta_j z_{ij}\right)) \cdot z_{ij} = 0$$

↑
Anche qui la risoluzione di β_j
è affidata nell' \exp quindi
questo crea problemi

Nel caso della gaussiana ritroviamo le
equazioni che minimizzano la distanza
col predittore lineare.

Quando metto i miei y_i e la matrice diretta z
nel modello generalizzato
ottengo i miei $\hat{\beta}$

Quindi il mio predittore lineare stimato è $\hat{\eta}_i = \sum_{j=0}^R \hat{\beta}_j z_{ij}$
e con il predittore lineare stima
 $g(\hat{\mu}_i) = \hat{\eta}_i$

(156) Dunque $\text{logit}(\hat{p}_i) = \hat{\eta}_i$

$$\Leftrightarrow \hat{p}_i = \frac{\exp(\hat{\eta}_i)}{1 + \exp(\hat{\eta}_i)}$$

Da cui

$$\hat{y}_i = \frac{\exp(\sum_j z_{ij} \hat{\beta}_j)}{1 + \exp(\sum_j z_{ij} \hat{\beta}_j)}$$

produiamo stime in $[0, 1]$, che sono delle probabilità.

Da \hat{p}_i posso dire se la previsione \hat{y}_i la prevedeo come 0 o come 1.

Io osservo dieci 0 e 1.



funzione logistica
della probabilità di avere
effetto collaterale del farmaco
in funzione dell'età.

Il modello produce una probabilità in base all'età,
ci dà la probabilità che sia 1.

Per esempio posso dire
che se la probabilità è $> \frac{1}{2}$ allora
vedo la y come 1,
se $< \frac{1}{2}$ come 0.

Nel modello di Poisson pensare in cash
le y_i è N , numero di ~~passante auto esattutto~~
e lo voglio spiegare con tariffazione autostrada.
Avrei-

$$\hat{\log}(\mu_i) = \hat{\eta}_i = \sum_{j=0}^n z_{ij} \hat{\beta}_j$$

Quindi la media

$$\hat{\mu}_i = \exp(\hat{\eta}_i) = \exp\left(\sum_{j=0}^n z_{ij} \hat{\beta}_j\right)$$

$\hat{\mu}_i$ non è un numero di $\in N$,

Quindi devo capire come valutare il
discreto numero che l'osservazione
è il μ_i previsto.

$$\text{Cov}(\vec{\beta}) = (Z^T W Z)^{-1} \quad \text{si può dimostrare questo,}$$

con W matrice diagonale con $W_{ii} = \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 \frac{1}{\ln(y_i)}$

157

nell'ipotesi
lineari queste I ,
Quindi minimizza la covarianza
nel solito modo

CASO BERNOLLI

$$\frac{\partial \mu_i}{\partial \eta_i} = p_i(1-p_i) = \ln(y_i)$$

$$W_{ii} = \ln(y_i)$$

Quindi

$$\text{Cov}(\vec{\beta}) = (Z^T \text{diag}(\hat{p}_i(1-\hat{p}_i))Z)^{-1}$$

$\hat{p}_i = \frac{\exp(\hat{\eta}_i)}{1 + \exp(\hat{\eta}_i)}$

REGRESSIONE
LOGISTICA

Quindi quando R è stretta

$\hat{\beta}_j$ ~~è~~ Se $(\hat{\beta}_j)$ dato dall'elemento
diagonale j -esimo.

Per il modello è "stretto" quando ha
grossa la differenza tra 0 e 1,
quindi il p stimato è ≈ 0 o ≈ 1 .

CASO POISSON

$$W = \frac{\mu_i^2}{\mu_i} = \mu_i$$

Quindi

$$\text{Cov}(\vec{\beta}) = (Z^T \text{diag}(\hat{\mu}_i)Z)^{-1}$$

$\hat{\mu}_i = \exp\left(\sum_j z_{ij} \hat{\beta}_j\right)$

COME VALUTARE un MODELLO

Indici di GOF - Goodness of fit

* DEVIANZA

$$\tilde{\theta}_i = \tilde{\mu}_i = y_i \quad \forall i = 1 \dots n$$

i nostri parametri sono tanti quanti le osservazioni.

$$\hat{\theta}_i = \hat{\mu}_i \quad \text{del modello, stimato}$$

solo di meno.

$$D = -2 \left[l(\hat{\mu}; \vec{y}) - l(\vec{y}, \vec{y}) \right]$$

misura la discrepanza
rispetto al fit migliore

Nel nostro caso

$$l_i = \frac{y_i \tilde{\theta}_i - b(\tilde{\theta}_i)}{a(\phi)}$$

$$D = 2 \sum_{i=1}^n \frac{y_i \tilde{\theta}_i - b(\tilde{\theta}_i)}{a(\phi)} - 2 \sum_{i=1}^n \frac{y_i \hat{\theta}_i - b(\hat{\theta}_i)}{a(\phi)}$$

$$= 2 \sum_{i=1}^n \frac{y_i (\tilde{\theta}_i - \hat{\theta}_i) - b(\tilde{\theta}_i) + b(\hat{\theta}_i)}{a(\phi)}$$

anche chiamata
devianza scalata

$$-2 \log(\lambda(\vec{x})) \rightsquigarrow \chi^2$$

Cosa diventa la devianza nel caso di Poisson e di Bernoulli?

Poisson

$$\tilde{\theta}_i = \log y_i$$

$$\hat{\theta}_i = \log(\hat{\mu}_i)$$

$$b(\theta_i) = \exp(\theta_i)$$

$$a(\phi) = 1$$

$$D(\vec{y}, \vec{\mu}) = 2 \sum_{i=1}^n \left[y_i \log \left(\frac{y_i}{\mu_i} \right) - y_i + \mu_i \right]$$

pesa la discrepanza
tra osservazioni e media
e logaritmo del quoziente

BERNOULLI

159

$$\hat{\theta}_i = \log \left(\frac{\hat{p}_i}{1-\hat{p}_i} \right)$$

$$b(\theta) = \log (1 + \exp(\theta)) \quad \text{modello saturato}$$

$$b(\hat{\theta}_i) = \log \left(1 + \frac{\hat{p}_i}{1-\hat{p}_i} \right) = \log \frac{1}{1-\hat{p}_i} - \log (1-\hat{p}_i)$$

$$\tilde{\theta}_i = \log \left(\frac{y_i}{1-y_i} \right)$$

$$b(\tilde{\theta}_i) = -\log (1-y_i) \quad \} \text{modello saturato}$$

$$\begin{aligned} D(\vec{y}, \vec{\mu}) &= 2 \sum_i \left[y_i \left(\log \left(\frac{y_i}{1-y_i} \right) - \log \frac{\hat{p}_i}{1-\hat{p}_i} \right) \right. \\ &\quad \left. + \log (1-y_i) - \log (1-\hat{p}_i) \right] \\ &= 2 \sum_i \left[y_i \log \left(\frac{y_i}{\hat{p}_i} \right) \right] + 2 \sum_i [1-y_i] \log \frac{1-y_i}{1-\hat{p}_i} \end{aligned}$$

Quindi la devianza è in certo senso

totalmente simmetrica,

se fossero tutti 0 o tutti 1 una delle due parti andrebbe via

Prendere il modello con devianza più bassa

Se ho due modelli annidati posso direttamente confrontare tra i due modelli, senza usare il modello annidato.

Mo sottomodello di M_0 .

$$l(\vec{\mu}_0, \vec{y}) \leq l(\vec{\mu}_1, \vec{y})$$

$$\begin{aligned} D(\vec{y}, \vec{\mu}_1) &= -2 \left[l(\vec{\mu}_1, \vec{y}) - l(\vec{y}, \vec{y}) \right] \leq -2 \left[l(\vec{\mu}_0, \vec{y}) - l(\vec{y}, \vec{y}) \right] \\ &= D(\vec{y}, \vec{\mu}_0) \end{aligned}$$

(se prendo un modello più semplice la devianza aumenta)

Faccio un test che dice se i due modelli sono equivalenti o meno.

R restituisce test asintotici legati al fatto che $-2\log(\lambda)$ è asintoticamente una χ^2

160 DEVIANZE PER LA SINGOLA OSSERVAZIONE

$$D = \sum \underbrace{[y_i (\hat{\theta}_i - \tilde{\theta}_i) - b(\tilde{\theta}_i) + b(\hat{\theta}_i)]}_{d_i: \text{ devianza singola osservazione}} = \sum d_i$$

$\sqrt{d_i}$: sign $(y_i - \hat{\mu}_i)$ devianza residua

per vedere se sovrashiuo o sottostima
l'osservazione

RESIDUI di PEARSON

$$\frac{y_i - \hat{\mu}_i}{\sqrt{v_{\hat{\mu}_i} y_i}}$$

Soprattutto per la Bernoulli si usa spesso BRIEN'S SCORE

$$\frac{1}{n} \sum_i (y_i - \hat{p}_i)^2$$

AIC
 $-2 \left(l(\hat{\mu}, \hat{y}) - \# \text{parametri modello} \right)$

più parametri metto e medio è,
ma così tempo calcolo che ho $+ \# \text{ parametri}$

BIC

REGRESSIONE LOGISTICA SEMPLICE

su solo parametro

161

$$\text{logit}(p_i) = \beta_0 + \beta_1 x$$

L'equivalente dell'incremento di un'unità mi fa vedere l'incremento del logit

$$x \rightarrow x+1$$

$$\log\left(\frac{p(x+1)}{1-p(x+1)}\right) - \log\left(\frac{p(x)}{1-p(x)}\right) = \beta_1$$

ci dà il significato di β_1 :

$$\log \frac{\frac{p(x+1)}{1-p(x+1)}}{\frac{p(x)}{1-p(x)}} = \log [\text{odds ratio}]$$

Quindi abbiamo che

e^{β_1} = odds ratio all'incremento unitario della covariata.


All'aumentare della covariata l'odds ratio aumenta di e^{β_1} .

I test che si fanno sono di solito

$$\text{ODDS} = 1 \quad \text{vs} \quad \text{ODDS} \leq 1$$

Quindi faremo test legati a β_1 .

Tra le 2 possiamo avere anche una variabile categorica



$$y_i \begin{matrix} \\ 0 \\ 1 \end{matrix}$$

la categoria potrebbe essere

fumatore
non fumatore

$$\hat{p}_i = \hat{\beta}_0 + \hat{\beta}_1 c_i$$

e^{β_1} = odds ratio tra categoria fumatori e non fumatori,

JK passa aumentando di una unità passo da una all'altra:

$$\frac{p_s}{1-p_s}$$

$$\frac{p_{ns}}{1-p_{ns}}$$

(162) Regressione Logistica

10 gennaio 2015

$$y_i \sim \text{Be}(\pi)$$

$$\text{la link function } g(\cdot) = \text{logit}(\pi_i) = \log\left(\frac{\pi_i}{1-\pi_i}\right)$$

$g(\pi_i) = \eta_i$ predittore lineare
pro-varianza da -\infty a +\infty

l'inverso di g_i , che ci spiega π_i è

$$\pi_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)} = \frac{\exp(\sum \beta_j z_{ij})}{1 + \exp(\sum \beta_j z_{ij})}$$

CASO di $R=1$

$$\eta_i = \beta_0 + \beta_1 x_i$$

\uparrow covariata continua

Possiamo scrivere

$$\text{logit}(p(x)) = \beta_0 + \beta_1 x$$


\uparrow funzione della covariata x

$$p(x) = \frac{\exp(\beta_0 + \beta_1 x)}{1 + \exp(\beta_0 + \beta_1 x)}$$



formula delle funzioni di riportazione.

per vedere la simmetria rispetto all'origine: $p(-x) = \frac{\exp(\beta_0 - \beta_1 x)}{1 + \exp(\beta_0 - \beta_1 x)}$



Se incremento $x \rightarrow x+1$

$$\text{logit}(p(x+1)) - \text{logit}(p(x)) = \beta_0 + \beta_1(x+1) - \beta_0 - \beta_1x = \beta_1$$

↑
COSA SOCCEDA ALLA
RISPOSTA QUI LO VEDIAMO
CON IL LOGIT
INCREMENTANDO x di UNA UNITÀ

$$\beta_1 = \log \left(\frac{\frac{p(x+1)}{1-p(x+1)}}{\frac{p(x)}{1-p(x)}} \right) = \log \text{(ODDS RATIO)}$$

rapporto tra
due odds,
ossia $\frac{\text{prob}}{1-\text{prob}}$

Se x è variabile categorica
l'incremento di 1 è un
passaggio di categoria.

$c_1 \dots c_k$ categorie
ottengo un coeff. relativo a oculi passaggio di
categoria.

gli altri coefficienti rappresentano lo scozzamento
rispetto a quella categoria.
↑
log dell'odds ratio

$$OR = \exp(\beta_1)$$

$\hat{\beta}_1$

↑
STIME
MLE ASINTOTICAMENTE
GAUSSIANE

Oltre la stima abbiamo uno standard error

$\hat{\beta}_1$	$Se(\hat{\beta}_1)$	Z_{stat}	P-value	tabella di regressione logistica per $H_0: \beta_1 = 0$ $H_1: \beta_1 \neq 0$

Possiamo costruire un IC per $\hat{\beta}_1$,
 XK è Gaussiano e ha standard error,
quindi è

$$IC = \hat{\beta}_1 \pm Z_{1-\frac{\alpha}{2}} Se(\hat{\beta}_1)$$

$$1-\alpha = P(\beta_1 \in IC)$$

↑
probabilità di copertura

(164) Possiamo costruire un intervallo per l'odds ratio.

$$1 - \alpha = P[\hat{\beta}_1 - z_{1-\frac{\alpha}{2}} \text{se}(\hat{\beta}_1) \leq \beta_1 \leq \hat{\beta}_1 + z_{1-\frac{\alpha}{2}} \text{se}(\hat{\beta}_1)]$$

$$1 - \alpha = P[\exp(\hat{\beta}_1 - z_{1-\frac{\alpha}{2}} \text{se}(\hat{\beta}_1)) \leq \text{OR} \leq \exp(\hat{\beta}_1 + z_{1-\frac{\alpha}{2}} \text{se}(\hat{\beta}_1))]$$

Funzione

che ci dà la dipendenza tra $p(x)$ cui dà anche che

$$\begin{aligned} \frac{\partial p(x)}{\partial x} &= \frac{\partial}{\partial x} \left(\frac{\exp(\beta_0 + \beta_1 x)}{1 + \exp(\beta_0 + \beta_1 x)} \right) = \\ &= \frac{\beta_1 \exp(\beta_0 + \beta_1 x)(1 + \exp(\beta_0 + \beta_1 x)) - \beta_1 [\exp(\beta_0 + \beta_1 x)]^2}{(1 + \exp(\beta_0 + \beta_1 x))^2} \\ &= \frac{\beta_1 \exp(\beta_0 + \beta_1 x)}{(1 + \exp(\beta_0 + \beta_1 x))^2} \\ &= \beta_1 p(x)(1 - p(x)) \end{aligned}$$

Quindi come cambia $p(x)$ rispetto a x ?

$$\frac{\partial p(x)}{\partial x} = \beta_1 p(x)(1 - p(x))$$


e' massima in $p(x) = \frac{1}{2}$,
dove vale

$$\frac{\beta_1}{4}$$

\bar{x} : punto di massimo
tolleranza

$$p(\bar{x}) = \frac{1}{2} \Rightarrow \text{logit}(p(\bar{x})) = 0 = \beta_0 + \beta_1 \bar{x}$$

seconda del β_1 ho
crescita più o meno
nei punti
delle $p(x)$



$$\boxed{\bar{x} = -\frac{\beta_0}{\beta_1}}$$

MEDIAN EFFECTIVE LEVEL

(165)
È quando $\bar{y} = \frac{1}{n} \sum y_i \approx 0 \circ 1$

Regola del pollice ci dice che dobbiamo avere abbastanza 0 o 1.

Se ho



R dice che non ho convergenza,

per cui mi è più chiaro che per le $x < \text{tot}$ ho 0, per $x > \text{tot}$ ho 1,

non ho bisogno di regressione logistica

Regressione Logistica per Classificazione

METODI DI CLASSIFICAZIONE:

- > CLASSIFICAZIONE SUPERVISIONATA
- > CLASSIFICAZIONE NON SUPERVISIONATA

La prima è quella per cui nei miei dati so se y_i è
gruppo A o gruppo B e voglio cercare modelli per
distinguere i due gruppi (ho maschi e femmine e voglio
vedere quali sono le etichette che mi portano a
classificare una persona in A o B).

Io faccio x_k mi serve a fare previsione)

Impara dalle etichette che osserva e capisce quali sono
le covariate che mi permettono di dare etichette.

La seconda mi ha etichette, ma cerca
di vedere se ci sono gruppi, e es. vedendo la
distanza euclidea,
e quando ho molti "dati vicini" se voglio
metterlo in un gruppo o l'altro



La regressione logistica è modello
di classificazione supervisionata.

Noi studiamo

$$\hat{p} = \hat{y}_i = \frac{\exp(\eta_i)}{1 + \exp(\eta_i)} = \frac{\exp\left(\sum_{j=0}^2 \hat{\beta}_j z_{ij}\right)}{1 + \exp\left(\sum \hat{\beta}_j z_{ij}\right)}$$

(166) $\forall i=1 \dots n$ produco \hat{p}_i e posso dire

$$\hat{p}_i \rightsquigarrow \hat{y}_i = \begin{cases} 1 & \text{se } \hat{p}_i > p_0 \\ 0 & \text{se } \hat{p}_i \leq p_0 \end{cases}$$

p_0 di solito è $= \frac{1}{2}$.

↑
valore di
soglia

Se la proporzione delle unità statistiche nel dataset è molto sbilanciata (x es 75% di 0)

prendo un altro p

Abbiamo quindi

classificazioni y_i
classificate \hat{y}_i

Si costruisce una

tabella di Contingenza

\hat{y}	0	1	classificazione
0	solo 0 e no previsto n_{00}	solo 1 e no previsto n_{01}	← veri 0 e veri 1
1	n_{10}	n_{11}	

$$n_{00} + n_{01} + n_{10} + n_{11} = n \quad \text{numerato statistiche dataset}$$

Le unità classificate in modo corretto sono $\frac{n_{00} + n_{11}}{n}$

Mi piacerebbe avere una tabella diagonale!

Ges' questa tabella mi dice se sto classificando bene o no

1: malato

0: sano

I due errori fuori diagonale non sono gravi allo stesso modo,

ma pesa di più se classifico un malato come sano piuttosto che il contrario

Si introducono quindi

LA SENSIBILITÀ: probabilità di classificare un malato quando è malato
 $p(\hat{y} = 1 | y = 1)$ la voglio ≥ 1
e se altri metti dico che è sano
ma è malato

LA SPECIFICITÀ

$p(\hat{y} = 0 | y = 0)$
probabilità di classificare sano quando è sano

A ogni tabella di contingenza è associato un valore di sensibilità e di specificità

Ora studiamo le


Curva ROC (curve risposte)

punti del piano

Asse x : 1 - specificità

Asse y : sensibilità

Ogni punto corrisponde a (x_i, y_i) di un classificatore
al valore della soglia p_0



$p_0 = 0$
sotto i sani
ma anche tutti i
malati

$p_0 \in \{p_1, \dots, p_n\}$ per ogni p_i ho un classificatore;
per ogni classificatore ho tabella di contingenza;
e da essa calcolo sensibilità e specificità

La curva è vincolata a passare per $(0,0)$, $(1,1)$

e il classificatore è migliore quanto più
è sopra il ~~quadrato~~ la diagonale,
simile al quadrato

$\downarrow p_0 = 1$
ho tutto 0
e anche tutti i sani

In realtà non posso decidere quale class è meglio
si calcola l'area sotto la curva

di fatto non ha senso
prendere $p_0 = p_i$

(168) Sensibilità e specificità alta è top
1 - specificità bassa

1 - Specificità falsi positivi (sono malati ma sono salvi)
 $P(\hat{Y}=0|Y=0) = P(\hat{Y}=1|Y=0)$

Sensibilità: veri positivi

Come calcolo specificità e sensibilità dalla tabella di contingenza?

$$\text{SENSIBILITÀ} = \frac{P(\hat{Y}=1, Y=1)}{P(Y=1)} = \frac{n_{11}}{n_{01} + n_{11}}$$

formula
prob. condiz.

$$\text{SPECIFICITÀ} = \frac{P(\hat{Y}=0, Y=0)}{P(Y=0)} = \frac{n_{00}}{n_{00} + n_{10}}$$

Il modello sotto, stimato con la regressione logistica, non cambia.

Se la tabella ha una colonna vuota viene definita degenera se la classificazione è banale.

Di fatto in realtà la curva ROC non sarà continua ma magari è tipo un gradino, non è detto che cambino sia sens che spec.

Sensibilità e specificità sono importanti rispetto a un classificatore XK al nuovo classificato voglio sapere

$P(Y=1 | \hat{Y}=1)$, il contrario voglio sapere se, essendo classificato malato, sono malati

$$= \frac{P(Y=1, \hat{Y}=1)}{P(\hat{Y}=1)} = \frac{P(\hat{Y}=1|Y=1) P(Y=1)}{P(\hat{Y}=1|Y=1) P(Y=1) + P(\hat{Y}=1|Y=0) P(Y=0)}$$

$$P(\text{Malato} | \text{test}+) = \frac{\text{sensibilità} \cdot \text{Incidenza}}{\text{sensibilità} \cdot \text{Incidenza} + (1 - \text{Specificità}) (1 - \text{Incidenza})}$$

169

\uparrow prob di essere malati
quando test dice + Incidenza = $P(Y=1)$

TABELLE di Contingenza con R righe e C colonne

Quando 2 caratteristiche categoniche
(fascia reddito e marca macchina)

B	A_1	A_2	
B_1			$n_{i.}$
B_2			$n_{..}$
		$n_{.j}$	

Che tipo di inferenza ci può interessare?

Vedere se c'è associazione o indipendenza

Che test faccio?

Un test assiutotico.

$$n_{ij} = \#\{x_i : x_i \in B_i \cap A_j\}$$

Questa tabella di contingenza viene da variabili indipendenti se la coulontà è prodotto marginale

O_{ij} = numerosità osservata

$n_{i.}$ = numerosità di riga

$n_{.j}$ = numerosità di colonna

$n_{..}$

Le frequenze attese (numerosità attesa) in caso di indipendenza

$$E_{ij} = \frac{n_{i.} n_{.j}}{n_{..}}$$

xx la ~~caso~~ coulontà è prodotto marginale

170 Si può costruire una statistica test

$$\chi^2_0 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \quad \leftarrow \begin{array}{l} \text{modo di} \\ \text{standardizzare} \\ \text{una casella da} \\ \text{una poisson} \end{array}$$

se fossero I la statistica sarebbe 0.

$$\sim \chi^2 ((c-1)(r-1))$$

sotto H_0 (indipendenza)
 $[H_1: \text{non indipendenza}]$

colonne - 1
 (# categorie in A - 1)
 # righe - 1

Quindi

$$RC = \{ \chi^2_0 > \chi^2_{1-\alpha} ((c-1)(r-1)) \}$$

Torniamo a una 2×2

$A \setminus B$	1	2	
1	n_{11}	n_{12}	$n_{1..}$
2	n_{21}	n_{22}	$n_{2..}$
	$n_{..1}$	$n_{..2}$	$n_{..1}$

$n_{..} =$

$\frac{n_{1..} + n_{2..}}{n_{..1}}$

$$P_{A=1}^B = \frac{n_{11}}{n_{1..}} = \frac{n_{11}}{n_{11} + n_{12}} \quad \stackrel{\uparrow \text{ se è}}{=} \frac{(n_{11} + n_{12})(n_{21} + n_{11})}{n_{..} (n_{11} + n_{12})} = \frac{n_{11} + n_{21}}{n_{..}}$$

probabilità
 di successo rispetto
 a essere nella categoria 1)

$$P_{A=2}^B = \frac{n_{21}}{n_{2..}} = \frac{(n_{21} + n_{22})(n_{11} + n_{21})}{(n_{21} + n_{22})n_{..}} = \frac{n_{11} + n_{21}}{n_{..}}$$

Indipendenza: $P_{A=1}^B = P_{A=2}^B \Rightarrow OR = 1$

Altro modo x stimare l' ODDS RATIO dalla tabella di contingenza: (17)

$$\text{ODDS}_{A=1} = \frac{\frac{n_{11}}{n_{1\cdot}}}{\frac{n_{12}}{n_{1\cdot}}} = \frac{n_{11}}{n_{12}}$$

$$\text{ODDS}_{A=2} = \frac{\frac{n_{21}}{n_{2\cdot}}}{\frac{n_{22}}{n_{2\cdot}}} = \frac{n_{21}}{n_{22}}$$

Quindi

$$OR = \frac{n_{11}}{n_{12}} \frac{n_{22}}{n_{21}}$$

$$OR = \frac{ad}{bc}$$

a	b
c	d

Stima puntoale
dell' ODDS

ma è detto sia = a qd di denostimazione con
regressione logistica

Si puo' dimostrare che

$$SE(\log OR) = \sqrt{\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}}}$$

(asintotico, per n grande)

Un altro IC per $\log(OR)$

$$\log(OR) \pm Z_{1-\frac{\alpha}{2}} SE(\log OR)$$

quindi x trovare

l'IC per OR

basta prendere l'exp.

Si puo' vedere quanto queste stime abbiano
a quelle della regressione.

(72) FACTOR ANALYSIS

Nasce in ambito psicometruco

la variabile di cui voglio cogliere il comportamento non è direttamente misurabile - fattori latenti.

Se per esempio voglio studiare la percezione del dolore,

o il QI o il Quoziente di apprendimento ho sì

un'unità di misura, ma non sono facilmente misurabili

la quantità di informazione che mi dà un questionario
è limitata rispetto alla realtà, e se se è
particolamente difficile calcolare.

- Modelli di Rasch x capire come è fatto il questionario.

Ma come creare i questionari? Come diseguarli?

Vogliamo descrivere delle relazioni di covarianza tra variabili
in termini di Pochi (voglio modelli semplici) FATTORI
soggiacenti e NON OSSERVABILI

Voglio la covarianza tra le mie variabili.

Massimizzazione la sconnessenza tra i gruppi.

Voglia uno MODELLIZZARE IL NOSTRO fenomeno



Orthogonal Factor model

\vec{X} aleatorio $\in \mathbb{R}^P$

\vec{X} : variabili osservabili

$$\vec{\mu} = \mathbb{E}[\vec{X}]$$

$$\sigma = \text{Cov}(\vec{X}) \quad (p \times p)$$

Il Modello postula che \vec{X} sia linearmente dipendente
da Pochi variabili non osservabili

f_1, \dots, f_m (fattori comuni) (come adese matrice
di direzioni non osservabili)

p Sorgenti addizionali di
variabilità $\epsilon_1, \dots, \epsilon_p$ (ERRORE o
FATTORI SPECIFICI)

$$X_1 - \mu_1 = l_{11} f_1 + l_{12} f_2 + \dots + l_{1m} f_m + \varepsilon_1$$

:

$$X_p - \mu_p = l_{p1} f_1 + l_{p2} f_2 + \dots + l_{pm} f_m + \varepsilon_p$$

Un modello del genere può essere pensato come modello che genera i dati?

$$\vec{X} - \vec{\mu} = \underbrace{\mathbf{L} \vec{F}}_{\substack{\text{vettore } (p \times 1) \\ \text{dimensionalmente}}} + \vec{\varepsilon}$$

(p \times m) (m \times 1) torus

$$l_{ij} = [L]_{ij} \quad \begin{array}{l} \text{: LOADING della variabile } i = 1 \dots p \\ \text{sul fattore } j \end{array} \quad j = 1 \dots m$$

Ma devo fare assunzioni sulla struttura di F , che sono di ortogonalità:

Assunzioni

- $\mathbb{E}[\vec{F}] = 0$

- $\text{Cov}[\vec{F}] = \mathbf{I}_{m \times m}$

- $\mathbb{E}[\vec{\varepsilon}] = 0$

- $\text{Cov}[\vec{\varepsilon}] = [\varphi_1 \dots \varphi_p]$

- $\vec{F} \perp \vec{\varepsilon}$ fattori comuni indipendenti da quelli specifici

Se assumiamo $\vec{X} - \vec{\mu} = \vec{LF} + \vec{\varepsilon}$
e quest'anno vincoli sulla matrice di varianza covarianza di \vec{X}

Studiare la struttura che viene implicata nelle assunzioni su $\text{cov}(\vec{X})$

$$\begin{aligned}
 (\vec{X} - \vec{\mu})(\vec{X} - \vec{\mu})^T &= (\vec{LF} + \vec{\varepsilon})(\vec{LF} + \vec{\varepsilon})^T = \\
 &= (\vec{LF} + \vec{\varepsilon})(((\vec{LF})^T + \vec{\varepsilon}^T)) = \\
 &= (\vec{LF})(\vec{LF})^T + \vec{\varepsilon}(\vec{LF})^T + \vec{LF}\vec{\varepsilon}^T + \vec{\varepsilon}\vec{\varepsilon}^T
 \end{aligned}$$

$\underbrace{\vec{\varepsilon}}_{\substack{\text{la sua media} \\ \text{la matrice Var-Cov} \\ (E(\cdot) = 0)}}$

(174)

$$\star \Sigma = \text{Cov}(\vec{x}) = \mathbb{E}[(\vec{x} - \mu)(\vec{x} - \mu)^T] =$$

$$= L \mathbb{E}[\vec{F}\vec{F}^T] L^T + \mathbb{E}[\vec{\varepsilon}\vec{F}^T] L^T + L \mathbb{E}[\vec{F}\vec{\varepsilon}^T] + \mathbb{E}[\vec{\varepsilon}\vec{\varepsilon}^T]$$

$\vec{\varepsilon} \perp \vec{F} \Rightarrow$ posso fattorizzazione.

$$\mathbb{E}[\vec{\varepsilon}] = 0$$

$$= \underbrace{L \mathbb{E}[\vec{F}\vec{F}^T]}_{L^T} L^T + \mathbb{E}[\vec{\varepsilon}\vec{\varepsilon}^T] = LL^T + \Psi$$

Allora $\text{Cov}(\vec{x})$: matrice varianza cov di F

$$\boxed{\Sigma = LL^T + \Psi}$$

Ψ diagonale.

$$\star \text{Cov}(\vec{x}, \vec{F}) = \mathbb{E}[(\vec{x} - \mu)\vec{F}^T] =$$

$$= \mathbb{E}[L\vec{F}\vec{F}^T + \vec{\varepsilon}\vec{F}^T] = L \text{Cov}(\vec{F}) + \text{Cov}(\vec{\varepsilon}, \vec{F}) =$$

$$= L$$

Quindi:

se voglio spiegare la mia risposta $\vec{x} - \vec{\mu}$ come $(\vec{F} + \vec{\varepsilon})$ con le associazioni di orthogonal factor model

$$1. \Sigma = LL^T + \Psi \quad \left[\begin{smallmatrix} l_{11} & l_{12} & \dots & l_{1m} \\ l_{21} & l_{22} & \dots & l_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ l_{p1} & l_{p2} & \dots & l_{pm} \end{smallmatrix} \right] \left[\begin{smallmatrix} l_{11} & l_{12} & \dots & l_{1m} \\ l_{21} & l_{22} & \dots & l_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ l_{p1} & l_{p2} & \dots & l_{pm} \end{smallmatrix} \right]^T \text{ non realmente}$$

$$\text{Var}(x_i) = l_{i1}^2 + l_{i2}^2 + \dots + l_{im}^2 + \Psi_i \rightarrow \text{Varianza specifica}$$

l_{ij}^2 : somma dei quadrati dei loadings $\sum_{j=1}^p l_{ij}^2$ elemento della matrice i
 Ψ_i : communality o varianza comune

$$\text{Cov}(x_i, x_k) = l_{i1} \cdot l_{k1} + l_{i2} \cdot l_{k2} + \dots + l_{im} \cdot l_{km}$$

$$2. \text{Cov}(\vec{x}, \vec{F}) = L$$

$$\text{Cov}(x_i, F_j) = l_{ij} \quad i = 1 \dots p \quad (\text{variabili})$$

$$j = 1 \dots m \quad (\text{fattori})$$

(175)

Il modello assaiutte che
 p varianze (delle x_i) + $\frac{p(p-1)}{2}$ covarianze
 $\Leftrightarrow p \frac{(p+1)}{2}$ parameetri

Spiegabili da

p in loading + varianze specifiche φ_i
 $= p(m+1)$ obietti

~~Se $m < p$ ho vantaggio: se mi servono 100 fattori per spiegare 100 variabili unica a Gosa d'argos~~

il problema diventa:

Quando la struttura di Σ (osservabile)
può essere decomposta in $LL^T + \Psi$ mcp?

La matrice Σ è la matrice del modello probabilistico
che c'è sotto, ma la osservo, posso stimarla.

$$S = \frac{\sum (x_i - \bar{x})(y - \bar{y})}{n-1} \quad \begin{matrix} \text{stima delle} \\ \text{varianza a} \\ \text{parte dei dati} \end{matrix}$$

Il problema è ben posto? No.

Esempio

$$p=3$$

$m=1 \leftarrow$ voglio trovare un fattore comune

$$\Sigma = \left[\begin{array}{c|cc|c} 1 & 0.9 & 0.7 \\ \hline 0.9 & 1 & 0.4 \\ 0.7 & 0.4 & 1 \end{array} \right]$$

dai nostri vincoli:

$$1 = l_{11}^2 + \varphi_1$$

$$0.9 = l_{11} \cdot l_{21}$$

$$0.7 = l_{11} \cdot l_{31}$$

$$1 = l_{22}^2 + \varphi_2$$

$$0.4 = l_{22} \cdot l_{32}$$

$$1 = l_{33}^2 + \varphi_3$$

$$(176) \begin{cases} 0.7 = l_{11}l_{31} \\ 0.4 = l_{21}l_{31} \end{cases} \Rightarrow l_{21} = \frac{0.4}{l_{31}} = \frac{0.4}{0.7} l_{11} \quad \text{Vincolo}$$

lo butto in

$$0.9 = l_{11}l_{21}$$

$$\Rightarrow 0.9 = l_{11}^2 \cdot \frac{0.4}{0.7} \Rightarrow l_{11}^2 = 1.575$$

$$\boxed{l_{11} = \pm 1.255}$$

$$\text{ma } l_{11} = \text{Cov}(\vec{X}_1, \vec{F}_1) = \text{Cov}(X_1, F_1) \underbrace{\left(\text{Var}(F_1) \cdot \text{Var}(X_1) \right)}_{\substack{\text{tutto} \\ \text{no assunto} \\ \text{che sono 1} \\ 1 \quad 1}}$$

$$\boxed{|l_{11}| \leq 1}$$

\downarrow

il modulo delle correlazioni deve essere ≤ 1 (qui correlazione = cov)

Oppure posso vederlo come

$$1 = l_{11}^2 + \varphi_1 \Rightarrow \varphi_1 = 1 - l_{11}^2 < 0$$

$$\text{Var}(\varepsilon_2) < 0 \quad \text{impossibile!}$$

Quindi con questa matrice c'è

Non troviamo LL^T

\rightarrow dovrò aumentare n

Le cose così migliorano x_k ha meno vincoli
ma

$$m > 1$$

T matrice $m \times m$ ortogonale (notazione) $T^T = T^T = 1$
succede che

$$\vec{X} - \vec{\mu}' = L\vec{F} + \vec{\varepsilon} = \overset{L^*}{\underset{m \times m}{LT}} \overset{F^*}{\underset{m \times n}{T^T}} \vec{F} + \vec{\varepsilon} = L^* \vec{F}^* + \vec{\varepsilon}$$

soddisfa ancora le proprietà di ortogonalità,
 x_k

$$\mathbb{E}[\vec{F}^*] = T^T \mathbb{E}[\vec{F}] = 0$$

$$\text{Cov}(\vec{F}^*) = T^* \text{Cov}(\vec{F}) T = T^T T = I$$

Quindi per $m > 1$ se ho solo 2 soluzioni non ho unicita',

JK posso fare una trasformazione ortogonale

Quindi quando trovo soluzione devo ricordarmi che anche rotando lo è.

Ok.

Sappiamo che mero la traspongo $\Sigma = L L^T + \varepsilon$.

Come posso stimare?

Se ho già struttura diagonale le variabili sono già scomposte quindi è utile che voglio costruire un modello che mi dia cov.

Se nella stima di Σ ho elementi molto piccoli fuori diagonale ha senso cercare il modello.

Metodi di Stima

se la struttura di fattorabilità è fonte dove si ottiene la stessa risposta dai due metodi.

1) PRINCIPAL FACTOR Model

Noi abbiamo Σ e (λ_i, e_i) copie di autovar e autovettori $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0$

Vale la decomposizione

$$\begin{aligned}\Sigma &= \sum_{j=1}^p \lambda_j \vec{e}_j \vec{e}_j^T \\ &= [\sqrt{\lambda_1} \vec{e}_1 | \sqrt{\lambda_2} \vec{e}_2 | \dots | \sqrt{\lambda_p} \vec{e}_p] \begin{bmatrix} \sqrt{\lambda_1} \vec{e}_1^T \\ \sqrt{\lambda_2} \vec{e}_2^T \\ \vdots \\ \sqrt{\lambda_p} \vec{e}_p^T \end{bmatrix}\end{aligned}$$

factor decomposition
con $\varphi \Sigma = 0$ e $m=p$

infatti

$$\Sigma = L L^T + \varepsilon \quad \text{con } L \text{ (mmp)}$$

Sarebbe una decomposizione legittima
MA $p=m$

certo un certo punto questa struttura è truncata a un
basso dimensione di cui considerare il contributo da
un certo punto in poi:

$$d_{m+1} \vec{e}_{m+1} + \dots + d_p \vec{e}_p \vec{e}_p^\top \text{ li batte via:}$$

$$\Sigma \approx \sum_{j=1}^m d_j \vec{e}_j \vec{e}_j^\top$$

C'è stato che sono ordinati
 $i & che teli sono
piccoli$

Quindi

$$L = [\sqrt{\lambda_1} \vec{e}_1 | \dots | \sqrt{\lambda_m} \vec{e}_m]$$

$$\Sigma = LL^\top + \Psi$$

↑

$$\Psi_i = \Sigma_{ii} - \sum_{j=1}^m \lambda_{ij}^2 \quad \forall i=1 \dots p$$

↑ nella parte
diagonale faccio la cosa giusta
Ma nel fuori diagonale.

Così ho la mia
decomposizione ortogonale
che mi serve:

$$\Sigma = \left(\begin{array}{c} \text{(truncamento a } m \\ \text{della decompo} \\ \text{speciale)} \end{array} \right) + \Psi$$

residui
delle varianze

batte via

quando λ è piccolo

$$(si \ guarda \ \frac{\sum \lambda_i^2}{\sum \lambda_i^2})$$

Guardo la varianza
delle componenti scelte /
il totale)

per dimostrare che
se prendo la stima della Σ , s

$$\text{stima della decomposizione troncata}$$

$$\text{tra } (\hat{\Sigma}_{m \times m} + \hat{\Psi}) \text{ e } \Sigma$$

$$\leq \hat{\lambda}_{m+1}^2 + \dots + \hat{\lambda}_p^2$$

→ l'errore che commetto lo posso quantificare
come somma dei quadrati degli
autovalori che batte via.